

计算机工程
Computer Engineering
ISSN 1000-3428,CN 31-1289/TP

《计算机工程》网络首发论文

题目：基于局部偏好优化的大模型机器翻译方法研究
作者：鲁凯文，杨雅婷，董瑞，马博，王磊，周喜，马荣
DOI：10.19678/j.issn.1000-3428.0252213
网络首发日期：2025-09-22
引用格式：鲁凯文，杨雅婷，董瑞，马博，王磊，周喜，马荣．基于局部偏好优化的大模型机器翻译方法研究[J/OL]．计算机工程.
https://doi.org/10.19678/j.issn.1000-3428.0252213



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-09-22 16:49:22　网络首发地址：https://link.cnki.net/urlid/31.1289.tp.20250919.1909.004

计 算 机 工 程
Computer Engineering

基于局部偏好优化的大模型机器翻译方法研究

鲁凯文[1,2,3]，杨雅婷[1,2,3*]，董瑞[1,2,3]，马博[1,2,3]，王磊[1,2,3]，周喜[1,2,3]，马荣[1,2,3]

（1.中国科学院新疆理化技术研究所，乌鲁木齐 830011；
2.中国科学院大学，北京 100049；
3.新疆民族语音语言信息处理实验室，乌鲁木齐 830011）

摘　要：基于直接偏好优化的强化学习方法在大模型诸多下游任务中展现了良好的效果，然而该方法直接应用在机器翻译中常常会因为全局奖励最大化策略而会产生过度优化问题，具体表现为模型过度关注与参考译文的分布一致性，而丧失了局部翻译多样性和全局优化的潜力。为了解决上述问题，探究了直接偏好优化方法在大模型机器翻译中表现劣化的根本原因，在此基础上提出了一种基于局部偏好优化的大模型机器翻译方法。该方法通过对大模型的动态温度采样和无参考评估找出翻译中的易错低频短语，然后提出了一种结合全局差异和局部关键差异的偏好数据构造方法，在综合考虑模型全局翻译效果和局部多样性的前提下提出了 token 级的全局损失和局部损失函数，最后利用两阶段课程学习的策略逐步调整模型对低频短语的输出偏好。提出的方法在 FLORES-200 数据集上进行验证，选取了十四种形态复杂的多语言翻译任务进行测试，实验结果表明，所提方法在 XCOMET、COMET-22 和 BLEU 的得分结果分别为 80.7、89.9 和 30.2。通过与多个多语言机器翻译强基线进行对比，所提方法在所有翻译语向上均优于基线模型，验证了方法的有效性。

关键词：机器翻译；大语言模型；多语言；强化学习；直接偏好优化
中图分类号：TP391　　**文献标志码：**A　　**DOI：**DOI:10.19678/j.issn.1000-3428.0252213

Research on large language model machine translation method based on local preference optimization

LU Kaiwen[1,2,3], YANG Yating[1,2,3*], DONG Rui[1,2,3], MA Bo[1,2,3], WANG Lei[1,2,3], ZHOU Xi[1,2,3], MA Rong[1,2,3]

(1. Xinjiang Technical Institute of Physics and Chemistry, Chinese Academy of Sciences, Urumqi 830011, China;
2. University of Chinese Academy of Sciences, Beijing 100049, China;
3. Xinjiang Laboratory of Minority Speech and Language Information Processing，Urumqi 830011, China)

【Abstract】Reinforcement learning methods based on direct preference optimization have shown excellent results in many downstream tasks of large language models. However, when applied directly to machine translation, this approach often leads to over-optimization problems due to the global reward maximization strategy. Specifically, it causes the model to overly focus on consistency with the distribution of reference translations, thereby losing the potential for local translation diversity and global optimization. To address the aforementioned issues, the problem of performance degradation of direct preference optimization methods in large language model machine translation was investigated. Based on this, a large language model machine translation method based on local preference optimization was proposed. This method identifies frequently mistranslated low-frequency phrases in translations through dynamic temperature sampling and reference-free evaluation of the large language model. Furthermore, a preference data construction method that combines global differences and local key differences is introduced. Considering both the overall translation quality of the model and the local translation diversity, global loss and local loss functions at the token level are proposed. Finally, a two-phase curriculum learning strategy is employed to gradually adjust the model's output preference for low-frequency phrases. The proposed method was validated on the FLORES-200 dataset, selecting fourteen multilingual translation tasks with complex morphologies for testing. The experimental results showed that the scores of the proposed method on XCOMET, COMET-22, and BLEU were 80.7, 89.9, and 30.2, respectively. By comparing with several strong baselines in multilingual machine translation, the proposed method outperformed the baseline models across all translation directions, confirming the effectiveness of the method.

【Key words】machine translation; large language model; multilingual; reinforcement learning; direct preference optimization

0　引言

大语言模型（Large Language Model，LLM）的出现给自然语言处理（Natural Language Processing，NLP）领域带来了一种新的范式[1-3]。当前 LLM 的训练工作主要集中于预训练阶段[4]、监督微调阶段

基金项目：新疆维吾尔自治区天山英才(2022TSYCCX0059)，新疆维吾尔自治区自然科学基金（2022D01D04），新疆维吾尔自治区天山英才（2023TSYCCX0041，2023TSYCCX0044，2022TSYCLJ0046），中国科学院青年创新促进会（Y2021112，Y2023118，2021436），新疆维吾尔自治区上合组织科技伙伴计划及国际科技合作计划项目（2023E01019），国家自然科学基金（62406317）。

通信作者 E-mail：yangyt@ms.xjb.ac.cn

[5]、强化学习阶段[6]，其中强化学习方法侧重于对齐 LLM 和人类的行为偏好，该方法更是被诸如 Deepseek[7]等具有代表性的 LLM 着重使用。现有 LLM 强化学习方法主要基于近端策略优化方法[8]（Proximal Policy Optimization，PPO）和直接偏好优化方法[9]（Direct Preference Optimization，DPO），其中 DPO 可以使用简单的二元交叉熵目标来优化策略,从而生成符合偏好数据的隐式奖励函数的最优策略，相比 PPO 来说 DPO 更加容易实现并且消耗的计算资源更少，因而受更多轻量级方法和模型的青睐。

尽管 DPO 在 NLP 的诸多下游任务中展现了良好的表现[10,11]，但与这些期望相悖的是，如果在翻译任务上将一个经过翻译监督微调（Supervised Fine-Tun-ing，SFT）的 LLM 直接在翻译偏好语料上进行 DPO，所得到的模型相较其他任务的 DPO 来说效果会远低于期望，甚至会出现比 SFT 模型效果更差的情况，这也被看做是 DPO 在翻译任务上的劣化问题。Xu 等人[12]将此问题归结于 DPO 的标准参考答案已经不如模型生成的翻译结果，从而使得标准的 DPO 数据构造方法无法为已经足够强大的 LLM 翻译系统带来正面提升。类似的，He 等人[13]认为现有方法对基于人类反馈构建的翻译强化学习数据建模不足，导致数据带来的翻译偏好监督信号弱，并且这种人类翻译偏好可以直接被机器翻译质量评估方法（Quality Estimation, QE）近似取代。

为了缓解强化学习方法在机器翻译任务上带来的负优化问题，本文系统地探究了强化学习在机器翻译任务上劣化的问题来源，并在此基础上对模型进行多次独立采样生成局部最优候选短语，之后应用局部偏好优化方法来增强模型对局部最优翻译的偏好以缓解 DPO 造成的全局劣化问题的产生。本文提出的局部偏好优化方法（Local Preference Optimization, LPO）在 FLORES-200[14]数据集上选取的二十八个具有挑战性的翻译方向上均取得了提升。通过与基线和其他具有代表性的 LLM 对比可知，本文提出的方法可以在保证全局翻译质量的前提下有效提升 LLM 的局部翻译效果并能很好的缓解强化学习带来的劣化问题。

1 相关工作

1.1 大模型机器翻译

随着 LLM 的出现，其非凡的语义理解能力和生成类人文本的强大能力改变了 NLP 诸多下游任务的范式，也促使神经机器翻译的研究开始从传统的 Transformer 类方法转向基于 LLM 的翻译方法上。

Mao 等人[15]通过构建翻译指令和跨语言对齐指令来提高 LLM 在零样本翻译中的性能。Zhang 等人[16]比较了三种 LLM 翻译方法的性能，分别是零样本提示方法、少样本学习方法和翻译微调方法微调，并在句子级和文档级的翻译任务上量化对比了这些方法。Zhang 等人通过使用交互式翻译任务数据对 LLM 进行 SFT，将语言生成和对话跟踪能力从英语转移到其他语言，并开发了一个名为 BayLing 的翻译 LLM。侯钰涛等人[17]提出了一种基于 NLLB 模型的低资源语言机器翻译训练方法，通过数据增强和损失函数的优化有效提升了模型在越南语和老挝语翻译任务中的表现。Yin 等人[18]提出了一种简单而有效的数据收集方法，即使用双语字典来生成数据集。在对收集到的数据进行微调后，LLM 在涉及专门的术语翻译的任务中显示出了显著的性能改进。Feng 等人[19]提出了一个名为 TEaR 的 LLM 自我细化框架，它包含了翻译生成、翻译评估、迭代细化三个过程，提高了 LLM 在高低资源和英语与非英语间的翻译质量。Raunakd 等人[20]利用思维链的方式将 GPT4 作为译后编辑模型以改进翻译的输出结果。李博等人[21]提出了一种针对 LLM 的译文易错词纠正机制，利用大模型和小模型结合的方式有效纠正了 LLM 机器翻译过程中产生的易错词。

1.2 大模型强化学习应用

强化学习通过优化决策过程、对齐人类偏好来提升 LLM 的可控性和一致性。Ma 等人[22]提出了一种名为 EUREKA 的方法，该方法利用最先进的 LLM 的代码生成能力和上下文改进能力，对强化学习的奖励进行进化优化，由此产生的奖励可以使得模型通过强化学习获得执行复杂任务的技能。Wu 等人[23]利用书面指导手册来帮助提高针对特定任务的策略学习能力，提出了阅读和奖励框架以此训练了一个更高效和表现更好的智能体。Zhou 等人[24]提出了一个新的框架，即通过使用来自基于 LLM 的教师智能体的指令来培训一个更小的、专业的学生强化学习

智能体，该智能体可以将 LLM 的先验知识提取到它自己的模型中，因此学生智能体可以用更少的数据进行训练，通过进一步的环境反馈培训，学生智能体在任务上的表现超越了其教师智能体。罗焕坤等人[25]总结了包括强化学习在内的 LLM 在数学推理中的进展。

现有大模型机器翻译方法大多聚焦于利用 SFT 对 LLM 进行微调或者对 LLM 输入和输出进行改进，而现有的强化学习研究也仍然缺乏对翻译任务劣化原因的探索和针对性调整。

2 基于局部偏好优化的大模型训练方法

为缓解强化学习在 LLM 机器翻译任务上的劣化问题和提升 LLM 机器翻译的表现，本章首先分析了 LLM 机器翻译的偏好，揭示了强化学习在该任务上劣化的具体原因，其次通过多样化的翻译偏好数据构造和“全局+局部”的偏好损失设计，有效提高了强化学习在 LLM 翻译任务上的表现。

2.1 大模型翻译偏好分析

虽然 LLM 可以通过广泛的无监督学习获得流利地输出语言的能力，但由于其训练的完全无监督性质，精确控制其行为的挑战仍然存在。为了解决这个问题，通常使用基于人类反馈的强化学习对其进行偏好对齐。然而，这个过程是复杂且不稳定的。为了简化这个过程，Rafailovd 等人提出了 DPO 方法，损失函数如下所示：

$$L_{\mathrm{DPO}}(\pi_\theta;\pi_{\mathrm{ref}})=-\mathbb{E}_{\sim\mathcal{D}}\left[\log\sigma\left(\beta\left(\log\frac{\pi_\theta(y_w\mid x)}{\pi_{\mathrm{ref}}(y_w\mid x)}-\log\frac{\pi_\theta(y_l\mid x)}{\pi_{\mathrm{ref}}(y_l\mid x)}\right)\right)\right]，(1)$$

其中π_θ是当前模型的状态，θ代表当前的具体参数，π_{ref}是一个理想状态下的模型分布，也是当前模型的最终目标，$\mathcal{D}$为 DPO 数据集，一般包括的样本形式为（x，y_w，y_l），代表了一个输入x和一个理想的、更加正确的文本y_w以及一个相较更劣质的文本y_l，σ是 sigmoid 的函数，用于将输入映射到[0,1]，β是一个超参数，用于控制不合理文本相对于合理文本的权重。整个损失函数的意图为，通过训练使模型更倾向于选择y_w作为输出而拒绝以y_l作为输出，以此来控制模型的输出偏好。

这种任务形式在大多数开放式的生成任务上展现出了显著的优势，但在机器翻译这一特殊场景下却面临着特殊的挑战。相较于多数生成任务仅需保持主题连贯性，机器翻译存在严格的输入-输出映射约束，即输出和输入的相关性远高于其他生成式任务。其次，翻译还具有一定的灵活发挥空间，最好的翻译往往不是严格按照源句逐字进行翻译的。与之矛盾的是 DPO 的标准训练策略会使模型过度关注与参考译文的全局分布一致性而抑制局部翻译的多样性和模型进一步提升的潜力。

具体地，对于机器翻译中的 DPO 数据构建范式来说，DPO 数据的构造往往依赖于人类译员给予的参考译文和模型生成的译文来组成偏好数据[26]。这种数据构造机制在基础模型训练阶段具有指导意义，但随着 LLM 翻译能力的突破性进展，其内在缺陷逐渐显现：（1）偏好优化数据来源相对单一，这意味着模型往往要朝着一个固定的y_w（参考译文）来进行偏好的对齐，这也抑制了模型输出的多样性；（2）根据现有的研究，一些优秀的翻译 LLM 已经可以在部分语言上输出优于大多人类译员的翻译结果，例如 InstructGPT[27]、GPT4[28]、X-ALMA[29]等，这标志着对于优秀的翻译 LLM 来说，人类译员的翻译结果已经不再是唯一标准的黄金参考了，相应的，传统的 SacreBLEU[30]和 COMET[31]等有参考的翻译评价指标已经不适合作为此类场景的绝对量化指标了。

为了将这种困境形式化出来，本文利用一个强大的多语言机器翻译大模型 X-ALMA-13B 作为基础模型，将翻译语向设置为中文到英文，之后对其进行一百次的非连续独立采样，最后对所有结果利用无参考翻译评价指标 XCOMET[32]计算得分。得到的结果统计分类如图 1 所示，经过去重计数统计所有输出共可分为十一类，之后将十一种译文按语序拆分合并，将这种输出流看做源语言约束下的 LLM 输出偏好分布并以此绘出桑基图，不同输出的 XCOMET 得分置于最后一列。

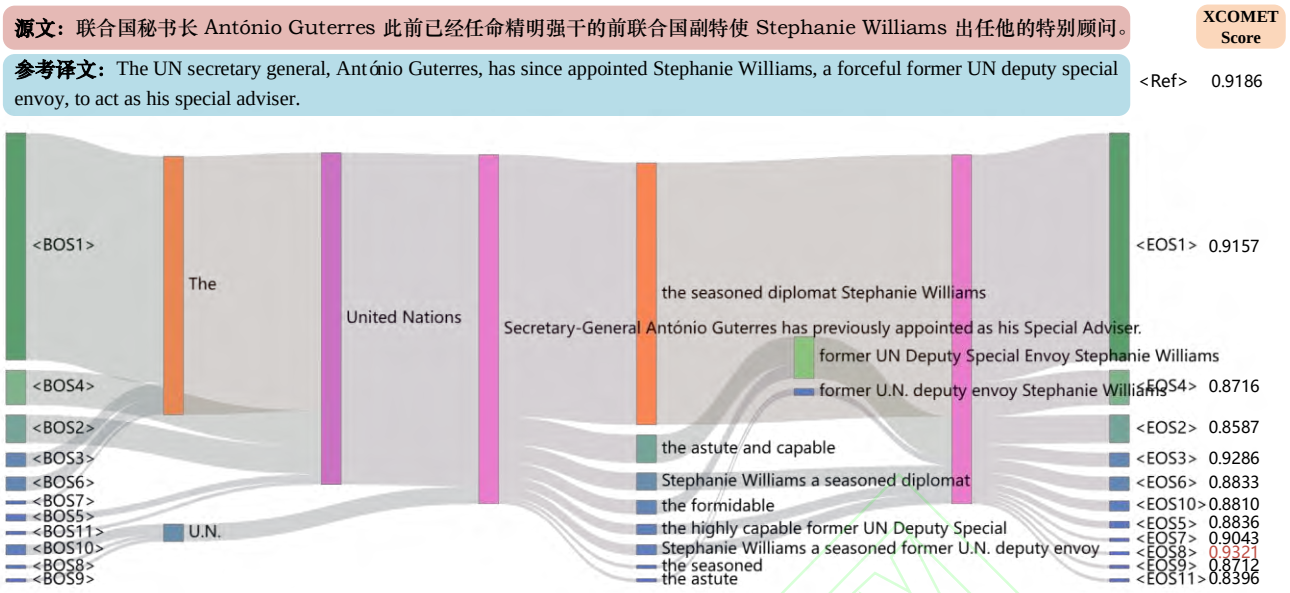


图 1　LLM 翻译偏好流向

Fig.1　Large language model translation preference flow

通过对图 1 的分析可以发现，在一些高频翻译短语（例如“联合国”）上，模型展现出了高度的确定性并且不会有太大的分歧，但在一些低频的短语（例如“精明强干”）上，模型的输出就变得不确定并且多样化。对其的定量分析更凸显传统参考标准的局限性，根据 XCOMET 分数可以看出，最高频的输出（<BOS1>）的分数仅在所有输出中排名第三位，这种"高频低质"现象表明模型在解码时更倾向于选择训练数据中统计显著的表达方式，而非语义层面的最优解。进一步观察可以发现，甚至参考译文<Ref>的分数都低于两个 LLM 的低频输出。这种现象证明参考译文已经不再对 LLM 有着绝对正确的指导了，并且 LLM 有潜力在一些低频短语上产生更加良好的表现。

2.2 翻译局部偏好优化方法

为了找出翻译中低频且正确的短语和提高模型对这些短语的输出偏好，本文提出了“先发现、后训练”的两阶段训练方法，整体结构如图 2 所示。

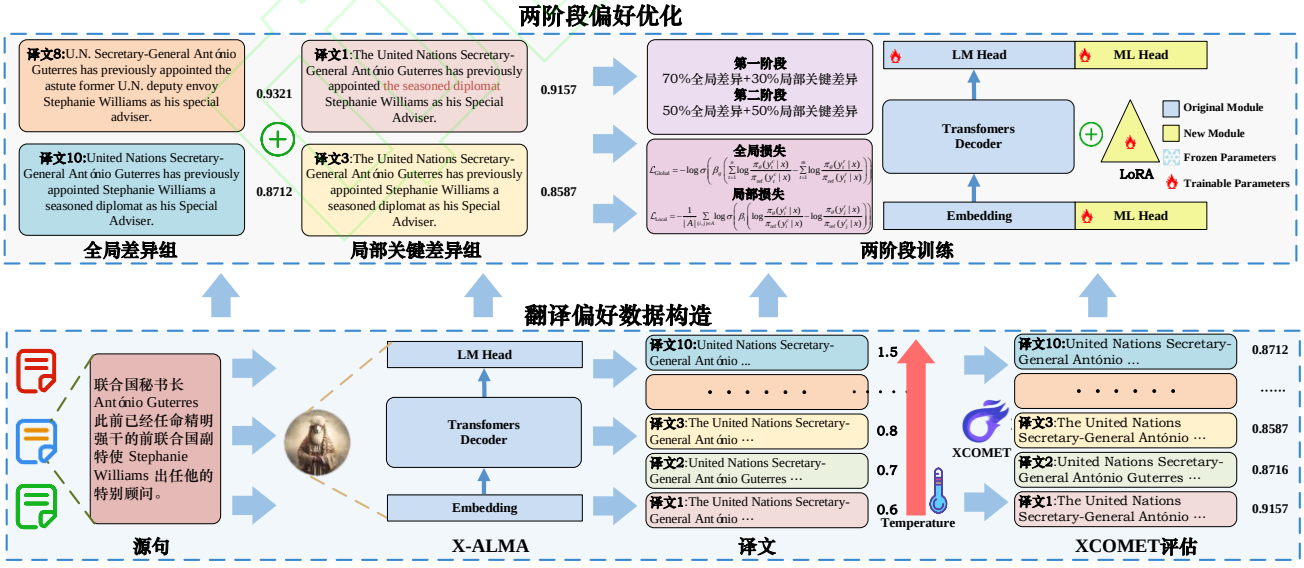


图 2　局部偏好优化方法

Fig.2　Local preference optimization method

第一阶段以提升低频输出概率构造偏好数据为主要任务，第二阶段通过“全局+局部”的两阶段多粒度优化模型的偏好。本节将从翻译偏好数据构造和两阶段多粒度局部偏好优化两方面对本文所提出的局部偏好优化方法（Local Preference Optimization，LPO）进行阐述。

2.2.1 翻译偏好数据构造

为了尽可能激发模型潜在的低频翻译能力，本文提出了一种动态温度采样策略，采用X-ALMA-13B作为基础生成模型，设计线性温度调度机制控制生成多样性。具体地，对每个源句执行10轮独立采样，温度参数τ按$\tau_k = 0.5 + 0.1\mathrm{k}(\mathrm{k} \in 1,\ldots,9)$，即从0.6递增至1.5。低温阶段（$\tau < 1.0$）通过锐化概率分布生成保守翻译，保证核心语义准确性；高温阶段（$\tau \geq 1.0$）则扩大采样空间，探索潜在合理表达。每轮采样生成10个候选翻译，覆盖从偏向直译到偏向意译的连续性表达谱系，并用XCOMET作为评估标准对所有候选翻译进行打分，以待后续训练使用。

2.2.2 局部偏好优化

为了优化LLM对低频且正确的短语偏好，本文提出了层次差异化数据分组和基于课程学习的两阶段偏好优化训练策略。

层次差异化数据分组方面，本文基于XCOMET评估分数和编辑距离从10组候选翻译中，构建双层对比样本集以适配翻译任务的细粒度优化需求进行筛选。在全局差异组层面，筛选出候选组中XCOMET分数差异最大的两个样本，该组样本呈现整体翻译质量的显著差异，主要反映宏观层面的改进空间。在局部关键差异层面，首先两两计算样本间的最小编辑距离$d_{Levenshtein}$，考虑到语种之间的字符数量的差异性，故在所有计算结果中，选取$d_{Levenshtein}$大于0且数值最低的30%的候选组，在其中选择XCOMET差异最大的那一个样本组，该组样本呈现出局部翻译质量的显著差异，主要反映局部层面的改进空间。

偏好优化方面，本文设计了一种两阶训练方法，整体损失函数$\mathcal{L}_{\mathrm{LPO}}$如下所示：

$$\mathcal{L}_{\mathrm{LPO}} = \alpha\mathcal{L}_{\mathrm{Global}} + (1-\alpha)\mathcal{L}_{\mathrm{Local}}, \quad (2)$$

其中$\mathcal{L}_{\mathrm{Global}}$为全局损失，$\mathcal{L}_{\mathrm{Local}}$为局部损失，$\alpha$在第一阶段为0.7，在第二阶段设置为0.5。全局损失函数$\mathcal{L}_{\mathrm{Global}}$具体如下所示：

$$\mathcal{L}_{\mathrm{Global}} = -\log\sigma\left(\beta\left(\sum_{t=1}^{n}\log\frac{\pi_\theta(y_t^w \mid x)}{\pi_{\mathrm{ref}}(y_t^w \mid x)} - \sum_{t=1}^{m}\log\frac{\pi_\theta(y_t^l \mid x)}{\pi_{\mathrm{ref}}(y_t^l \mid x)}\right)\right), \quad (3)$$

为了后续局部损失的表示便利，本文将式(3)从式(1)的句子级整体表示修改为token级累计的形式，n表示DPO数据中“Chosen”的长度，m表示DPO数据中“Rejected”的长度。局部损失$\mathcal{L}_{\mathrm{Local}}$定义如下：

$$\mathcal{L}_{\mathrm{Local}} = -\frac{1}{|A|}\sum_{(i,j)\in A}\log\sigma\left(\beta\left(\log\frac{\pi_\theta(y_i^w \mid x)}{\pi_{\mathrm{ref}}(y_i^w \mid x)} - \log\frac{\pi_\theta(y_j^l \mid x)}{\pi_{\mathrm{ref}}(y_j^l \mid x)}\right)\right), \quad (4)$$

其中$A(y^w, y^l)$代表y^w和y^l的差异区域的集合，(i,j)则分别代表y^w和y^l中具体的差异位置，且规定

$$y_i^w \neq y_j^l, \quad (5)$$

式(4)即可表示为，“Chosen”和“Rejected”中关键差异区域的损失。在两阶段训练的数据采样方面，和α类似的是，第一阶段分别采样70%的全局差异组和30%的关键差异组，第二阶段采样50%的全局差异组和50%的关键差异组，通过课程学习的方式让模型在不丢失全局输出偏好的前提下渐进地改进模型对于低频短语的准确率。

3 实验设置

3.1 数据集

为了全面评估本文提出的方法在多语言复杂场景下的泛化能力和鲁棒性，本实验选择了包含50种语言的X-ALMA-Preference数据集，并将该数据集的源句作为本文偏好数据构造的输入来源，该数据集主要来源于两个权威多语言评估基准：Flores-200的验证集和NTREX[33,34]的测试集。并按照X-ALMA的设置，同样选择了两种不同的翻译场景，第一组是如表1所示的六种书写系统差异较大的语言组，该组包括六种形态复杂的不同语言，分别是中文、爱沙尼亚语、芬兰语、格鲁吉亚语、日语、韩语，且这些语言在LLM预训练阶段所使用的资源数量级差距较大，能够很好的展示本文方法在形态复杂场景下的健壮性。第二组是如表2所示的八种相似语言，分别是阿拉伯语、阿塞拜疆语、希伯来语、哈萨克语、吉尔吉斯语、波斯语、土耳其语、乌兹

别克语，这些语言在训练阶段使用的数据规模相对较少，可以用来衡量本实验方法在低资源相似语言翻译场景的表现。实验采用 Flores-200 的标准测试集进行最终评估，重点考察实验语言与英语之间的双向互译任务。

表 1 书写系统差异组数据分布情况

Table 1 Data distribution of script difference group

语言	ISO 代码	书写系统	语族	子群	训练集大小		测试集规模	
					en→xx	xx→en	en→xx	xx→en
中文	zh	汉字	汉藏语系	汉语族	15628	14927	1012	1012
爱沙尼亚语	et	拉丁字母	乌拉尔语系	芬兰语支	11110	10982	1012	1012
芬兰语	fi	拉丁字母	乌拉尔语系	芬兰语支	15114	15626	1012	1012
格鲁吉亚语	ka	格鲁吉亚字母	南高加索语系	格鲁吉亚-赞语支	2994	2993	1012	1012
日语	ja	日文	日本语系	日语支	15460	15672	1012	1012
韩语	ko	谚文（韩字）	朝鲜语系	朝鲜语支	7292	7343	1012	1012

表 2 中亚语言组数据分布情况

Table 2 Data distribution of Central Asia language group

语言	ISO 代码	书写系统	语族	子群	训练集大小		测试集规模	
					en→xx	xx→en	en→xx	xx→en
阿拉伯语	ar	阿拉伯字母	亚非语系	中闪米特语支	7185	7137	1012	1012
阿塞拜疆语	az	拉丁字母	突厥语族	乌古斯语支	2994	2994	1012	1012
希伯来语	he	希伯来字母	亚非语系	西北闪米特语支	6677	7126	1012	1012
哈萨克语	kk	西里尔字母	突厥语族	钦察语支	4992	4991	1012	1012
吉尔吉斯语	ky	西里尔字母	突厥语族	钦察语支	2994	2994	1012	1012
波斯语	fa	波斯字母	印欧语系	伊朗语支	7488	7115	1012	1012
土耳其语	tr	拉丁字母	突厥语族	乌古斯语支	13000	13310	1012	1012
乌兹别克语	uz	拉丁字母	突厥语族	葛逻禄语支	2994	2994	1012	1012

3.2 基线设置

为了测试本文所提出的 LPO 方法，选取了五个强大的开源多语言 LLM 作为基线，包括：

（1）NLLB-200：是一种利用跨语言迁移学习的单一大规模多语言机器翻译模型，NLLB 开发了一个基于稀疏门控混合专家架构的条件计算模型，使用针对资源匮乏语言定制的新挖掘技术获得的 200 种语言数据进行训练。

（2）Aya-101[35]：是一种采用了与 MT5-xxl[36]相同的架构多语言翻译 LLM，该模型收集了 101 种语言的翻译数据并用多种数据增强策略对数据进行扩充，之后对模型进行了多语言微调。

（3）LLaMAX3-Alpaca[37]：是一个基于 LLaMA2[38]的多语言翻译 LLM，其在 LLaM2 的基础上通过词汇拓展和数据增强等策略全面增强了其在翻译任务上的表现。

（4）LLaMA-3.1-8B-Instruct[39]：是目前最强大的通用开源模型之一，LLaMA-3.1 采用了多轮迭代的训练方式，在常识、可控性、数学、工具使用和多语言翻译方面都具有极好的表现。

（5）X-ALMA-13B：是一个强大的多语言翻译 LLM，也是本文方法的基线模型。其在 ALMA-13B-R 的基础上拓展了 50 种语言，并利用类似于专家混合模型（Mixture of Experts, MOE）的方式避免了多语言带来的灾难性遗忘的问题。

3.3 评估指标

在本文中，翻译效果评估主要依据无参考评估方法 XCOMET，此外本文还引入了传统的有参考翻译质量评估指标 SacreBLEU 和 COMET-22[40]作为辅助参考。

3.4 实验设置

本文的方法以一个强大的多语言机器翻译大模

型 X-ALMA-13B 作为基础模型。实验环境设置为 Ubuntu 22.04.5，共计使用 12 块 GPU，型号为 NVIDIA Tesla A100，单卡显存为 80GB。参数设置为精度为 bf16，β设置为 0.1，学习率设置为 1e-4，句子最大长度为 512，Batch size 设置为 2，训练使用 DeepSpeed Zero3 进行加速。

3.5 提示设置

为了在保持模型的基础能力，本文沿用了 X-ALMA 的提示模板，如图 3 所示，其中<source language name>和<target language name>分别代表源语言和目标语言的英文全称，<source language sentence>代表输入的待翻译源句。

```
<s>[INST] Translate this from <source language name> into
<target language name> :
<source language name> : <source language sentence>
<target language name> : [/INST]
```

图 3 提示模版示例

Fig.3 Example of a prompt template

4 实验结果及分析

4.1 对比实验

本实验对比分析了 NLLB-200、Aya-101、LLaMAX3-Alpaca、LLaMA-3.1-8B-Instruct、X-ALMA-13B 以及本文使用的局部偏好优化方法 X-ALMA-LPO 在 FLORES-200 数据集上选取的两组不同翻译场景下的翻译能力。结果分别如表 3 和图 4 所示。

表 3 书写系统差异组对比实验

Table 3 Comparative experiment of script difference group

Models	en→et			en→fi			en→ja			en→ka		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
Llama-3.1*	9.3	66.3	48.1	16.0	82.0	70.4	10.8	66.0	25.0	7.0	73.1	48.1
NLLB-3.3B*	25.0	90.5	79.7	24.1	91.7	81.1	22.6	87.9	75.1	14.8	84.6	70.2
LLaMAX2-Alpaca-7B*	19.0	88.4	76.1	18.4	90.2	79.6	28.1	88.9	78.1	10.7	83.0	68.2
LLaMAX3-Alpaca-8B*	18.1	87.7	75.1	17.5	89.3	77.6	27.5	89.0	77.3	9.6	78.6	55.9
Aya-101*	21.9	90.7	81.3	18.9	90.3	78.9	27.3	89.0	77.4	11.3	85.3	72.1
X-ALMA*	27.9	92.2	84.0	26.4	92.9	85.2	36.6	91.7	81.9	15.2	88.5	76.9
X-ALMA-LPO (ours)	**28.0**	**92.4**	**84.8**	**26.6**	**93.1**	**85.9**	**36.6**	**91.9**	**82.7**	**15.5**	**88.7**	**77.7**

Models	en→ko			en→zh			Avg.en→xx		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
Llama-3.1*	6.8	71.5	41.7	14.0	67.7	37.6	10.6	71.1	45.1
NLLB-3.3B*	12.5	88.4	79.1	32.4	82.0	64.1	21.9	87.5	74.9
LLaMAX2-Alpaca-7B*	10.3	86.8	76.7	35.2	85.5	74.0	20.3	87.1	75.4
LLaMAX3-Alpaca-8B*	8.8	85.6	74.0	36.3	85.6	73.3	19.6	86.0	72.2
Aya-101*	10.2	87.4	77.2	27.3	82.4	64.7	19.5	87.5	75.3
X-ALMA*	15.8	89.9	81.6	44.9	88.7	78.4	27.8	90.6	81.3
X-ALMA-LPO (Ours)	**16.1**	**90.2**	**82.6**	**45.0**	**88.9**	**79.3**	**28.0**	**90.9**	**82.2**

Models	et→en			fi→en			ja→en			ka→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
Llama-3.1*	4.1	45.9	51.6	5.8	53.3	52.8	17.7	69.4	67.6	0.3	39.2	34.3
NLLB-3.3B*	7.2	62.5	29.9	10.2	67.7	39.2	17.2	79.5	61.0	25.6	84.8	70.3

LLaMAX2-Alpaca-7B*	32.1	87.4	80.7	31.7	89.0	78.9	23.4	87.1	76.4	18.1	76.7	66.8
LLaMAX3-Alpaca-8B*	33.6	88.3	82.2	31.6	89.3	79.4	24.6	87.5	76.9	1.2	50.7	51.5
Aya-101*	32.5	87.7	80.2	29.7	88.6	77.8	23.5	86.5	75.5	25.6	84.5	69.7
X-ALMA*	38.8	89.6	83.5	36.2	90.5	80.4	28.8	88.5	77.7	29.3	87.1	72.8
X-ALMA-LPO (Ours)	**38.8**	**89.7**	**84.2**	**36.3**	**90.5**	**80.9**	**29.0**	**88.6**	**78.4**	**29.5**	**87.4**	**73.6**

Models	ko→en			zh→en			Avg.xx→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
Llama-3.1*	15.9	66.0	62.4	24.2	78.8	69.9	11.3	58.8	56.4
NLLB-3.3B*	26.2	84.9	73.1	16.8	77.1	52.8	17.2	76.1	54.4
LLaMAX2-Alpaca-7B*	25.2	86.6	76.4	25.8	86.5	77.2	26.1	85.5	76.1
LLaMAX3-Alpaca-8B*	26.3	87.5	77.1	25.9	86.6	77.3	23.9	81.7	74.1
Aya-101*	26.5	87.0	76.9	23.1	84.5	71.8	26.8	86.5	75.3
X-ALMA*	30.8	88.7	78.1	29.6	87.6	78.1	32.2	88.7	78.4
X-ALMA-LPO (Ours)	**30.9**	**88.7**	**78.9**	**29.7**	**87.8**	**78.7**	**32.4**	**88.8**	**79.1**

注：粗体代表在该翻译方向上的最高分，带有*的模型结果来自 X-ALMA，表中 en→et 表示从 en 翻译到 et，以此类推。

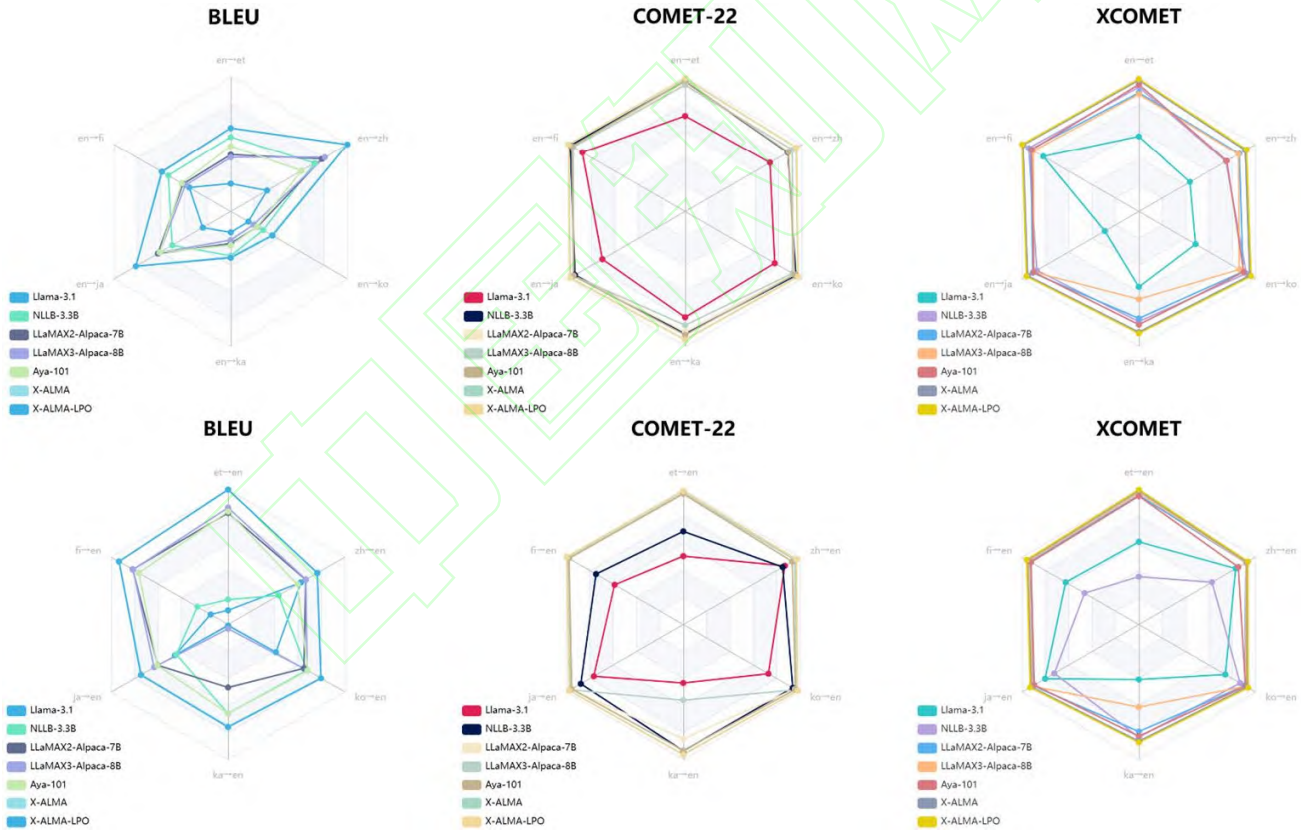


图 4　中亚语言组对比实验

Fig.4　Comparative experiment of Central Asia language group

本文所提出的LPO方法在所有翻译语向上均获得了显著的提升，特别是在 en→xx 的所有翻译方向上，这一现象与当前 LLM 的预训练数据分布特性及多语言能力的不均衡性密切相关。具体而言在于在模型的预训练和监督微调过程中英语等高资源语言所占比重较大，模型对于英语等高资源语言的理解和输出能力较强，对于其他低资源语言的理解和输出能力则相对较差，这些语言的所涉及的低频短语

也相对更多，故而以这些非英语语言为输出的翻译方向能从 LPO 中获得更多的提升。

4.2 消融实验

为了证明本文方法的有效性，本实验在两组不同翻译场景上各设置了 2 组消融实验：第一组为只进行动态温度采样和翻译差异组构造的实验。即在 X-ALMA 的基础上进行动态数据采样，将所得数据进行差异区分，对 X-ALMA 直接采用原始的 DPO 方法训练。第二组为只进行局部偏好优化的实验。即不进行特别的数据筛选，直接利用 X-ALMA-Preference 数据集独立采样两次构造训练数据，采用两阶段的损失函数对 X-ALMA 进行训练。表 4 和表 5 给出了消融实验的结果，其中 w/o LPO 代表去掉改进的损失函数，只进行数据构造的方法，w/o DA 表示去掉数据构造只进行损失函数改进的方法。实验表明，无论是单独去除数据构造模块还是损失函数改进模块，都会导致模型性能出现不同程度的下降。深入分析这一现象可以发现，当缺乏数据构造方法时，模型训练将受限于单一且同质化的监督信号，无法获取足够多样化的训练样本，这会显著制约模型对复杂翻译场景的适应能力。与此同时，若仅依赖传统 DPO 损失函数而缺少本文提出的改进方案，模型会因 DPO 固有的“过度拒绝”机制而产生性能劣化问题，导致翻译质量下降。实验结果证明，将多层次数据构造方法与改进的损失函数设计相结合，通过二者的协同作用，既确保了训练数据的丰富性和代表性，又优化了模型的学习动态，从而显著提升了大型语言模型在多样化翻译任务上的整体表现。

表 4　书写系统差异组消融实验

Table 4　Ablation experiment of script difference group

Models	en→et			en→fi			en→ja			en→ka		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**28.0**	**92.4**	**84.8**	**26.6**	**93.1**	**85.9**	**36.6**	**91.9**	**82.7**	**15.5**	**88.7**	**77.7**
w/o DA	27.7	92.1	83.9	26.2	92.7	84.9	36.2	91.4	82.0	15.0	88.3	76.8
w/o LPO	27.3	91.7	83.2	25.9	92.4	84.2	35.6	90.8	81.5	14.7	87.9	76.3

Models	en→ko			en→zh			Avg.en→xx		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**16.1**	**90.2**	**82.6**	**45.0**	**88.9**	**79.3**	**28.0**	**90.9**	**82.2**
w/o DA	15.5	89.6	81.8	44.6	88.5	78.2	27.5	90.4	81.3
w/o LPO	15.2	89.1	81.3	44.0	87.9	77.8	27.1	90.0	80.7

Models	et→en			fi→en			ja→en			ka→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**38.8**	**89.7**	**84.2**	**36.3**	**90.5**	**80.9**	**29.0**	**88.6**	**78.4**	**29.5**	**87.4**	**73.6**
w/o DA	38.5	89.0	83.7	35.9	90.1	80.2	28.5	88.0	77.8	28.9	86.9	72.8
w/o LPO	38.2	88.5	83.1	35.7	89.6	79.7	28.3	87.9	77.5	28.6	86.8	72.4

Models	ko→en			zh→en			Avg.xx→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**30.9**	**88.7**	**78.9**	**29.7**	**87.8**	**78.7**	**32.4**	**88.8**	**79.1**
w/o DA	30.7	88.4	78.3	29.5	87.6	78.0	32.0	88.3	78.5
w/o LPO	30.4	88.0	77.8	29.3	87.3	77.6	31.8	88.0	78.0

表 5 中亚语言组消融实验

Table 5 Ablation experiment of Central Asia language group

Models	en→ar			en→az			en→fa			en→he		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**28.6**	**88.4**	**79.1**	**14.3**	**88.5**	**79.5**	**27.2**	**89.0**	**81.0**	**33.7**	**89.8**	**79.7**
w/o DA	28.4	87.9	78.8	14.1	88.2	79.1	26.5	88.4	80.5	33.4	89.3	79.5
w/o LPO	28.0	87.5	78.2	13.8	87.9	78.7	25.8	88.4	80.0	33.0	89.0	78.8

Models	en→kk			en→ky			en→tr			en→uz		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**22.3**	**91.3**	**81.6**	**12.4**	**89.1**	**79.3**	**28.7**	**90.0**	**78.9**	**15.8**	**90.7**	**77.5**
w/o DA	22.2	89.6	81.2	12.3	88.5	78.5	27.8	90.4	78.4	15.5	89.7	77.4
w/o LPO	21.4	89.1	81.2	12.1	88.4	78.1	27.4	90.3	78.0	15.2	89.3	77.2

Models	Avg.en→xx			ar→en			az→en			fa→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**22.9**	**89.7**	**79.6**	**41.2**	**88.4**	**76.8**	**25.5**	**87.2**	**75.8**	**38.2**	**89.0**	**75.7**
w/o DA	22.5	89	79.2	40.5	88.1	76.3	24.9	86.8	75.6	38.0	88.6	75.2
w/o LPO	22.1	88.7	78.8	40.3	87.9	76.2	24.7	86.5	75.2	37.5	88.4	74.8

Models	he→en			kk→en			ky→en			tr→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**44.2**	**89.0**	**76.8**	**34.9**	**88.4**	**76.8**	**25.0**	**86.1**	**74.8**	**40.2**	**90.1**	**78.7**
w/o DA	43.8	88.7	75.6	34.7	87.3	76.2	24.4	85.8	74.5	40.0	89.8	78.4
w/o LPO	43.6	88.1	75.5	34.5	87.0	75.8	24.0	85.8	74.3	39.7	89.6	78.1

Models	uz→en			Avg.xx→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**33.6**	**87.4**	**74.3**	**35.4**	**88.2**	**76.2**
w/o DA	33.1	86.9	74.1	34.9	87.8	75.7
w/o LPO	33.2	86.4	73.7	34.7	87.5	75.5

4.3 案例研究

为了进一步说明 LPO 方法的有效性，从测试集中抽取出了 en→zh 的一组样本并分别给出参考译文、本文基线 X-ALMA 和本文方法 X-ALMA-LPO 输出的结果，结果如表 6 所示，通过对比可以明显观察到，X-ALMA-LPO 生成的译文在语序组织上更为自然流畅，整体可读性显著提升。特别是在处理“germ-line cells”等专业低频术语时，LPO 方法展现出更精准的翻译能力，避免了基线模型可能出现的语义偏差或表达生硬等问题。以上实例证明，LPO 方法不仅在宏观层面的语义连贯性和语言流畅度上有所突破，在微观层面的专业术语和低频词汇处理上也取得了实质性进展。这种全局与局部翻译效果的双重提升，验证了 LPO 方法在解决 LLM 翻译任务中的关键挑战方面具有独特优势，为提升机器翻译质量提供了新的技术思路。实验结果从定性和定量两个维度共同证实，相比传统方法，LPO 能够产生更符合人类语言习惯的高质量翻译输出。

表 6 案例研究

Table 6 Case study

源文	Mutations can have a variety of different effects depending on the type of mutation, the significance of the piece of genetic material affected and whether the cells affected are germ-line cells.
参考译文	突变会产生各种各样不同的影响，这取决于突变的类型、受影响遗传物质的重要性以及受影响的细胞是否为生殖系细胞。
X-ALMA	突变的影响取决于突变的类型、受影响基因物质的重要性以及受影响细胞是否为受精卵细胞。
X-ALMA-LPO	突变可能会产生多种不同的影响，这取决于突变的类型、受影响基因物质的重要性以及受影响的细胞是否是生殖细胞。

5 结束语

本文提出了一种针对 LLM 机器翻译任务的局部偏好优化训练方法，该方法首先通过动态温度采样和评估构造了多样的偏好数据，在此基础上设计了两阶段的损失函数，旨在缓解 DPO 带来的劣化问题并在保障整体翻译质量的前提下提升 LLM 在翻译中的局部表现。实验结果表明，本文方法有效地增强了 LLM 在翻译任务中的整体表现，并提高了 LLM 对一些低频词的翻译准确性。未来将探索本文所提出的方法在更多的翻译方向和不同的 LLM 基座上的普适性，以及研究本文方法在多语言翻译的零样本翻译方向上的影响。

参考文献

[1] Touvron H, Lavril T, Izacard G, et al. LLaMA: open and efficient foundation language models. arXiv[J]. arXiv preprint arXiv:2302.13971, 2023.

[2] Anil R, Dai A M, Firat O, et al. Palm 2 technical report[J]. arXiv preprint arXiv:2305.10403, 2023.

[3] Chowdhery A, Narang S, Devlin J, et al. Palm: Scaling language modeling with pathways[J]. Journal of Machine Learning Research, 2023, 24(240): 1-113.

[4] Fujii K, Nakamura T, Loem M, et al. Continual Pre-Training for Cross-Lingual LLM Adaptation: Enhancing Japanese Language Capabilities[J]. arXiv preprint arXiv:2404.17790, 2024.

[5] Zhang S, Fang Q, Zhang Z, et al. BayLing: Bridging Cross-lingual Alignment and Instruction Following through Interactive Translation for Large Language Models[J]. arXiv pre-print server, 2023.

[6] Lu K, Yang Y, Yang F, et al. Low-Resource Language Expansion and Translation Capacity Enhancement for LLM: A Study on the Uyghur[C]. Proceedings of the 31st International Conference on Computational Linguistics, 2025: 8360-8373.

[7] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in LLM via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.

[8] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.

[9] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model[J]. Advances in Neural Information Processing Systems, 2024, 36.

[10] Wang P, Xu A, Zhou Y, et al. Direct Judgement Preference Optimization[J]. arXiv preprint arXiv:2409.14664, 2024.

[11] Chen G, Liao M, Li C, et al. Step-level Value Preference Optimization for Mathematical Reasoning[J]. arXiv preprint arXiv:2406.10858, 2024.

[12] Xu H, Sharaf A, Chen Y, et al. Contrastive Preference Optimization: Pushing the Boundaries of LLM Performance in Machine Translation[C]. Forty-first International Conference on Machine Learning.

[13] He Z, Wang X, Jiao W, et al. Improving Machine Translation with Human Feedback: An Exploration of Quality Estimation as a Reward Model[C]. Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), 2024: 8157-8173.

[14] Costa-Juss à M R, Cross J, Çelebi O, et al. No language left behind: Scaling human-centered machine translation[J]. arXiv preprint arXiv:2207.04672, 2022.

[15] Mao Z, Yu Y. Tuning LLM with contrastive alignment instructions for machine translation in unseen, low-resource languages[J]. arXiv preprint arXiv:2401.05811, 2024.

[16] Zhang X, Rajabi N, Duh K, et al. Machine translation with large language models: Prompting, few-shot learning, and

fine-tuning with QLoRA[C]. Proceedings of the Eighth Conference on Machine Translation, 2023: 468-481.

[17] 侯钰涛, 阿布都克力木·阿布力孜, 史亚庆, et al. 面向"一带一路"的低资源语言机器翻译研究[J]. 计算机工程, 2024, 50(4): 332-341.
Hou Y, Abudukelimu A, Shi Y, Research on low-resource language machine translation for the "Belt an Road" [J]. Computer Engineering, 2024, 50(4): 332-341.

[18] Yin Y, Zeng J, Li Y, et al. LexMatcher: Dictionary-centric Data Collection for LLM-based Machine Translation[J]. arXiv preprint arXiv:2406.01441, 2024.

[19] Feng Z, Zhang Y, Li H, et al. Improving LLM-based machine translation with systematic self-correction[J]. arXiv preprint arXiv:2402.16379, 2024.

[20] Raunak V, Sharaf A, Wang Y, et al. Leveraging GPT-4 for Automatic Translation Post-Editing[C]. Findings of the Association for Computational Linguistics: EMNLP 2023, 2023: 12009-12024.

[21] 李博, 季佰军, 段湘煜. 基于译文易错词纠正机制的大语言模型机器翻译[J]. 计算机工程: 0.
Li B, Ji B, Duan X, Machine Translation with Large Language Models Based on the Correction Mechanism of the Translations Error-Prone Words [J]. Computer Engineering, 0.

[22] Ma Y J, Liang W, Wang G, et al. Eureka: Human-Level Reward Design via Coding Large Language Models[C]. 2nd Workshop on Language and Robot Learning: Language as Grounding, 2023.

[23] Wu Y, Fan Y, Liang P P, et al. Read and reap the rewards: Learning to play atari with the help of instruction manuals[J]. Advances in Neural Information Processing Systems, 2023, 36: 1009-1023.

[24] Zhou Z, Hu B, Zhao C, et al. Large language model as a policy teacher for training reinforcement learning agents[C]. Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence, 2024: 5671-5679.

[25] 罗焕坤, 葛一烽, 刘帅. 大语言模型在数学推理中的研究进展[J]. 计算机工程: 0.
Luo H, Ge Y, Liu S, Research Progress of Large Language Models in Mathematical Reasoning [J]. Computer Engineering, 0.

[26] Yang G, Chen J, Lin W, et al. Direct Preference Optimization for Neural Machine Translation with Minimum Bayes Risk Decoding[C]. Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 2: Short Papers), 2024: 391-398.

[27] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. Advances in neural information processing systems, 2022, 35: 27730-27744.

[28] Achiam J, Adler S, Agarwal S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.

[29] Xu H, Murray K, Koehn P, et al. X-alma: Plug & play modules and adaptive rejection for quality translation at scale[J]. arXiv preprint arXiv:2410.03115, 2024.

[30] Post M. A Call for Clarity in Reporting BLEU Scores[J]. WMT 2018, 2018: 186.

[31] Rei R, Stewart C, Farinha A C, et al. COMET: A Neural Framework for MT Evaluation[C], 2020: 2685-2702.

[32] Guerreiro N M, Rei R, Stigt D V, et al. xcomet: Transparent machine translation evaluation through fine-grained error detection[J]. Transactions of the Association for Computational Linguistics, 2024, 12: 979-995.

[33] Barrault L, Bojar O, Costa-Jussa M R, et al. Findings of the 2019 conference on machine translation (WMT19)[C], 2019.

[34] Federmann C, Kocmi T, Xin Y. NTREX-128–news test references for MT evaluation of 128 languages[C]. Proceedings of the first workshop on scaling up multilingual evaluation, 2022: 21-24.

[35] Üstün A, Aryabumi V, Yong Z, et al. Aya Model: An Instruction Finetuned Open-Access Multilingual Language Model[C]. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2024: 15894-15939.

[36] Xue L, Constant N, Roberts A, et al. mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer[C]. Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2021: 483-498.

[37] Lu Y, Zhu W, Li L, et al. LLaMAX: Scaling Linguistic Horizons of LLM by Enhancing Translation Capabilities Beyond 100 Languages[C]. Findings of the Association for Computational Linguistics: EMNLP 2024, 2024: 10748-10772.

[38] Touvron H, Martin L, Stone K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.

[39] Dubey A, Jauhri A, Pandey A, et al. The llama 3 herd of models[J]. arXiv preprint arXiv:2407.21783, 2024.

[40] Rei R, De Souza J G, Alves D, et al. COMET-22: Unbabel-IST 2022 submission for the metrics shared task[C]. Proceedings of the Seventh Conference on Machine Translation (WMT), 2022: 578-585.