利用大纲，输出一篇简要的报告，参考文献见后文

报告完整大纲与写作指南

题目建议

《数理逼近与语言尊严的博弈：万能逼近定理视域下的大模型翻译重构》

引言：当数理还原论撞上人类语言（约 300 字）

作为人工智能技术的底层基石，“万能逼近定理”代表了理工科试图将复杂世界彻底“函数化”与“公式化”的最高理想。而语言作为人类文明最具不确定性与温情思想的载体，天然地抗拒着这种冰冷的量化。本报告将前八讲的底层核心定理作为理论镜鉴，去审视后八讲中大模型机器翻译的应用，探讨现代 AI 翻译的新模式究竟在多大程度上逼近了人类的真实思维，又给人类的文化主体性带来了怎样的冲击。

第一部分：用人文语言解构“万能逼近定理”（约 500 字）

在深度学习的世界里，世间万物的因果转换都可以被看作是一个极其曲折的高维函数。万能逼近定理的核心结论用大白话来说就是：只要给神经网络塞入足够多的神经元，配合上非线性激活函数，它理论上就能像搭马赛克瓷砖一样，在数字世界里严丝合缝地拼出任何一条复杂的规律曲线。

从早期的循环神经网络（RNN）到如今大火的 Transformer 架构，技术的演进本质上并不是语言学的胜利，而是人类在有限的算力资源下，为了以更高的精度和效率去逼近、去模仿长文本中绵延不绝的文化语境而做出的工具改良。

第二部分：高维语义空间的桥接与大模型翻译实践的一站化重构（约 500 字）

（本段深度融合胡健老师的前沿研究） 大模型时代的机器翻译彻底颠覆了传统的工匠式翻译流程。在提示词工程的催化下，大模型这个“万能逼近器”展现出了强大的工作流整合能力。它打破了传统翻译中词性标注、句法对齐等线性步骤，将原本割裂的原文术语提取、初译输出、译后编辑以及风格校对，极速压缩并坍缩为一个“一站式”的生成式流，呈现出鲜明的“翻译过程一站化”与“翻译模式提示化”特征。

但从人文科学的角度看，这种极致的效率逼近也带来了译者主体性的深刻危机。译者从传统上面对文本进行创造性转换的“桥梁筑造者”，被降维异化为了多模态协同网络中的“提示词调校师”。这种黑盒式的坍缩，实际上正在剥夺人类在翻译中反复推敲、容纳语言不确定性的主体性空间。

第三部分：通用语义中间层的神话与局部偏好优化的文化微雕（约 500 字）

（本段深度融合马潇老师与鲁凯文老师的前沿成果） 多语言大模型在进行全局万能逼近时，产生了一个令人惊叹的技术神话：为了在数字空间里找到最简且最具有普适性的函数解释，模型在内部强行拟合出了一个不依赖于任何特定人类语种的“通用语义中间层”。这种零样本跨语言迁移翻译能力，就像是在数字空间里重构了圣经中的“巴别塔”——AI 试图绕过人类纷繁复杂的具体语言，去逼近一种纯粹的、跨越文化鸿沟的“共有语义”。

然而，这种宏观的数学逼近在面对微观、具体的民族文化特有词汇时，引发了严重的平庸化排异反应。由于传统的直接偏好优化（DPO）等对齐手段过度追求全局奖励的最大化，导致模型在面对形态复杂、承载着独特历史记忆的低频专业短语时，极其容易发生机械性误译或文化消减。为了修正这种技术傲慢，科研界被迫引入了“局部偏好优化（LPO）”路径，在 Token 级别引入精细的损失函数来修正低频词汇的输出偏好。这在人文视角下，不再是一个冷冰冰的技术调优补丁，而更像是人类理性的温情在庞大的算法框架上，为那些拒绝被技术标准吞噬的局部语言尊严，小心翼翼地雕刻出的一块文化自留地。

结语：确定性数学向语言多样性的终极致敬（约 200 字）

总的来说，万能逼近定理展现了数学模型拟合复杂规律的强大能力。当它被引入机器翻译，虽然通过提示词工程精简了传统流程、提升了效率，但也对译者的主体性造成了不小的冲击。然而，大模型在处理带有独特文化背景的低频专业词汇时所面临的平庸化困境，以及技术上为了解决这一问题而做出的局部偏好优化，恰恰说明了语言背后的文化多样性很难被简单的统计概率彻底抹平。未来的智能翻译不该只是盲目追求效率，更需要人文视角的介入与微调，在技术确定性与人类文化主体性之间找到真正的平衡。



计算机工程
Computer Engineering
ISSN 1000-3428,CN 31-1289/TP

《计算机工程》网络首发论文

题目：基于局部偏好优化的大模型机器翻译方法研究
作者：鲁凯文，杨雅婷，董瑞，马博，王磊，周喜，马荣
DOI：10.19678/j.issn.1000-3428.0252213
网络首发日期：2025-09-22
引用格式：鲁凯文，杨雅婷，董瑞，马博，王磊，周喜，马荣．基于局部偏好优化的大模型机器翻译方法研究[J/OL]．计算机工程.
https://doi.org/10.19678/j.issn.1000-3428.0252213



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2025-09-22 16:49:22　网络首发地址：https://link.cnki.net/urlid/31.1289.tp.20250919.1909.004

计 算 机 工 程
Computer Engineering

基于局部偏好优化的大模型机器翻译方法研究

鲁凯文[1,2,3]，杨雅婷[1,2,3*]，董瑞[1,2,3]，马博[1,2,3]，王磊[1,2,3]，周喜[1,2,3]，马荣[1,2,3]

（1.中国科学院新疆理化技术研究所，乌鲁木齐 830011；
2.中国科学院大学，北京 100049；
3.新疆民族语音语言信息处理实验室，乌鲁木齐 830011）

摘　要：基于直接偏好优化的强化学习方法在大模型诸多下游任务中展现了良好的效果，然而该方法直接应用在机器翻译中常常会因为全局奖励最大化策略而会产生过度优化问题，具体表现为模型过度关注与参考译文的分布一致性，而丧失了局部翻译多样性和全局优化的潜力。为了解决上述问题，探究了直接偏好优化方法在大模型机器翻译中表现劣化的根本原因，在此基础上提出了一种基于局部偏好优化的大模型机器翻译方法。该方法通过对大模型的动态温度采样和无参考评估找出翻译中的易错低频短语，然后提出了一种结合全局差异和局部关键差异的偏好数据构造方法，在综合考虑模型全局翻译效果和局部多样性的前提下提出了 token 级的全局损失和局部损失函数，最后利用两阶段课程学习的策略逐步调整模型对低频短语的输出偏好。提出的方法在 FLORES-200 数据集上进行验证，选取了十四种形态复杂的多语言翻译任务进行测试，实验结果表明，所提方法在 XCOMET、COMET-22 和 BLEU 的得分结果分别为 80.7、89.9 和 30.2。通过与多个多语言机器翻译强基线进行对比，所提方法在所有翻译语向上均优于基线模型，验证了方法的有效性。

关键词：机器翻译；大语言模型；多语言；强化学习；直接偏好优化
中图分类号：TP391　　**文献标志码：**A　　**DOI：**DOI:10.19678/j.issn.1000-3428.0252213

Research on large language model machine translation method based on local preference optimization

LU Kaiwen[1,2,3], YANG Yating[1,2,3*], DONG Rui[1,2,3], MA Bo[1,2,3], WANG Lei[1,2,3], ZHOU Xi[1,2,3], MA Rong[1,2,3]

(1. Xinjiang Technical Institute of Physics and Chemistry, Chinese Academy of Sciences, Urumqi 830011, China;
2. University of Chinese Academy of Sciences, Beijing 100049, China;
3. Xinjiang Laboratory of Minority Speech and Language Information Processing，Urumqi 830011, China)

【Abstract】Reinforcement learning methods based on direct preference optimization have shown excellent results in many downstream tasks of large language models. However, when applied directly to machine translation, this approach often leads to over-optimization problems due to the global reward maximization strategy. Specifically, it causes the model to overly focus on consistency with the distribution of reference translations, thereby losing the potential for local translation diversity and global optimization. To address the aforementioned issues, the problem of performance degradation of direct preference optimization methods in large language model machine translation was investigated. Based on this, a large language model machine translation method based on local preference optimization was proposed. This method identifies frequently mistranslated low-frequency phrases in translations through dynamic temperature sampling and reference-free evaluation of the large language model. Furthermore, a preference data construction method that combines global differences and local key differences is introduced. Considering both the overall translation quality of the model and the local translation diversity, global loss and local loss functions at the token level are proposed. Finally, a two-phase curriculum learning strategy is employed to gradually adjust the model's output preference for low-frequency phrases. The proposed method was validated on the FLORES-200 dataset, selecting fourteen multilingual translation tasks with complex morphologies for testing. The experimental results showed that the scores of the proposed method on XCOMET, COMET-22, and BLEU were 80.7, 89.9, and 30.2, respectively. By comparing with several strong baselines in multilingual machine translation, the proposed method outperformed the baseline models across all translation directions, confirming the effectiveness of the method.

【Key words】machine translation; large language model; multilingual; reinforcement learning; direct preference optimization

0　引言

大语言模型（Large Language Model，LLM）的出现给自然语言处理（Natural Language Processing，NLP）领域带来了一种新的范式[1-3]。当前 LLM 的训练工作主要集中于预训练阶段[4]、监督微调阶段

基金项目：新疆维吾尔自治区天山英才(2022TSYCCX0059)，新疆维吾尔自治区自然科学基金（2022D01D04），新疆维吾尔自治区天山英才（2023TSYCCX0041，2023TSYCCX0044，2022TSYCLJ0046），中国科学院青年创新促进会（Y2021112，Y2023118，2021436），新疆维吾尔自治区上合组织科技伙伴计划及国际科技合作计划项目（2023E01019），国家自然科学基金（62406317）。

通信作者 E-mail：yangyt@ms.xjb.ac.cn

[5]、强化学习阶段[6]，其中强化学习方法侧重于对齐 LLM 和人类的行为偏好，该方法更是被诸如 Deepseek[7]等具有代表性的 LLM 着重使用。现有 LLM 强化学习方法主要基于近端策略优化方法[8]（Proximal Policy Optimization，PPO）和直接偏好优化方法[9]（Direct Preference Optimization，DPO），其中 DPO 可以使用简单的二元交叉熵目标来优化策略,从而生成符合偏好数据的隐式奖励函数的最优策略，相比 PPO 来说 DPO 更加容易实现并且消耗的计算资源更少，因而受更多轻量级方法和模型的青睐。

尽管 DPO 在 NLP 的诸多下游任务中展现了良好的表现[10,11]，但与这些期望相悖的是，如果在翻译任务上将一个经过翻译监督微调（Supervised Fine-Tun-ing，SFT）的 LLM 直接在翻译偏好语料上进行 DPO，所得到的模型相较其他任务的 DPO 来说效果会远低于期望，甚至会出现比 SFT 模型效果更差的情况，这也被看做是 DPO 在翻译任务上的劣化问题。Xu 等人[12]将此问题归结于 DPO 的标准参考答案已经不如模型生成的翻译结果，从而使得标准的 DPO 数据构造方法无法为已经足够强大的 LLM 翻译系统带来正面提升。类似的，He 等人[13]认为现有方法对基于人类反馈构建的翻译强化学习数据建模不足，导致数据带来的翻译偏好监督信号弱，并且这种人类翻译偏好可以直接被机器翻译质量评估方法（Quality Estimation, QE）近似取代。

为了缓解强化学习方法在机器翻译任务上带来的负优化问题，本文系统地探究了强化学习在机器翻译任务上劣化的问题来源，并在此基础上对模型进行多次独立采样生成局部最优候选短语，之后应用局部偏好优化方法来增强模型对局部最优翻译的偏好以缓解 DPO 造成的全局劣化问题的产生。本文提出的局部偏好优化方法（Local Preference Optimization, LPO）在 FLORES-200[14]数据集上选取的二十八个具有挑战性的翻译方向上均取得了提升。通过与基线和其他具有代表性的 LLM 对比可知，本文提出的方法可以在保证全局翻译质量的前提下有效提升 LLM 的局部翻译效果并能很好的缓解强化学习带来的劣化问题。

1 相关工作

1.1 大模型机器翻译

随着 LLM 的出现，其非凡的语义理解能力和生成类人文本的强大能力改变了 NLP 诸多下游任务的范式，也促使神经机器翻译的研究开始从传统的 Transformer 类方法转向基于 LLM 的翻译方法上。

Mao 等人[15]通过构建翻译指令和跨语言对齐指令来提高 LLM 在零样本翻译中的性能。Zhang 等人[16]比较了三种 LLM 翻译方法的性能，分别是零样本提示方法、少样本学习方法和翻译微调方法微调，并在句子级和文档级的翻译任务上量化对比了这些方法。Zhang 等人通过使用交互式翻译任务数据对 LLM 进行 SFT，将语言生成和对话跟踪能力从英语转移到其他语言，并开发了一个名为 BayLing 的翻译 LLM。侯钰涛等人[17]提出了一种基于 NLLB 模型的低资源语言机器翻译训练方法，通过数据增强和损失函数的优化有效提升了模型在越南语和老挝语翻译任务中的表现。Yin 等人[18]提出了一种简单而有效的数据收集方法，即使用双语字典来生成数据集。在对收集到的数据进行微调后，LLM 在涉及专门的术语翻译的任务中显示出了显著的性能改进。Feng 等人[19]提出了一个名为 TEaR 的 LLM 自我细化框架，它包含了翻译生成、翻译评估、迭代细化三个过程，提高了 LLM 在高低资源和英语与非英语间的翻译质量。Raunakd 等人[20]利用思维链的方式将 GPT4 作为译后编辑模型以改进翻译的输出结果。李博等人[21]提出了一种针对 LLM 的译文易错词纠正机制，利用大模型和小模型结合的方式有效纠正了 LLM 机器翻译过程中产生的易错词。

1.2 大模型强化学习应用

强化学习通过优化决策过程、对齐人类偏好来提升 LLM 的可控性和一致性。Ma 等人[22]提出了一种名为 EUREKA 的方法，该方法利用最先进的 LLM 的代码生成能力和上下文改进能力，对强化学习的奖励进行进化优化，由此产生的奖励可以使得模型通过强化学习获得执行复杂任务的技能。Wu 等人[23]利用书面指导手册来帮助提高针对特定任务的策略学习能力，提出了阅读和奖励框架以此训练了一个更高效和表现更好的智能体。Zhou 等人[24]提出了一个新的框架，即通过使用来自基于 LLM 的教师智能体的指令来培训一个更小的、专业的学生强化学习

智能体，该智能体可以将 LLM 的先验知识提取到它自己的模型中，因此学生智能体可以用更少的数据进行训练，通过进一步的环境反馈培训，学生智能体在任务上的表现超越了其教师智能体。罗焕坤等人[25]总结了包括强化学习在内的 LLM 在数学推理中的进展。

现有大模型机器翻译方法大多聚焦于利用 SFT 对 LLM 进行微调或者对 LLM 输入和输出进行改进，而现有的强化学习研究也仍然缺乏对翻译任务劣化原因的探索和针对性调整。

2 基于局部偏好优化的大模型训练方法

为缓解强化学习在 LLM 机器翻译任务上的劣化问题和提升 LLM 机器翻译的表现，本章首先分析了 LLM 机器翻译的偏好，揭示了强化学习在该任务上劣化的具体原因，其次通过多样化的翻译偏好数据构造和“全局+局部”的偏好损失设计，有效提高了强化学习在 LLM 翻译任务上的表现。

2.1 大模型翻译偏好分析

虽然 LLM 可以通过广泛的无监督学习获得流利地输出语言的能力，但由于其训练的完全无监督性质，精确控制其行为的挑战仍然存在。为了解决这个问题，通常使用基于人类反馈的强化学习对其进行偏好对齐。然而，这个过程是复杂且不稳定的。为了简化这个过程，Rafailovd 等人提出了 DPO 方法，损失函数如下所示：

$$L_{\mathrm{DPO}}(\pi_\theta;\pi_{\mathrm{ref}})=-\mathbb{E}_{\sim\mathcal{D}}\left[\log\sigma\left(\beta\left(\log\frac{\pi_\theta(y_w\mid x)}{\pi_{\mathrm{ref}}(y_w\mid x)}-\log\frac{\pi_\theta(y_l\mid x)}{\pi_{\mathrm{ref}}(y_l\mid x)}\right)\right)\right]，(1)$$

其中π_θ是当前模型的状态，θ代表当前的具体参数，π_{ref}是一个理想状态下的模型分布，也是当前模型的最终目标，$\mathcal{D}$为 DPO 数据集，一般包括的样本形式为（x，y_w，y_l），代表了一个输入x和一个理想的、更加正确的文本y_w以及一个相较更劣质的文本y_l，σ是 sigmoid 的函数，用于将输入映射到[0,1]，β是一个超参数，用于控制不合理文本相对于合理文本的权重。整个损失函数的意图为，通过训练使模型更倾向于选择y_w作为输出而拒绝以y_l作为输出，以此来控制模型的输出偏好。

这种任务形式在大多数开放式的生成任务上展现出了显著的优势，但在机器翻译这一特殊场景下却面临着特殊的挑战。相较于多数生成任务仅需保持主题连贯性，机器翻译存在严格的输入-输出映射约束，即输出和输入的相关性远高于其他生成式任务。其次，翻译还具有一定的灵活发挥空间，最好的翻译往往不是严格按照源句逐字进行翻译的。与之矛盾的是 DPO 的标准训练策略会使模型过度关注与参考译文的全局分布一致性而抑制局部翻译的多样性和模型进一步提升的潜力。

具体地，对于机器翻译中的 DPO 数据构建范式来说，DPO 数据的构造往往依赖于人类译员给予的参考译文和模型生成的译文来组成偏好数据[26]。这种数据构造机制在基础模型训练阶段具有指导意义，但随着 LLM 翻译能力的突破性进展，其内在缺陷逐渐显现：（1）偏好优化数据来源相对单一，这意味着模型往往要朝着一个固定的y_w（参考译文）来进行偏好的对齐，这也抑制了模型输出的多样性；（2）根据现有的研究，一些优秀的翻译 LLM 已经可以在部分语言上输出优于大多人类译员的翻译结果，例如 InstructGPT[27]、GPT4[28]、X-ALMA[29]等，这标志着对于优秀的翻译 LLM 来说，人类译员的翻译结果已经不再是唯一标准的黄金参考了，相应的，传统的 SacreBLEU[30]和 COMET[31]等有参考的翻译评价指标已经不适合作为此类场景的绝对量化指标了。

为了将这种困境形式化出来，本文利用一个强大的多语言机器翻译大模型 X-ALMA-13B 作为基础模型，将翻译语向设置为中文到英文，之后对其进行一百次的非连续独立采样，最后对所有结果利用无参考翻译评价指标 XCOMET[32]计算得分。得到的结果统计分类如图 1 所示，经过去重计数统计所有输出共可分为十一类，之后将十一种译文按语序拆分合并，将这种输出流看做源语言约束下的 LLM 输出偏好分布并以此绘出桑基图，不同输出的 XCOMET 得分置于最后一列。

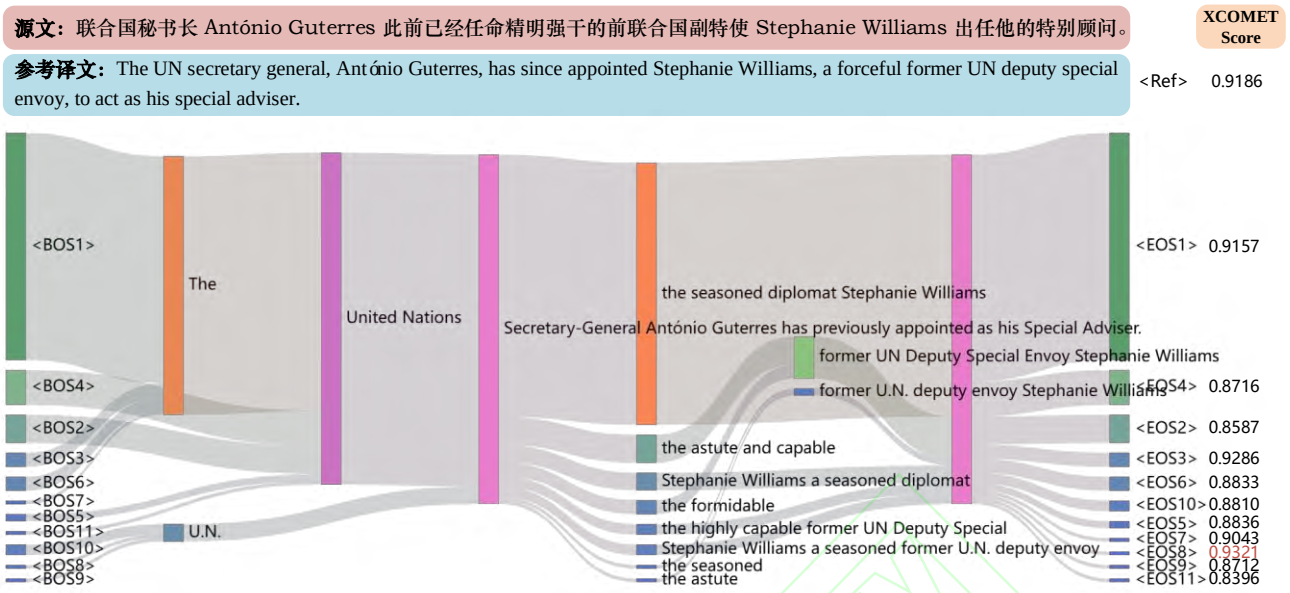


图 1　LLM 翻译偏好流向

Fig.1　Large language model translation preference flow

通过对图 1 的分析可以发现，在一些高频翻译短语（例如“联合国”）上，模型展现出了高度的确定性并且不会有太大的分歧，但在一些低频的短语（例如“精明强干”）上，模型的输出就变得不确定并且多样化。对其的定量分析更凸显传统参考标准的局限性，根据 XCOMET 分数可以看出，最高频的输出（<BOS1>）的分数仅在所有输出中排名第三位，这种"高频低质"现象表明模型在解码时更倾向于选择训练数据中统计显著的表达方式，而非语义层面的最优解。进一步观察可以发现，甚至参考译文<Ref>的分数都低于两个 LLM 的低频输出。这种现象证明参考译文已经不再对 LLM 有着绝对正确的指导了，并且 LLM 有潜力在一些低频短语上产生更加良好的表现。

2.2 翻译局部偏好优化方法

为了找出翻译中低频且正确的短语和提高模型对这些短语的输出偏好，本文提出了“先发现、后训练”的两阶段训练方法，整体结构如图 2 所示。

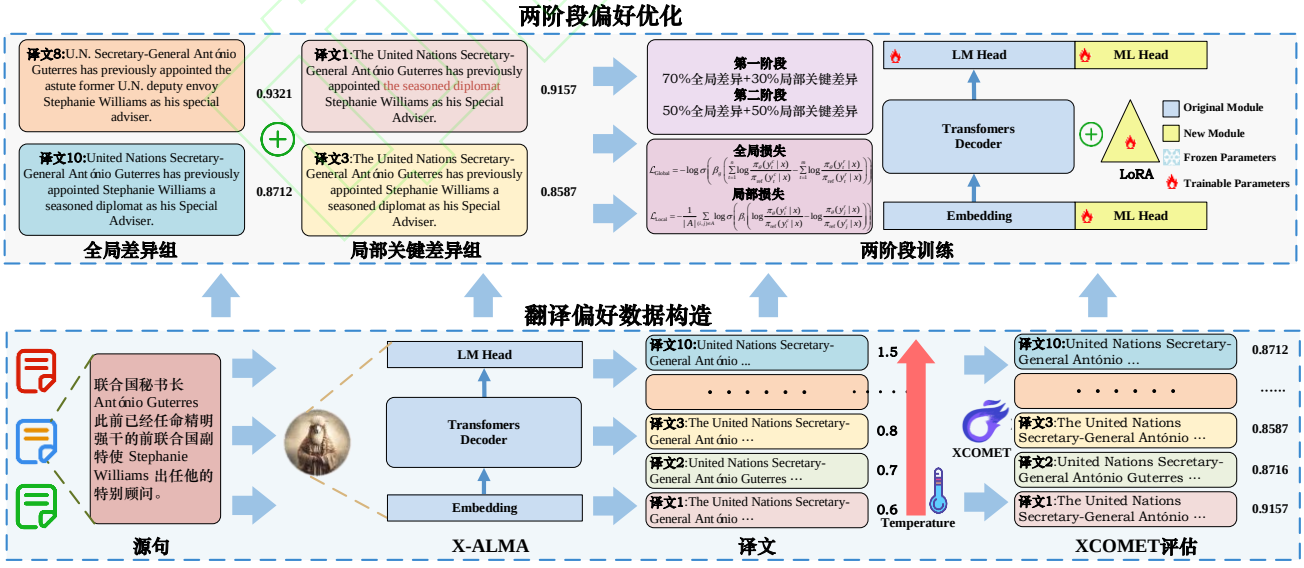


图 2　局部偏好优化方法

Fig.2　Local preference optimization method

第一阶段以提升低频输出概率构造偏好数据为主要任务，第二阶段通过“全局+局部”的两阶段多粒度优化模型的偏好。本节将从翻译偏好数据构造和两阶段多粒度局部偏好优化两方面对本文所提出的局部偏好优化方法（Local Preference Optimization，LPO）进行阐述。

2.2.1 翻译偏好数据构造

为了尽可能激发模型潜在的低频翻译能力，本文提出了一种动态温度采样策略，采用X-ALMA-13B作为基础生成模型，设计线性温度调度机制控制生成多样性。具体地，对每个源句执行10轮独立采样，温度参数τ按$\tau_k = 0.5 + 0.1\mathrm{k}(\mathrm{k} \in 1,\ldots,9)$，即从0.6递增至1.5。低温阶段（$\tau < 1.0$）通过锐化概率分布生成保守翻译，保证核心语义准确性；高温阶段（$\tau \geq 1.0$）则扩大采样空间，探索潜在合理表达。每轮采样生成10个候选翻译，覆盖从偏向直译到偏向意译的连续性表达谱系，并用XCOMET作为评估标准对所有候选翻译进行打分，以待后续训练使用。

2.2.2 局部偏好优化

为了优化LLM对低频且正确的短语偏好，本文提出了层次差异化数据分组和基于课程学习的两阶段偏好优化训练策略。

层次差异化数据分组方面，本文基于XCOMET评估分数和编辑距离从10组候选翻译中，构建双层对比样本集以适配翻译任务的细粒度优化需求进行筛选。在全局差异组层面，筛选出候选组中XCOMET分数差异最大的两个样本，该组样本呈现整体翻译质量的显著差异，主要反映宏观层面的改进空间。在局部关键差异层面，首先两两计算样本间的最小编辑距离$d_{Levenshtein}$，考虑到语种之间的字符数量的差异性，故在所有计算结果中，选取$d_{Levenshtein}$大于0且数值最低的30%的候选组，在其中选择XCOMET差异最大的那一个样本组，该组样本呈现出局部翻译质量的显著差异，主要反映局部层面的改进空间。

偏好优化方面，本文设计了一种两阶训练方法，整体损失函数$\mathcal{L}_{\mathrm{LPO}}$如下所示：

$$\mathcal{L}_{\mathrm{LPO}} = \alpha\mathcal{L}_{\mathrm{Global}} + (1-\alpha)\mathcal{L}_{\mathrm{Local}}, \quad (2)$$

其中$\mathcal{L}_{\mathrm{Global}}$为全局损失，$\mathcal{L}_{\mathrm{Local}}$为局部损失，$\alpha$在第一阶段为0.7，在第二阶段设置为0.5。全局损失函数$\mathcal{L}_{\mathrm{Global}}$具体如下所示：

$$\mathcal{L}_{\mathrm{Global}} = -\log\sigma\left(\beta\left(\sum_{t=1}^{n}\log\frac{\pi_\theta(y_t^w \mid x)}{\pi_{\mathrm{ref}}(y_t^w \mid x)} - \sum_{t=1}^{m}\log\frac{\pi_\theta(y_t^l \mid x)}{\pi_{\mathrm{ref}}(y_t^l \mid x)}\right)\right), \quad (3)$$

为了后续局部损失的表示便利，本文将式(3)从式(1)的句子级整体表示修改为token级累计的形式，n表示DPO数据中“Chosen”的长度，m表示DPO数据中“Rejected”的长度。局部损失$\mathcal{L}_{\mathrm{Local}}$定义如下：

$$\mathcal{L}_{\mathrm{Local}} = -\frac{1}{|A|}\sum_{(i,j)\in A}\log\sigma\left(\beta\left(\log\frac{\pi_\theta(y_i^w \mid x)}{\pi_{\mathrm{ref}}(y_i^w \mid x)} - \log\frac{\pi_\theta(y_j^l \mid x)}{\pi_{\mathrm{ref}}(y_j^l \mid x)}\right)\right), \quad (4)$$

其中$A(y^w, y^l)$代表y^w和y^l的差异区域的集合，(i,j)则分别代表y^w和y^l中具体的差异位置，且规定

$$y_i^w \neq y_j^l, \quad (5)$$

式(4)即可表示为，“Chosen”和“Rejected”中关键差异区域的损失。在两阶段训练的数据采样方面，和α类似的是，第一阶段分别采样70%的全局差异组和30%的关键差异组，第二阶段采样50%的全局差异组和50%的关键差异组，通过课程学习的方式让模型在不丢失全局输出偏好的前提下渐进地改进模型对于低频短语的准确率。

3 实验设置

3.1 数据集

为了全面评估本文提出的方法在多语言复杂场景下的泛化能力和鲁棒性，本实验选择了包含50种语言的X-ALMA-Preference数据集，并将该数据集的源句作为本文偏好数据构造的输入来源，该数据集主要来源于两个权威多语言评估基准：Flores-200的验证集和NTREX[33,34]的测试集。并按照X-ALMA的设置，同样选择了两种不同的翻译场景，第一组是如表1所示的六种书写系统差异较大的语言组，该组包括六种形态复杂的不同语言，分别是中文、爱沙尼亚语、芬兰语、格鲁吉亚语、日语、韩语，且这些语言在LLM预训练阶段所使用的资源数量级差距较大，能够很好的展示本文方法在形态复杂场景下的健壮性。第二组是如表2所示的八种相似语言，分别是阿拉伯语、阿塞拜疆语、希伯来语、哈萨克语、吉尔吉斯语、波斯语、土耳其语、乌兹

别克语，这些语言在训练阶段使用的数据规模相对较少，可以用来衡量本实验方法在低资源相似语言翻译场景的表现。实验采用 Flores-200 的标准测试集进行最终评估，重点考察实验语言与英语之间的双向互译任务。

表 1 书写系统差异组数据分布情况

Table 1 Data distribution of script difference group

语言	ISO 代码	书写系统	语族	子群	训练集大小		测试集规模	
					en→xx	xx→en	en→xx	xx→en
中文	zh	汉字	汉藏语系	汉语族	15628	14927	1012	1012
爱沙尼亚语	et	拉丁字母	乌拉尔语系	芬兰语支	11110	10982	1012	1012
芬兰语	fi	拉丁字母	乌拉尔语系	芬兰语支	15114	15626	1012	1012
格鲁吉亚语	ka	格鲁吉亚字母	南高加索语系	格鲁吉亚-赞语支	2994	2993	1012	1012
日语	ja	日文	日本语系	日语支	15460	15672	1012	1012
韩语	ko	谚文（韩字）	朝鲜语系	朝鲜语支	7292	7343	1012	1012

表 2 中亚语言组数据分布情况

Table 2 Data distribution of Central Asia language group

语言	ISO 代码	书写系统	语族	子群	训练集大小		测试集规模	
					en→xx	xx→en	en→xx	xx→en
阿拉伯语	ar	阿拉伯字母	亚非语系	中闪米特语支	7185	7137	1012	1012
阿塞拜疆语	az	拉丁字母	突厥语族	乌古斯语支	2994	2994	1012	1012
希伯来语	he	希伯来字母	亚非语系	西北闪米特语支	6677	7126	1012	1012
哈萨克语	kk	西里尔字母	突厥语族	钦察语支	4992	4991	1012	1012
吉尔吉斯语	ky	西里尔字母	突厥语族	钦察语支	2994	2994	1012	1012
波斯语	fa	波斯字母	印欧语系	伊朗语支	7488	7115	1012	1012
土耳其语	tr	拉丁字母	突厥语族	乌古斯语支	13000	13310	1012	1012
乌兹别克语	uz	拉丁字母	突厥语族	葛逻禄语支	2994	2994	1012	1012

3.2 基线设置

为了测试本文所提出的 LPO 方法，选取了五个强大的开源多语言 LLM 作为基线，包括：

（1）NLLB-200：是一种利用跨语言迁移学习的单一大规模多语言机器翻译模型，NLLB 开发了一个基于稀疏门控混合专家架构的条件计算模型，使用针对资源匮乏语言定制的新挖掘技术获得的 200 种语言数据进行训练。

（2）Aya-101[35]：是一种采用了与 MT5-xxl[36]相同的架构多语言翻译 LLM，该模型收集了 101 种语言的翻译数据并用多种数据增强策略对数据进行扩充，之后对模型进行了多语言微调。

（3）LLaMAX3-Alpaca[37]：是一个基于 LLaMA2[38]的多语言翻译 LLM，其在 LLaM2 的基础上通过词汇拓展和数据增强等策略全面增强了其在翻译任务上的表现。

（4）LLaMA-3.1-8B-Instruct[39]：是目前最强大的通用开源模型之一，LLaMA-3.1 采用了多轮迭代的训练方式，在常识、可控性、数学、工具使用和多语言翻译方面都具有极好的表现。

（5）X-ALMA-13B：是一个强大的多语言翻译 LLM，也是本文方法的基线模型。其在 ALMA-13B-R 的基础上拓展了 50 种语言，并利用类似于专家混合模型（Mixture of Experts, MOE）的方式避免了多语言带来的灾难性遗忘的问题。

3.3 评估指标

在本文中，翻译效果评估主要依据无参考评估方法 XCOMET，此外本文还引入了传统的有参考翻译质量评估指标 SacreBLEU 和 COMET-22[40]作为辅助参考。

3.4 实验设置

本文的方法以一个强大的多语言机器翻译大模

型 X-ALMA-13B 作为基础模型。实验环境设置为 Ubuntu 22.04.5，共计使用 12 块 GPU，型号为 NVIDIA Tesla A100，单卡显存为 80GB。参数设置为精度为 bf16，β设置为 0.1，学习率设置为 1e-4，句子最大长度为 512，Batch size 设置为 2，训练使用 DeepSpeed Zero3 进行加速。

3.5 提示设置

为了在保持模型的基础能力，本文沿用了 X-ALMA 的提示模板，如图 3 所示，其中<source language name>和<target language name>分别代表源语言和目标语言的英文全称，<source language sentence>代表输入的待翻译源句。

```
<s>[INST] Translate this from <source language name> into
<target language name> :
<source language name> : <source language sentence>
<target language name> : [/INST]
```

图 3 提示模版示例

Fig.3 Example of a prompt template

4 实验结果及分析

4.1 对比实验

本实验对比分析了 NLLB-200、Aya-101、LLaMAX3-Alpaca、LLaMA-3.1-8B-Instruct、X-ALMA-13B 以及本文使用的局部偏好优化方法 X-ALMA-LPO 在 FLORES-200 数据集上选取的两组不同翻译场景下的翻译能力。结果分别如表 3 和图 4 所示。

表 3 书写系统差异组对比实验

Table 3 Comparative experiment of script difference group

Models	en→et			en→fi			en→ja			en→ka		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
Llama-3.1*	9.3	66.3	48.1	16.0	82.0	70.4	10.8	66.0	25.0	7.0	73.1	48.1
NLLB-3.3B*	25.0	90.5	79.7	24.1	91.7	81.1	22.6	87.9	75.1	14.8	84.6	70.2
LLaMAX2-Alpaca-7B*	19.0	88.4	76.1	18.4	90.2	79.6	28.1	88.9	78.1	10.7	83.0	68.2
LLaMAX3-Alpaca-8B*	18.1	87.7	75.1	17.5	89.3	77.6	27.5	89.0	77.3	9.6	78.6	55.9
Aya-101*	21.9	90.7	81.3	18.9	90.3	78.9	27.3	89.0	77.4	11.3	85.3	72.1
X-ALMA*	27.9	92.2	84.0	26.4	92.9	85.2	36.6	91.7	81.9	15.2	88.5	76.9
X-ALMA-LPO (ours)	**28.0**	**92.4**	**84.8**	**26.6**	**93.1**	**85.9**	**36.6**	**91.9**	**82.7**	**15.5**	**88.7**	**77.7**

Models	en→ko			en→zh			Avg.en→xx		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
Llama-3.1*	6.8	71.5	41.7	14.0	67.7	37.6	10.6	71.1	45.1
NLLB-3.3B*	12.5	88.4	79.1	32.4	82.0	64.1	21.9	87.5	74.9
LLaMAX2-Alpaca-7B*	10.3	86.8	76.7	35.2	85.5	74.0	20.3	87.1	75.4
LLaMAX3-Alpaca-8B*	8.8	85.6	74.0	36.3	85.6	73.3	19.6	86.0	72.2
Aya-101*	10.2	87.4	77.2	27.3	82.4	64.7	19.5	87.5	75.3
X-ALMA*	15.8	89.9	81.6	44.9	88.7	78.4	27.8	90.6	81.3
X-ALMA-LPO (Ours)	**16.1**	**90.2**	**82.6**	**45.0**	**88.9**	**79.3**	**28.0**	**90.9**	**82.2**

Models	et→en			fi→en			ja→en			ka→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
Llama-3.1*	4.1	45.9	51.6	5.8	53.3	52.8	17.7	69.4	67.6	0.3	39.2	34.3
NLLB-3.3B*	7.2	62.5	29.9	10.2	67.7	39.2	17.2	79.5	61.0	25.6	84.8	70.3

LLaMAX2-Alpaca-7B*	32.1	87.4	80.7	31.7	89.0	78.9	23.4	87.1	76.4	18.1	76.7	66.8
LLaMAX3-Alpaca-8B*	33.6	88.3	82.2	31.6	89.3	79.4	24.6	87.5	76.9	1.2	50.7	51.5
Aya-101*	32.5	87.7	80.2	29.7	88.6	77.8	23.5	86.5	75.5	25.6	84.5	69.7
X-ALMA*	38.8	89.6	83.5	36.2	90.5	80.4	28.8	88.5	77.7	29.3	87.1	72.8
X-ALMA-LPO (Ours)	**38.8**	**89.7**	**84.2**	**36.3**	**90.5**	**80.9**	**29.0**	**88.6**	**78.4**	**29.5**	**87.4**	**73.6**

Models	ko→en			zh→en			Avg.xx→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
Llama-3.1*	15.9	66.0	62.4	24.2	78.8	69.9	11.3	58.8	56.4
NLLB-3.3B*	26.2	84.9	73.1	16.8	77.1	52.8	17.2	76.1	54.4
LLaMAX2-Alpaca-7B*	25.2	86.6	76.4	25.8	86.5	77.2	26.1	85.5	76.1
LLaMAX3-Alpaca-8B*	26.3	87.5	77.1	25.9	86.6	77.3	23.9	81.7	74.1
Aya-101*	26.5	87.0	76.9	23.1	84.5	71.8	26.8	86.5	75.3
X-ALMA*	30.8	88.7	78.1	29.6	87.6	78.1	32.2	88.7	78.4
X-ALMA-LPO (Ours)	**30.9**	**88.7**	**78.9**	**29.7**	**87.8**	**78.7**	**32.4**	**88.8**	**79.1**

注：粗体代表在该翻译方向上的最高分，带有*的模型结果来自 X-ALMA，表中 en→et 表示从 en 翻译到 et，以此类推。

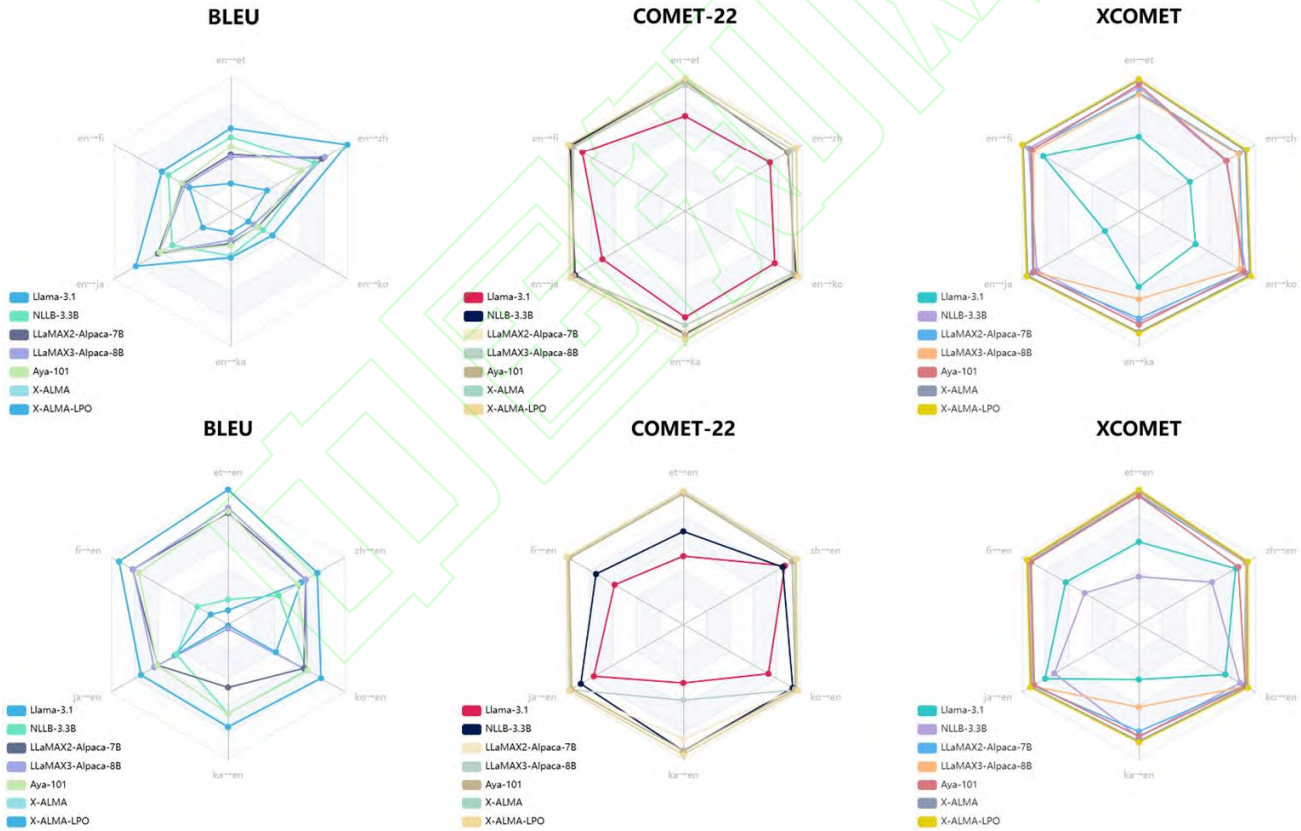


图 4　中亚语言组对比实验

Fig.4　Comparative experiment of Central Asia language group

本文所提出的LPO方法在所有翻译语向上均获得了显著的提升，特别是在 en→xx 的所有翻译方向上，这一现象与当前 LLM 的预训练数据分布特性及多语言能力的不均衡性密切相关。具体而言在于在模型的预训练和监督微调过程中英语等高资源语言所占比重较大，模型对于英语等高资源语言的理解和输出能力较强，对于其他低资源语言的理解和输出能力则相对较差，这些语言的所涉及的低频短语

也相对更多，故而以这些非英语语言为输出的翻译方向能从 LPO 中获得更多的提升。

4.2 消融实验

为了证明本文方法的有效性，本实验在两组不同翻译场景上各设置了 2 组消融实验：第一组为只进行动态温度采样和翻译差异组构造的实验。即在 X-ALMA 的基础上进行动态数据采样，将所得数据进行差异区分，对 X-ALMA 直接采用原始的 DPO 方法训练。第二组为只进行局部偏好优化的实验。即不进行特别的数据筛选，直接利用 X-ALMA-Preference 数据集独立采样两次构造训练数据，采用两阶段的损失函数对 X-ALMA 进行训练。表 4 和表 5 给出了消融实验的结果，其中 w/o LPO 代表去掉改进的损失函数，只进行数据构造的方法，w/o DA 表示去掉数据构造只进行损失函数改进的方法。实验表明，无论是单独去除数据构造模块还是损失函数改进模块，都会导致模型性能出现不同程度的下降。深入分析这一现象可以发现，当缺乏数据构造方法时，模型训练将受限于单一且同质化的监督信号，无法获取足够多样化的训练样本，这会显著制约模型对复杂翻译场景的适应能力。与此同时，若仅依赖传统 DPO 损失函数而缺少本文提出的改进方案，模型会因 DPO 固有的“过度拒绝”机制而产生性能劣化问题，导致翻译质量下降。实验结果证明，将多层次数据构造方法与改进的损失函数设计相结合，通过二者的协同作用，既确保了训练数据的丰富性和代表性，又优化了模型的学习动态，从而显著提升了大型语言模型在多样化翻译任务上的整体表现。

表 4　书写系统差异组消融实验

Table 4　Ablation experiment of script difference group

Models	en→et			en→fi			en→ja			en→ka		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**28.0**	**92.4**	**84.8**	**26.6**	**93.1**	**85.9**	**36.6**	**91.9**	**82.7**	**15.5**	**88.7**	**77.7**
w/o DA	27.7	92.1	83.9	26.2	92.7	84.9	36.2	91.4	82.0	15.0	88.3	76.8
w/o LPO	27.3	91.7	83.2	25.9	92.4	84.2	35.6	90.8	81.5	14.7	87.9	76.3

Models	en→ko			en→zh			Avg.en→xx		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**16.1**	**90.2**	**82.6**	**45.0**	**88.9**	**79.3**	**28.0**	**90.9**	**82.2**
w/o DA	15.5	89.6	81.8	44.6	88.5	78.2	27.5	90.4	81.3
w/o LPO	15.2	89.1	81.3	44.0	87.9	77.8	27.1	90.0	80.7

Models	et→en			fi→en			ja→en			ka→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**38.8**	**89.7**	**84.2**	**36.3**	**90.5**	**80.9**	**29.0**	**88.6**	**78.4**	**29.5**	**87.4**	**73.6**
w/o DA	38.5	89.0	83.7	35.9	90.1	80.2	28.5	88.0	77.8	28.9	86.9	72.8
w/o LPO	38.2	88.5	83.1	35.7	89.6	79.7	28.3	87.9	77.5	28.6	86.8	72.4

Models	ko→en			zh→en			Avg.xx→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**30.9**	**88.7**	**78.9**	**29.7**	**87.8**	**78.7**	**32.4**	**88.8**	**79.1**
w/o DA	30.7	88.4	78.3	29.5	87.6	78.0	32.0	88.3	78.5
w/o LPO	30.4	88.0	77.8	29.3	87.3	77.6	31.8	88.0	78.0

表 5 中亚语言组消融实验

Table 5 Ablation experiment of Central Asia language group

Models	en→ar			en→az			en→fa			en→he		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**28.6**	**88.4**	**79.1**	**14.3**	**88.5**	**79.5**	**27.2**	**89.0**	**81.0**	**33.7**	**89.8**	**79.7**
w/o DA	28.4	87.9	78.8	14.1	88.2	79.1	26.5	88.4	80.5	33.4	89.3	79.5
w/o LPO	28.0	87.5	78.2	13.8	87.9	78.7	25.8	88.4	80.0	33.0	89.0	78.8

Models	en→kk			en→ky			en→tr			en→uz		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**22.3**	**91.3**	**81.6**	**12.4**	**89.1**	**79.3**	**28.7**	**90.0**	**78.9**	**15.8**	**90.7**	**77.5**
w/o DA	22.2	89.6	81.2	12.3	88.5	78.5	27.8	90.4	78.4	15.5	89.7	77.4
w/o LPO	21.4	89.1	81.2	12.1	88.4	78.1	27.4	90.3	78.0	15.2	89.3	77.2

Models	Avg.en→xx			ar→en			az→en			fa→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**22.9**	**89.7**	**79.6**	**41.2**	**88.4**	**76.8**	**25.5**	**87.2**	**75.8**	**38.2**	**89.0**	**75.7**
w/o DA	22.5	89	79.2	40.5	88.1	76.3	24.9	86.8	75.6	38.0	88.6	75.2
w/o LPO	22.1	88.7	78.8	40.3	87.9	76.2	24.7	86.5	75.2	37.5	88.4	74.8

Models	he→en			kk→en			ky→en			tr→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**44.2**	**89.0**	**76.8**	**34.9**	**88.4**	**76.8**	**25.0**	**86.1**	**74.8**	**40.2**	**90.1**	**78.7**
w/o DA	43.8	88.7	75.6	34.7	87.3	76.2	24.4	85.8	74.5	40.0	89.8	78.4
w/o LPO	43.6	88.1	75.5	34.5	87.0	75.8	24.0	85.8	74.3	39.7	89.6	78.1

Models	uz→en			Avg.xx→en		
	BLEU	COMET-22	XCOMET	BLEU	COMET-22	XCOMET
X-ALMA-LPO	**33.6**	**87.4**	**74.3**	**35.4**	**88.2**	**76.2**
w/o DA	33.1	86.9	74.1	34.9	87.8	75.7
w/o LPO	33.2	86.4	73.7	34.7	87.5	75.5

4.3 案例研究

为了进一步说明 LPO 方法的有效性，从测试集中抽取出了 en→zh 的一组样本并分别给出参考译文、本文基线 X-ALMA 和本文方法 X-ALMA-LPO 输出的结果，结果如表 6 所示，通过对比可以明显观察到，X-ALMA-LPO 生成的译文在语序组织上更为自然流畅，整体可读性显著提升。特别是在处理“germ-line cells”等专业低频术语时，LPO 方法展现出更精准的翻译能力，避免了基线模型可能出现的语义偏差或表达生硬等问题。以上实例证明，LPO 方法不仅在宏观层面的语义连贯性和语言流畅度上有所突破，在微观层面的专业术语和低频词汇处理上也取得了实质性进展。这种全局与局部翻译效果的双重提升，验证了 LPO 方法在解决 LLM 翻译任务中的关键挑战方面具有独特优势，为提升机器翻译质量提供了新的技术思路。实验结果从定性和定量两个维度共同证实，相比传统方法，LPO 能够产生更符合人类语言习惯的高质量翻译输出。

表 6 案例研究

Table 6 Case study

源文	Mutations can have a variety of different effects depending on the type of mutation, the significance of the piece of genetic material affected and whether the cells affected are germ-line cells.
参考译文	突变会产生各种各样不同的影响，这取决于突变的类型、受影响遗传物质的重要性以及受影响的细胞是否为生殖系细胞。
X-ALMA	突变的影响取决于突变的类型、受影响基因物质的重要性以及受影响细胞是否为受精卵细胞。
X-ALMA-LPO	突变可能会产生多种不同的影响，这取决于突变的类型、受影响基因物质的重要性以及受影响的细胞是否是生殖细胞。

5 结束语

本文提出了一种针对 LLM 机器翻译任务的局部偏好优化训练方法，该方法首先通过动态温度采样和评估构造了多样的偏好数据，在此基础上设计了两阶段的损失函数，旨在缓解 DPO 带来的劣化问题并在保障整体翻译质量的前提下提升 LLM 在翻译中的局部表现。实验结果表明，本文方法有效地增强了 LLM 在翻译任务中的整体表现，并提高了 LLM 对一些低频词的翻译准确性。未来将探索本文所提出的方法在更多的翻译方向和不同的 LLM 基座上的普适性，以及研究本文方法在多语言翻译的零样本翻译方向上的影响。

参考文献

[1] Touvron H, Lavril T, Izacard G, et al. LLaMA: open and efficient foundation language models. arXiv[J]. arXiv preprint arXiv:2302.13971, 2023.

[2] Anil R, Dai A M, Firat O, et al. Palm 2 technical report[J]. arXiv preprint arXiv:2305.10403, 2023.

[3] Chowdhery A, Narang S, Devlin J, et al. Palm: Scaling language modeling with pathways[J]. Journal of Machine Learning Research, 2023, 24(240): 1-113.

[4] Fujii K, Nakamura T, Loem M, et al. Continual Pre-Training for Cross-Lingual LLM Adaptation: Enhancing Japanese Language Capabilities[J]. arXiv preprint arXiv:2404.17790, 2024.

[5] Zhang S, Fang Q, Zhang Z, et al. BayLing: Bridging Cross-lingual Alignment and Instruction Following through Interactive Translation for Large Language Models[J]. arXiv pre-print server, 2023.

[6] Lu K, Yang Y, Yang F, et al. Low-Resource Language Expansion and Translation Capacity Enhancement for LLM: A Study on the Uyghur[C]. Proceedings of the 31st International Conference on Computational Linguistics, 2025: 8360-8373.

[7] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in LLM via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.

[8] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.

[9] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model[J]. Advances in Neural Information Processing Systems, 2024, 36.

[10] Wang P, Xu A, Zhou Y, et al. Direct Judgement Preference Optimization[J]. arXiv preprint arXiv:2409.14664, 2024.

[11] Chen G, Liao M, Li C, et al. Step-level Value Preference Optimization for Mathematical Reasoning[J]. arXiv preprint arXiv:2406.10858, 2024.

[12] Xu H, Sharaf A, Chen Y, et al. Contrastive Preference Optimization: Pushing the Boundaries of LLM Performance in Machine Translation[C]. Forty-first International Conference on Machine Learning.

[13] He Z, Wang X, Jiao W, et al. Improving Machine Translation with Human Feedback: An Exploration of Quality Estimation as a Reward Model[C]. Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), 2024: 8157-8173.

[14] Costa-Juss à M R, Cross J, Çelebi O, et al. No language left behind: Scaling human-centered machine translation[J]. arXiv preprint arXiv:2207.04672, 2022.

[15] Mao Z, Yu Y. Tuning LLM with contrastive alignment instructions for machine translation in unseen, low-resource languages[J]. arXiv preprint arXiv:2401.05811, 2024.

[16] Zhang X, Rajabi N, Duh K, et al. Machine translation with large language models: Prompting, few-shot learning, and

fine-tuning with QLoRA[C]. Proceedings of the Eighth Conference on Machine Translation, 2023: 468-481.

[17] 侯钰涛, 阿布都克力木·阿布力孜, 史亚庆, et al. 面向"一带一路"的低资源语言机器翻译研究[J]. 计算机工程, 2024, 50(4): 332-341.
Hou Y, Abudukelimu A, Shi Y, Research on low-resource language machine translation for the "Belt an Road" [J]. Computer Engineering, 2024, 50(4): 332-341.

[18] Yin Y, Zeng J, Li Y, et al. LexMatcher: Dictionary-centric Data Collection for LLM-based Machine Translation[J]. arXiv preprint arXiv:2406.01441, 2024.

[19] Feng Z, Zhang Y, Li H, et al. Improving LLM-based machine translation with systematic self-correction[J]. arXiv preprint arXiv:2402.16379, 2024.

[20] Raunak V, Sharaf A, Wang Y, et al. Leveraging GPT-4 for Automatic Translation Post-Editing[C]. Findings of the Association for Computational Linguistics: EMNLP 2023, 2023: 12009-12024.

[21] 李博, 季佰军, 段湘煜. 基于译文易错词纠正机制的大语言模型机器翻译[J]. 计算机工程: 0.
Li B, Ji B, Duan X, Machine Translation with Large Language Models Based on the Correction Mechanism of the Translations Error-Prone Words [J]. Computer Engineering, 0.

[22] Ma Y J, Liang W, Wang G, et al. Eureka: Human-Level Reward Design via Coding Large Language Models[C]. 2nd Workshop on Language and Robot Learning: Language as Grounding, 2023.

[23] Wu Y, Fan Y, Liang P P, et al. Read and reap the rewards: Learning to play atari with the help of instruction manuals[J]. Advances in Neural Information Processing Systems, 2023, 36: 1009-1023.

[24] Zhou Z, Hu B, Zhao C, et al. Large language model as a policy teacher for training reinforcement learning agents[C]. Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence, 2024: 5671-5679.

[25] 罗焕坤, 葛一烽, 刘帅. 大语言模型在数学推理中的研究进展[J]. 计算机工程: 0.
Luo H, Ge Y, Liu S, Research Progress of Large Language Models in Mathematical Reasoning [J]. Computer Engineering, 0.

[26] Yang G, Chen J, Lin W, et al. Direct Preference Optimization for Neural Machine Translation with Minimum Bayes Risk Decoding[C]. Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 2: Short Papers), 2024: 391-398.

[27] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. Advances in neural information processing systems, 2022, 35: 27730-27744.

[28] Achiam J, Adler S, Agarwal S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.

[29] Xu H, Murray K, Koehn P, et al. X-alma: Plug & play modules and adaptive rejection for quality translation at scale[J]. arXiv preprint arXiv:2410.03115, 2024.

[30] Post M. A Call for Clarity in Reporting BLEU Scores[J]. WMT 2018, 2018: 186.

[31] Rei R, Stewart C, Farinha A C, et al. COMET: A Neural Framework for MT Evaluation[C], 2020: 2685-2702.

[32] Guerreiro N M, Rei R, Stigt D V, et al. xcomet: Transparent machine translation evaluation through fine-grained error detection[J]. Transactions of the Association for Computational Linguistics, 2024, 12: 979-995.

[33] Barrault L, Bojar O, Costa-Jussa M R, et al. Findings of the 2019 conference on machine translation (WMT19)[C], 2019.

[34] Federmann C, Kocmi T, Xin Y. NTREX-128–news test references for MT evaluation of 128 languages[C]. Proceedings of the first workshop on scaling up multilingual evaluation, 2022: 21-24.

[35] Üstün A, Aryabumi V, Yong Z, et al. Aya Model: An Instruction Finetuned Open-Access Multilingual Language Model[C]. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2024: 15894-15939.

[36] Xue L, Constant N, Roberts A, et al. mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer[C]. Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2021: 483-498.

[37] Lu Y, Zhu W, Li L, et al. LLaMAX: Scaling Linguistic Horizons of LLM by Enhancing Translation Capabilities Beyond 100 Languages[C]. Findings of the Association for Computational Linguistics: EMNLP 2024, 2024: 10748-10772.

[38] Touvron H, Martin L, Stone K, et al. Llama 2: Open foundation and fine-tuned chat models[J]. arXiv preprint arXiv:2307.09288, 2023.

[39] Dubey A, Jauhri A, Pandey A, et al. The llama 3 herd of models[J]. arXiv preprint arXiv:2407.21783, 2024.

[40] Rei R, De Souza J G, Alves D, et al. COMET-22: Unbabel-IST 2022 submission for the metrics shared task[C]. Proceedings of the Seventh Conference on Machine Translation (WMT), 2022: 578-585.

基于提示词（工程）的大语言模型翻译实践：特征、困境与对策①

胡健　中央财经大学　范武邱　中南大学

摘　要：大语言模型通过提示词（工程）在一定程度上重构了传统翻译实践，形成了翻译过程一站化、翻译模式提示化与译者角色多元化三大特征，但也对应造成了三大困境：翻译过程过于集中、翻译模式信任危机以及译者角色职责扩大。对此，研究提出翻译过程“以人为本”、提示工程“以信为本”、角色职责“以我为本”三大应对策略，旨在为大语言模型翻译实践的发展提供来自翻译研究的启示。

主题词：大语言模型翻译实践；提示词（工程）；特征、困境与对策

中图分类号：H059　　**文献标识码：**A　　**文章编号：**1672-9382(2026)02-0090-07

DOI:10.13564/j.cnki.issn.1672-9382.2026.02.011

1 引言

作为新兴生成式人工智能的代表，大语言模型（large language models，LLMs，以下简称大模型）带给翻译的不仅是技术升级、业态丰富与行业赋能，还有人机主客体思辨、职业伦理挑战以及对翻译本质的反思（Lee，2024；王少爽、陈媛媛，2025）。大模型产生上述深刻广泛的影响，源于其以提示词（工程）为主导的翻译实践。当前实例与实证研究证明，大模型在提取原文术语并查找对应译文、输出初译、译后编辑、校对润色、输出一定风格与格式的译文等译前、译中、译后工作均可通过提示词（工程）完成（Siu，2023；耿芳、胡健，2023；Gao et al.，2023），这在某种程度上重构了传统翻译实践，继而成为人工智能翻译研究中的热门话题。大模型翻译实践发展呈现出多智能体分工协同（multi-agent collaboration）趋势（刘淼，2024），但基于提示词（工程）的单体大模型翻译仍是当下重要形式，也是本研究中大模型翻译实践的主要所指对象。

当前研究主要关注大模型融入翻译工作流的研发测试与过程方式（Yamada，2023；Zhu et al.，2025），测评对比不同大模型翻译质量与人机译后编辑效率（张曙康、赵朝永，2025；仲文明等，2024），梳理从谷歌翻译到ChatGPT、从MTPE（machine translation post-editing）到AIPE（artificial intelligence post-editing）等翻译工具的使用及译后编辑模式的发展（Mohammed，2025；王华树、刘世界，2025），反思译者实践工作转变对译者培养及翻译教学的启示（王少爽，2025；Kornacki & Pietrzak，2024）。以上研究可归纳为大模型翻译实践过程、翻译模式以及译者角色三个方面，但少有研究从提示词（工程）视角宏观总结这三个方面主要具有怎样的特征、这些特征对译者现有翻译实践造成了哪些困境以及译者如何应对这些困境。因此，有必要分析提示词（工程）的内涵与功能，对比现有翻译实践过程、模式以及译者角色，回答上述三个研究问题，辩证反思大模型翻译的利弊得失，提出应对策略，促进翻译学与大模型的跨学科结合，为人工智能翻译发展提供来自翻译学研究的启示。

2 基于提示词（工程）的大模型翻译实践特征

译者使用大模型进行翻译有使用提示词或提示词工程两种模式。提示词（prompt）

作者简介：
胡健，中央财经大学外国语学院讲师。研究方向：机器翻译、人工智能与翻译、翻译理论与实践。E-mail：hujian2017@foxmail.com。
范武邱，中南大学外国语学院教授，博士生导师。研究方向：翻译理论与实践、科技翻译。E-mail：fanwuqiu@163.com。

中国知网　https://www.cnki.net

指人类用户向大模型输入的问题或单句指令，适用于快速翻译（如“请翻译以下文章”）、检索询问（如“请搜索作者写作本文的时代背景”）等简单单次任务。

作为提示词的进阶版，提示词工程（prompt engineering）不只是一段文本，而是一种自然语言编程，是系统性与结构化设计、测试、优化提示词的过程与结果，一般包括背景介绍、角色分配、任务分工、输出要求等部分，用于处理复杂任务，确保生成结果更为稳定明确。例如，通用提示词框架CRISPE[②]包含5个维度：capacity and role（角色能力）、insight（背景洞察）、statement（任务声明）、personality（个性输出）和experiment（生成试例）。人类译者使用该提示词工程，相当于以提示性提问为方式与大模型交互，赋予大模型译者等角色身份（如“你是财经翻译专家”），告知大模型项目背景与具体任务，定制化生成翻译产品，事实上在翻译过程、翻译模式、译者角色三个方面重构了翻译实践的文本内外活动，符合当前研究热点。因此，以下从这三个方面分析大模型翻译实践的特征。

2.1 翻译过程一站化

传统翻译实践大致分译前、译中、译后三阶段进行，译者设置翻译提示词工程则相当于将翻译实践各步骤融于一体化框架内，由大模型一次性生成定制化译文，无须借助其他信源资料，理论上“消解”了译前、译中、译后的阶段划分，缩短了工序流程，减少了中间环节。以CRISPE为例，翻译提示词工程设置如下（见表1）。

如表1所示，基于CRISPE的翻译提示词工程把翻译实践模拟压缩至同一个页面，避免译者在多个网页、工具、软件之间切换，在理想情况下可依靠一个提示词（工程）“一站式”解决翻译任务。针对生成译文的不足，译者还可针对性地调整提示词工程，增加维度（如“译文评价”或“译后编辑”）或在现有维度中增加新内容（如在“任务声明”中增加“原文术语提取”），进一步提高生成译文质量。

2.2 翻译模式提示化

翻译模式（translation mode）指“翻译活动中的组织形式、工作流程与操作规范……侧重于翻译活动在实践层面的程序化管理和规范化应用”（王华树、刘世界，2025：111）。正所谓“好翻译是查出来的”，由于专业背景、百科知识、双语及跨文化能力有限，个体译者以往需要查阅词典资料以理解原文和产出译文，之后随着搜索引擎的发展，译者资料查证等工作转移至互联网。换言之，翻译实践一直遵循着“查证翻译”模式。得益于机器翻译（machine translation，MT）与计算机辅助翻译（computer-assisted translation，CAT）的兴起，译者通过机译引擎获取初步译稿后进行译后编辑（post-editing，PE），形成MTPE模式。或借助CAT调用应用程序接口（application programming interface，API）得到机译初稿，再载入翻译记忆库、术语库，执行预翻译，最后进行译后编辑，即MT+CAT+PE模式。这两种模式成为主流翻译模式。

大模型变革翻译实践的最显著特征是翻译各流程均可使用提示词（工程）完成，形成了以提示词（工程）为主导的工作流，不仅能直接生成译文，而且可凭借其搜索、生成、总结等功能，改变以往资料查证、术语提取、译后编辑等步骤均需要译者亲力亲为或者借助MT、

表 1 基于 CRISPE 的翻译提示词工程

维度	释义（以翻译为例）
角色能力	告诉大模型扮演的角色，明确角色能力，如财经领域专业译者，擅长财报翻译
背景洞察	告诉大模型任务背景信息或上下文，如某公司需要发布英文版年报，目标读者为境外投资者
任务声明	告诉大模型具体任务，如请英译该公司今年年报，参考该公司去年年报英文版
个性输出	告诉大模型以什么风格、形式、格式呈现生成结果，如译文语言专业严谨、以中英左右对照表格形式展示
生成示例	告诉大模型额外条件，限制生成或输出多个回答，如考虑美国、英国投资意向书的地道表达，请给出两个译本

中国知网 https://www.cnki.net

CAT等软件工具完成的历史。简言之，翻译实践模式正在经历从“查证翻译”、MTPE（或MT+CAT+PE）到“提示词（工程）翻译”的转变。

若使用大模型查证资料，在联网模式下，大模型以提示词（如“请搜索这则财经新闻的相关背景信息”）为关键词，查找当下互联网；关闭联网后，大模型并不实时查询互联网数据，而是以自身训练阶段学习的书籍、文档、图片、视频等作为信息源。无论哪种模式，大模型都会直接总结出“答案”，而以往基于网络的查证需要译者检索关键词，人工挑选网络资源或网页信息。

本质上，译者使用大模型属于计算机辅助翻译，但其操作逻辑并非逐一点击菜单选项，而是类似录制宏命令或编程，以提示词（工程）完成一系列翻译实践操作，在一定程度上可替代部分软件工具。以提取术语为例，以往提取原文术语由译者手工完成，速度慢，但准确性高；或使用Trados、MemoQ、YiCAT等CAT软件及其插件提取，效率高，但不易识别新词，难以调节分词颗粒度，容易遗漏术语。提取原文术语后，译者还需要搜寻对应译文，再人工汇总制表。

如今，大模型结合提示词可实现上述多步骤操作。例如，提取一篇财经新闻中的财经术语，在大模型联网模式下，输入“假设你是财经术语专家，请提取原文中的财经术语”“请根据上文内容，补充上述术语之外的相关财经术语”“请翻译上述提取和补充的财经术语，输出为双语对照表格”等简单指令，让大模型通过网络了解当前最新财经术语，补充遗漏术语，建立双语术语库，完成译前术语准备。

2.3 译者角色多元化

按常规翻译实践分工，翻译活动各环节的职责分别由各个角色负责，个体译者主要负责“翻译”一环，一般不会过多参与前期的项目管理或者后期的编辑加工校对。随着MTPE成为主流翻译模式，译者客观上被赋予了职责相对固定的机器译文编辑的角色。而大模型的研发初衷并不只是实现翻译功能，故人类译者需要撰写相关提示词（工程），在名义上赋予大模型相关角色，才能完成翻译实践的相关步骤与流程；反之，也给自己对应“增设”了各类角色，故译者角色可随着提示词的变化而变化，变得越发多元化。

使用简单提示词时，人类译者与大模型一般充当单一角色，例如“请帮我翻译以下文章”“请帮我校对以下译文”分别将大模型角色预设为“（机器）译者”与“编辑”，而人类对应的角色分别是“读者”与“译者”。使用提示词工程时，双方则扮演多重角色。如表1所示，人类提示者扮演的可能是翻译项目经理、译者或读者，而大模型扮演的则是译者、术语专家、编辑等多个角色的结合体。

提示词（工程）的“双向赋角”促使译者与大模型的交互更为拟人化，扩大了双方的交互范围。目前人类译者与大模型之间的翻译互动本质上仍属于人与工具之间的文本内活动，但提示词往往赋予大模型拟人角色，尤其是在采用提示词工程后，大模型与人类译者扮演多元角色（如编辑、术语专家），促使人类译者与大模型之间的交互关系开始从文本内转向文本外，即大模型不只是工具（如输入“请翻译”与“请搜索”等简单提示词时作为机器翻译与搜索引擎使用），而是具有虚拟人格，与人类译者进行类人际交互，丰富了两者之间的翻译实践交互关系。提示词工程要求大模型扮演“财经领域翻译专家”，译者扮演“项目经理”，后者应站在该角色立场上与大模型交互，两者的互动内容则超过原有译者文本外翻译活动的交互范畴，例如译者向大模型提供项目背景资料。

3 基于提示词（工程）的大模型翻译实践困境

目前大模型内部决策过程和运行逻辑机制仍难以被人类直接观察、理解和解释，处于所谓“黑箱”（black box）状态。大模型训练数据规模越来越大，数据类型与参数越来越多，这加剧了其生成结果的不可预测性，既有机会“涌现”（emergence）出创新表现，也有可能产生错误或“幻觉”（hallucination），而作为动态“变量”的提示词（工程）增加了大模型生成结果的不确定性。

正因如此，大模型以提示词（工程）作为翻译模式，涵盖翻译过程各个环节，为译者检索信息与翻译编辑提供了新渠道、新技术与新方法，在某种程度上提升了翻译效率，但也导致人类译者只知生成结果，不知生成过程，并

中国知网 https://www.cnki.net

被赋予其他角色，继而影响了翻译过程、翻译模式以及译者职责，造成以下三大困境。

3.1 翻译过程过于集中

俗话说“不要把鸡蛋放在同一个篮子里”，但当前大模型翻译以提示词（工程）作为翻译模式，实现过程一站化，类似于将整个翻译实践寄托于提示词（工程）这个“篮子”。然而，设计提示词工程不等同于自己手动查证、动笔翻译与译后编辑，译者无法预测或控制大模型生成结果。翻译过程一站化的风险在于一旦导出译文有误或者不佳，译者难以回溯提示词工程的哪一个维度出现错误，或者提示词是否撰写过多或不足。

针对上述问题，译者虽能进行后续追问或重新设计提示词（工程），增加新维度或更改维度内容，但难以控制“文字变量”，因为大模型生成译文都是一次性定制，维度之间的细微变化可能导致大模型生成新回答，译文修改效果不一定符合译者预定目标。

3.2 翻译模式信任危机

大模型凭借提示方式承担搜索、总结、翻译等工作，但由于其存在众所周知的编造答案等问题，所以只要大模型出现过一次错误回答或虚构信源，译者就难免对其后续输出质量产生疑虑，形成大模型翻译的信任危机。

加剧大模型翻译信任风险的另一因素是译者与大模型的问答单向性与顺从性。如果译者未在提示词中设置大模型“反问”或“求证”指令，那么两者之间往往形成前者提问、后者回答的单向交互。一旦译者质疑回答，大模型容易“承认错误”，然后给出相反或不同的结果，加深信任危机。即使译者提出“不合理”要求，大模型也会“言听计从”，不与争辩（李长栓，2023：83-84）。例如，译者发现原文有误后会主动纠正错误、做译者注或请教原文作者，而大模型通常不会自主“发现”并“报告”译者原文有误，从而反问译者或向译者求证原文信息，而是“将错就译”。

此外，不同大模型可能会给出不同反馈结果，即使采用同一大模型，若使用不同提示词提问，回答也可能千差万别，或者在不同时间使用同一提示词提问同一大模型，回答也可能发生变化。这些变化进一步加深了人类译者对大模型的信任危机。

3.3 译者角色职责扩大

人类译者通过提示词（工程）赋予大模型多种角色的同时，也给自己安排了其他角色，这就意味着双方肩负的职责均扩大或增加了。虽然人类译者在各翻译环节均有去主体性趋势（胡健、范梓锐，2023），但最后签字负责的不是大模型，而是人类译者。换言之，各翻译环节的责任不会消失，看似“转移”至大模型，但实际叠加在人类译者身上。

例如，人类译者赋予大模型“译者”角色的同时也给自己增加了编辑校对职责（王华树、刘世界，2024）。后期编辑的前提是编辑者的翻译水平或译入语水平高于或相当于初译者，但随着大模型翻译表现愈发优于传统机器翻译，译文质量逐渐媲美人工翻译（胡开宝、李晓倩，2023），译者越来越难发现其译文错误（Pym，2025），这就对译者自身译后编辑能力提出更高要求（郑国锋、潘曦，2025），其译后编辑职责从MTPE上升为HTPE（human translation post-editing，即人工翻译后编辑），无限接近编辑（类）人类译文，不只是处理一般机译容易出现的错译误译，而是挖掘大模型生成译文中的隐性错误、虚构内容或歧视偏见。

翻译初学者如果难以把握大模型初译质量，无法识别对错，承担校对和编辑工作，可能导致错上加错，甚至把正确的改成错误的。资深译者面对不熟悉的领域也将面临类似的挑战。又如，译者扮演项目经理角色，这就要求译者在把握真实项目全局和了解译文用途的基础上设计提示词工程，否则可能由于提示词信息不足或错误而误导大模型，导致生成译文质量不佳。

人类译者一旦无法把握提示词工程所增设的职责，这些职责就会向翻译项目下游或后期环节责任人转移。大模型翻译速度快、产量大，但倘若译文潜藏错误、编造虚假内容或存在歧视偏见，那么人类译后编辑者将陷入“弃之可惜，用之大改”的两难境地。如果进行深度译后编辑，人类译后编辑者将花费大量时间精力，重新查证事实，调整结构和语序，使得词意句义符合目标语及其所在社会的表达习惯、文化习俗，这还不如自己重译；但倘若进行轻度译后编辑，把关、审核这些看似正确但暗藏风险的大模型译文的负担则留给了后续出版校对人员，或最终由读者承担译文风险（Pym，2025）。

中国知网 https://www.cnki.net

4 基于提示词（工程）的大模型翻译实践对策

针对上述三类大模型翻译实践困境，译者应发挥主观能动性，施展专业技能，在与大模型对话中主动参与资料查证与翻译编辑，利用其他资源或工具，优化设计提示、交互方式或是更换大模型，提高大模型使用效度，从自身实际情况出发，做好本职工作。本研究提出的三个应对策略具体展开如下。

4.1 翻译过程“以人为本”

整个翻译过程理论上均可以提示词（工程）为方式，由大模型“一站式”完成，但实操中不一定非要如此。译者使用大模型不能期待仅通过一个提示词工程就生成完美译文，而应合理预估大模型表现，利用提示词与之持续对话，提高个人与其他工具资源在译前、译中、译后环节的参与度与使用度，坚持翻译过程“以人为本”，避免过度依赖大模型。

译前，译者可上传原文相关资料、平行文本或语言资产供大模型即时学习，再设计提示词（工程），提高译文准确性，保持风格统一。译中，译者可与大模型持续对话，表达译志，抒发译思。大模型对长上下文语义的理解越准确，越有利于其在与译者对话中理解与执行后者的指令。例如，译者在大模型生成译文后，可针对性地继续提示“依据本文所处时代背景与作者生平理解并重新翻译这个句子”。译后，译者应继续发挥主观能动性，引导大模型校验术语与文风，例如“查验译文术语与风格是否统一，指出不统一的词句”，最后进行人工润色与审核。

除了在与大模型的交互中增强译者主体性，译者还可利用现有翻译技术、工具和资源，增强翻译环节的人为把控。例如，针对大模型检索信息不稳定、虚构信源、错误较多等问题，译者如果熟悉原文领域，不是必须将大模型作为唯一搜索工具或者信息来源，而是可以选择专业权威网站、术语库、记忆库作为参考来源，包括中国特色话语对外翻译标准化术语库、UNTERM（联合国术语库）、MyMemory等，采用“半中半英”“半原文半译文”等检索技巧（卢植、胡健，2019），实现精准搜索、权威参考和多方验证。当前各大CAT软件已接入DeepSeek、ChatGPT等大模型，提供大模型初译，方便译者在CAT中对初译进行译后编辑，载入、复用记忆库、术语库等语言资产，保持译文术语和语言风格的一致性，而非通过大模型包揽整个流程。

4.2 提示工程“以信为本”

面对提示词（工程）翻译模式造成的回答错误、交互单向和模型差异三大信任问题，译者可从提示设计、交互方式以及模型选用三个方面提升大模型生成译文的精准性与可信度。

首先，根据译文错误类型，针对性改善提示词。对于事实性错误，译者可在提示词中注明“提供译文术语或参考出处的链接”，之后访问该链接确认其是否存在且有效，查证大模型译文与其对应参考源是否相符，减轻“幻觉”。如果译者了解待译领域，与其让大模型随机搜索，不如在提示词中指定准确信源，比如“重点参考这些网站内容”。对于偏见和歧视，译者可在提示词中添加大模型身份，如“跨文化专家，注重语言禁忌”，同时举出示例（如需要将“老年痴呆症”改为“阿尔茨海默症”）。

其次，译者可在提示词中设置大模型“反问”或“求证”指令，与大模型双向交互。译者应提前预测大模型可能对原文某些语句或文化负载词把握不准，并在提示词（工程）中增加相应维度或用简单提示词表述：“你是专业译者，帮我翻译下面这句话。如果对原文某些词句意思不确定或发现原文存在事实性错误，你可以反问我一些问题。”大模型在回答时会给出判断选项，方便人类译者选择反馈，提前介入原文理解与译文意义建构。

最后，如果提示设计、交互方式无法改善大模型“失信”问题，译者可考虑更换通用模型或选用垂直大模型及翻译专用模型。如果通用大模型的回答不确定且在更换提示词（工程）后回答仍不令人满意，译者可以提问其他通用大模型，或者利用其他大模型来审核校对当前模型生成的译文。除通用大模型外，Hunyuan-MT-7B、Seed-X、TranslateGemma等新近发布的翻译专用模型也应纳入试用范围，因为这些翻译模型在训练数据、微调模式或训练路线上各具特色，在文化理解、语境适配、多模态翻译或小语种翻译方面优于一般通用模型。如果待译原文属于某专业领域，译者还可挑选经过特定领域数据额外训练的垂直大模型，如医学领域的Med-PaLM、气象领域

中国知网 https://www.cnki.net

的“风清”、财经领域的“同花顺”、法律领域的HanFei（韩非）、教育领域的“桃李”（Taoli）等，深入理解特定行业文本及其使用场景，提高生成译文的专业性。此外，单体模型的算力、算法、算据毕竟有限，译者可引入多智能体翻译协作框架，即把翻译活动切分为“初译—审校—润色—质检”等子任务，由不同模型或智能体负责，译者分别对各模型或智能体输入提示词，促使其分工互动与整合结果（刘淼，2024），缓解信任危机。

4.3 角色职责“以我为本”

虽然译者借助提示词（工程）赋予大模型角色的同时也给自己增加了对应的角色和职责，但译者应根据自身翻译能力、对翻译项目及待译领域的熟悉程度，在角色职责分配中坚持“以我为本”。

如果已对整个翻译项目有充分了解，或者能通过与项目经理或赞助人沟通，主动了解翻译项目的来龙去脉，资深译者可以提高角色站位，扮演其他角色与大模型互动。例如，作为项目经理，把握项目全局，通过本地部署Hunyuan-MT-7B、Seed-X等轻量化开源翻译模型，利用本地模型对关键人名、地名、企业或数据信息进行去敏脱密，再将项目始末写入提示词工程，发挥大模型的“涌现”潜力，从而生成更符合客户需求的译文，也在硬件层面避免数据外泄风险。面对熟悉的翻译领域，资深译者可设计较简单的提示词（工程），快速获取大模型初译文本，之后化身“编辑”，负责校对润色。

倘若对整个翻译项目了解不多或原文非自身熟悉领域，翻译初学者则无法承担多种职责，不必在提示词中虚构项目信息或是设置过多维度需求，而应做好翻译本职工作，利用大模型的术语查证、图文识别等功能辅助翻译，或者选用翻译专用模型，通过与大模型持续对话，要求其提供译文时分享翻译过程。例如，提示“开启‘深度思考’模式，提供译文每段的解析思路”，译者也能从中不断学习，熟悉原文领域。最终交付时，译者应主动添加批注或译者注，注释查证后仍不确定的语句，避免给项目下游或后期环节的编辑校对人员增添额外负担。

5 结论与启示

基于提示词（工程）的大模型翻译实践在翻译过程、翻译模式、译者角色三个方面的具体特征表现为：大模型翻译将译前、译中、译后三个阶段压缩至同一个页面，“一站式”生成译文，缩短了翻译流程，形成提示化翻译模式；大模型搜索、查证、翻译等功能均可借助提示词（工程）实现，翻译实践方式正在经历从“搜出来”到“提出来”的转变；译者通过提示词（工程）赋予大模型多元角色的同时也给自己增加对应角色，丰富了彼此之间的交互关系。这些变革提升了翻译实践的效率，但其负面影响也值得我们冷静反思，例如翻译过程过于集中、翻译模式的信任危机，以及译者赋能大模型后反向造成自身角色职责的扩大。

针对上述三种困境，本研究提出以下三项应对策略：首先，译者应合理预估大模型表现，利用提示词与之持续对话，提高个人与其他工具在翻译各环节中的参与度与使用度，坚持翻译过程“以人为本”；其次，从提示设计、交互方式和模型选用三个方面提升大模型生成内容的质量，坚持提示工程“以信为本”；最后，根据自身翻译能力与对翻译项目及待译领域的熟悉程度，在角色职责分配中坚持“以我为本”。

RAG（检索增强生成）、智能体（AI agent）等的应用发展逐渐从技术层面缓和了上述大模型翻译困境，但也进一步加剧了翻译模式工具化与过程集成化，译者沦为翻译自动化的一环，埋下人类主体与去译者主位的风险隐患。这就更需要译者，尤其是翻译初学者，重视翻译基本功，将眼光放长远，深耕擅长领域，在主体性与工具性的博弈中不迷失初心，不泯灭人性，不摒弃“为人而译”的翻译本质。□

注释

① 本文系教育部人文社会科学研究青年基金项目“习近平经济思想的故事谱系与叙述机制研究”（编号：25YJC740016）与教育部人文社会科学研究规划基金项目“新中国成立以来中国军事语言演变及国际影响研究（1949—2021年）”（编号：22YJA740008）的阶段性成果。

② 提示词工程CRISPE由Matt Nigh在2023年1月14日提出，经微软研究院优化后成为业界标杆级提示词设计范式。

参考文献

[1] Gao, Y., R. Wang & F. Hou. How to design

中国知网 https://www.cnki.net

translation prompts for ChatGPT: An empirical study[Z]. arXiv, 2023. DOI: 10.48550/arXiv.2304.02182.

[2] Kornacki, M. & P. Pietrzak. *Hybrid Workflows in Translation: Integrating GenAI into Translator Training*[M]. New York: Routledge, 2024.

[3] Lee, T. K. Artificial intelligence and posthumanist translation: ChatGPT versus the translator[J]. *Applied Linguistics Review*, 2024(6): 2351-2372.

[4] Mohammed, T. A. S. From Google translate to ChatGPT: The use of large language models in translating, editing, and revising[A]. In M. H. Alaqad(ed). *Role of AI in Translation and Interpretation*[C]. London: IGI Global Scientific Publishing, 2025: 1-32.

[5] Pym, A. *Risk Management in Translation*[M]. Cambridge: Cambridge University Press, 2025.

[6] Siu, S. C. ChatGPT and GPT-4 for professional translators: Exploring the potential of large language Models in translation[Z]. 2023. DOI: http://dx.doi.org/10.2139/ss rn.4448091.

[7] Yamada, M. Optimizing machine translation Through prompt engineering: An investigation into ChatGPT's customizability[Z]. 2023. DOI: abs/2308.01391.195-204.

[8] Zhu, S., L. Pan, J. Dong et al. Overcoming language barriers via machine translation with sparse Mixture-of-Experts fusion of large language models[J]. *Information Processing and Management*, 2025(3). DOI: 10.1016/j.ipm.2025.104078.

[9] 耿芳, 胡健. 人工智能辅助译后编辑新方向——基于ChatGPT的翻译实例研究[J]. 中国外语, 2023(3): 41-47.

[10] 胡健, 范梓锐. 机器翻译视角下的翻译本质[J]. 当代外语研究, 2023(2): 90-96.

[11] 胡开宝, 李晓倩. 大语言模型背景下翻译研究的发展：问题与前景[J]. 中国翻译, 2023(6): 64-73.

[12] 李长栓. 利用ChatGPT做好中译外[J]. 民族翻译, 2023(4): 74-85.

[13] 刘淼. 大语言模型赋能中国时政话语俄译研究——多智能体互动翻译框架的创建与应用[J]. 外语电化教学, 2024(6): 15-22.

[14] 卢植, 胡健. 术语翻译的网络检索策略研究[J]. 上海翻译, 2019(2): 72-77.

[15] 王华树, 刘世界. 大语言模型对译者主体性的冲击及化解策略研究[J]. 外语与翻译, 2024(4): 16.

[16] 王华树, 刘世界. 从MTPE到AIPE: GenAI时代翻译模式演变及其对翻译教育的启示[J]. 山东外语教学, 2025(3): 111-121.

[17] 王少爽. 从“搜商”到“问商”：生成式人工智能时代的译者提示素养概念框架构建[J]. 外语教育研究, 2025(1): 1-8.

[18] 王少爽, 陈媛媛. 技术社会学视域下生成式人工智能对翻译行业发展的影响探析[J]. 上海翻译, 2025(4): 59-65.

[19] 张曙康, 赵朝永. 大语言模型之于文学翻译的适切性研究——基于多指标评估的《边城》多模型译文质量对比[J]. 中国外语, 2025(4): 85-95.

[20] 郑国锋, 潘曦. 人工智能时代的术语机器翻译：挑战与出路[J]. 中国外语, 2025(4): 98-99.

[21] 仲文明, 王迪, 田莎. 生成式人工智能与神经网络机器翻译人工译后编辑效率对比研究[J]. 翻译研究与教学, 2024(2): 96-105.

Prompt (Engineering)-Based LLM Translation Practice: Characteristics, Predicaments and Countermeasures

Abstract: To a considerable extent, large language models (LLMs), through prompt (engineering), have reconfigured traditional translation practice, triggering rise to three prominent characteristics: the integration of the translation process into a one-stop workflow, the prompt-driven transformation of translation modes, and the diversification of the translator's role. Correspondingly, however, three major challenges have emerged: excessive centralization of the translation process, a crisis of trust in prompt-based translation modes, and an expansion of the translator's professional responsibilities. In response, this study proposes three strategic orientations—human-centered translation processes, trust-oriented prompt engineering, and self-positioned role responsibility—aiming at offering insights from translation studies to accelerate the development of LLM-based translation practice.

Keywords: LLM translation practice; prompt (engineering); characteristics, predicaments and countermeasures

（责任编辑　秦彬彬）

中国知网 https://www.cnki.net

基于神经网络的机器翻译研究综述

马 潇,田永红+,赵 伟
内蒙古工业大学 数据科学与应用学院,呼和浩特 010080
+ 通信作者 E-mail:tyh@imut.edu.cn

摘 要:随着计算机技术的进步,机器翻译已成为实现跨语言沟通的关键工具,其发展历程可分为基于规则的机器翻译、基于统计的机器翻译以及基于深度学习的神经机器翻译。聚焦于大语言模型在翻译领域的应用与创新,全面回顾并系统性梳理了神经机器翻译(neural machine translation,NMT)的最新进展。从早期的循环神经网络到卷积神经网络,再到当前广泛应用的Transformer模型及其变体,概述了机器翻译的演进历程,分析了NMT的主流架构发展。深入剖析了大语言模型翻译的三个关键维度,系统比较了全参数微调与高效参数微调等技术在翻译任务上的差异性表现;详细探讨了多语言大模型翻译技术、零样本与少样本跨语言迁移的技术挑战与解决方案;全面综述了知识图谱增强、领域专业知识融合及多模态知识融合的大模型翻译方法;介绍了机器翻译的评价指标与常用数据集,并对低资源语言翻译提升、可解释与可控翻译系统、跨文化适应性翻译、计算资源优化以及隐私保护与安全可控等方向的研究前景进行了展望。

关键词:神经机器翻译;大语言模型;参数微调;多语言机器翻译;低资源语言翻译;知识图谱增强
文献标志码:A **中图分类号:**TP391.2 doi:10.3778/j.issn.1002-8331.2501-0086

Review of Neural Network-Based Machine Translation Research

MA Xiao, TIAN Yonghong+, ZHAO Wei
College of Data Science and Application, Inner Mongolia University of Technology, Hohhot 010080, China

Abstract: With the advancement of computer technology, machine translation has become a key tool for cross-language communication. Its development process can be divided into rule-based machine translation, statistics-based machine translation, and deep learning-based neural machine translation. Focusing on the application and innovation of large language models in the field of translation, this paper comprehensively reviews and systematically sorts out the latest developments of neural machine translation (NMT). The evolution of machine translation is summarized, and the mainstream architecture development of NMT is analyzed, from the early recurrent neural network to the convolutional neural network, and then to the widely used Transformer model and its variants. Three key dimensions of large language model translation are deeply analyzed, and the differences between full parameter fine-tuning and efficient parameter fine-tuning in translation tasks are systematically compared. The technical challenges and solutions of multilingual large model translation technology, zero-sample and few-sample cross-language transfer are discussed in detail. The large-scale model translation methods of knowledge graph enhancement, domain professional knowledge fusion and multi-modal knowledge fusion are comprehensively reviewed. In addition, the evaluation indicators and commonly used datasets of machine translation are introduced, and the research prospects of low-resource language translation promotion, interpretable and controllable translation systems, cross-cultural adaptive translation, computing resource optimization, privacy protection and security controllability are discussed.

Key words: neural machine translation; large language models; parameter fine-tuning; multilingual machine translation; low-resource language translation; knowledge graph enhancement

基金项目:国家自然科学基金(62466043)。

作者简介:马潇(1999—),女,硕士研究生,主要研究方向为自然语言处理、机器翻译;田永红(1974—),男,硕士,教授,硕士生导师,CCF会员,主要研究方向为自然语言处理、机器翻译、网络空间安全等;赵伟(1999—),男,硕士研究生,主要研究方向为自然语言处理、机器翻译。

收稿日期:2025-01-07 **修回日期:**2025-05-09 **文章编号:**1002-8331(2025)22-0036-19

中国知网 https://www.cnki.net

机器翻译是指利用计算机技术将一种自然语言自动转换为另一种自然语言的过程，旨在实现语言间的无缝对接，打破语言壁垒，促进全球信息的自由流通。其发展经历了三个阶段：基于规则的机器翻译（rule-based machine translation，RBMT）、基于统计的机器翻译（statistical machine translation，SMT）以及基于深度学习的机器翻译。基于深度学习的神经机器翻译（neural machine translation，NMT），近年来备受关注，成为机器翻译中的主流翻译技术。NMT模型发展迅速，从早期的循环神经网络（recurrent neural network，RNN）到后来的卷积神经网络（convolutional neural network，CNN）和当前广泛应用的Transformer模型及其变体，不断推动着机器翻译技术的进步。目前，大语言模型的出现带来一系列创新的机器翻译方法，为神经机器翻译领域注入了新的活力。因此，本文结合神经机器翻译领域最新进展探讨多种神经机器翻译方法，对神经机器翻译方法进行全面的回顾与系统性梳理总结，包括无监督机器翻译、半监督机器翻译、多语言机器翻译、多模态机器翻译、非自回归机器翻译及其他翻译方法。

1　机器翻译发展史

在机器翻译技术的发展历程中，从最初的基于规则的方法到现代的深度学习技术，每一步都标志着翻译技术的重大突破。本章将回顾机器翻译的发展史，从早期的基于规则的机器翻译，到后来的基于统计的机器翻译，再到当前基于深度学习的机器翻译，探讨它们各自的特点、优势和局限性。

1.1　基于规则的机器翻译

基于规则的机器翻译（RBMT）是20世纪40年代至80年代间广泛应用的早期机器翻译方法。该方法主要依赖于语言学家的专业知识和经验，通过构建详尽的双语词典和制定语法规则来指导计算机进行源语言到目标语言的转换。RBMT首先需要一个由语言学家预先定义并手动维护的静态双语词典，包含源语言和目标语言中所有可能出现的词汇及其对应关系。此外，还需要制定一系列描述两种语言在句子结构、词序、语态、时态等方面的差异的语法规则。在翻译过程中，先分析源语言句子的语法结构，再根据词典和语法规则将词汇和短语逐一转换为目标语言中的对应项，并重新组合成目标语言句子。然而，RBMT方法在处理复杂语言现象时存在一定的局限性。一方面，固定的规则框架不能像人类翻译者那样灵活地根据上下文进行调整，导致难以适应歧义、多义词以及语境变化等复杂语言现象；另一方面，构建一套能够全面覆盖所有语言现象的规则体系几乎是不可能的，这使得RBMT在处理复杂语言结构时容易出现错误或遗漏。此外，该方法需要大量时间和人力资源来制定及更新规则，以应对语言的发展和变化，大大增加了系统的维护成本和工作负担。因此，在机器翻译技术的演进过程中，RBMT逐渐被更为灵活和高效的翻译方法所取代。

1.2　基于统计的机器翻译

统计机器翻译（SMT）的出现为机器翻译领域带来了变革。这种方法放弃了传统的固定规则和词典，转而依赖于短语、句法和语言模型等统计信息，通过最大化翻译模型的概率来选择最佳翻译。其中，基于短语的统计机器翻译是SMT的重要分支。它利用短语对之间的对应关系，结合统计信息和上下文信息，选择最佳的目标语言短语序列作为翻译结果。而基于句法的统计机器翻译则通过分析源语言句子的句法结构，利用句法结构之间的对应关系来指导翻译。统计机器翻译的优点在于能够有效处理语言的复杂性和多样性，并且具有良好的可扩展性和灵活性。随着语料库的扩大和算法的改进，其性能得到了显著提升。然而，它也面临数据稀疏性、模型复杂度和计算资源需求等挑战，并且在处理特定领域的语言现象时可能仍有困难。

1.3　基于深度学习的机器翻译

神经机器翻译（NMT）的出现，标志着机器翻译技术的一个重要转折点。NMT利用深度学习技术，特别是序列到序列（sequence-to-sequence，Seq2Seq）模型架构，实现了自然语言之间的自动翻译。Seq2Seq模型架构最早由Sutskever等人于2014年提出，旨在解决序列到序列的转换问题。如图1所示，该模型通过编码器和解码器两个部分实现源语言到目标语言的映射。编码器负责将源语言序列编码成一个固定长度的向量表示输入解码器中，解码器则根据该向量表示生成目标语言序列。这种架构为机器翻译提供了一种全新的端到端学习方式，有效克服了传统的基于规则或统计的机器翻译方法中存在的局限性。随着研究的深入，Seq2Seq模型不断得到改进和扩展，特别是引入了注意力机制使得模型在解码过程中动态地关注源语言序列的不同部分，从而更好地捕捉长距离依赖关系和上下文信息。三种机器翻译方法对比如表1所示。

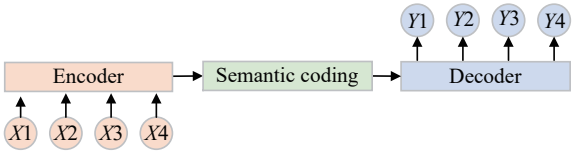


图1　Seq2Seq模型架构

Fig.1　Seq2Seq model architecture

2　机器翻译模型

常见的NMT模型主要有循环神经网络、卷积神经网络和Transformer模型等几类。本章将聚焦于这些神经网络结构在机器翻译中的应用，对它们的特点和性能进行深入分析。

中国知网　https://www.cnki.net

表1　机器翻译方法对比

Table 1　Comparison of machine translation methods

方法	优点	缺点
基于规则的机器翻译	易于理解和调试,可调整以满足特定需求,直接表达语言学知识	难以适应复杂语言现象,规则覆盖不全面
基于统计的机器翻译	具有良好的可扩展性和灵活性,随着语料库的扩大和算法的改进,性能得到显著提升,能够适应不同语言对和领域	模型复杂度高,需要精细调整,计算资源需求大,在处理特定领域的语言现象时可能存在困难,可解释性差
基于深度学习的机器翻译	翻译质量高,能处理复杂语言结构,泛化能力强,易于集成新技术	计算成本高,对长文本处理困难,对数据依赖性强,模型泛化能力有限

2.1　循环神经网络

循环神经网络(RNN)的概念在20世纪80年代得到了发展。1982年Hopfield[1]提出Hopfield网络作为RNN的一种特殊形式,具有对称连接,用于模拟人类记忆。此后,Rumelhart等人[2]进一步发展了反向传播算法用于训练神经网络。RNN的现代形态及其在序列数据处理上的应用,在20世纪90年代得到进一步完善。Elman[3]提出了Elman网络,这是一种早期的RNN模型。Elman网络通过在隐藏层和输入层之间引入反馈连接来处理序列数据,使得网络能够捕捉到时间序列的动态特性。RNN架构如图2所示。在RNN中,每个时间步 t 都有一个隐藏状态 $h(t)$,它不仅依赖于当前的输入 $x(t)$,还依赖于前一时间步的隐藏状态 $h(t-1)$。权重矩阵 U 用于将当前时间步的输入 $x(t)$ 转换为隐藏状态 $h(t)$,权重矩阵 W 用于将前一时间步的隐藏状态 $h(t-1)$ 转换为当前时间步的隐藏状态,权重矩阵 V 用于将隐藏状态 $h(t)$ 转换为输出 $o(t)$。这种结构允许网络在处理序列数据时保持一种“记忆”,使得模型能够利用先前的上下文信息来影响当前的输出。然而,RNN面临着梯度消失或梯度爆炸的问题,限制了其在处理长序列时的性能。为了解决这些问题,研究者提出了改进的RNN模型,如长短时记忆网络(long short-term memory,LSTM)[4]和门控循环单元(gated recurrent unit,GRU)[5]。

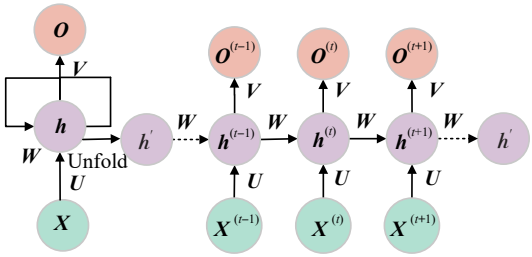


图2　RNN模型架构

Fig.2　RNN model architecture

2.2　卷积神经网络

卷积神经网络(CNN)是一种特别擅长处理图像数据的具有深度结构的前馈神经网络。CNN通过卷积操作提取输入数据的局部特征,并通过层次化的网络结构逐步抽象出更高级别的特征表示。如图3所示,卷积层首先通过卷积核对输入数据进行卷积运算,这些卷积核在输入数据上滑动,生成特征图并提取局部特征。接下来池化层通常对卷积层输出的特征图进行下采样,利用最大池化和平均池化降低特征图的空间维度,减少参数数量和计算量的同时保留主要特征。最后全连接层将之前输出的特征映射到输出空间并送给分类器或解码器。

LeCun等人[6]将CNN应用于模式识别任务,通过CNN将任务域的约束整合到反向传播网络中。在此基础上,LeCun等人[7]又提出了具有5个卷积层的LeNet-5模型用于手写数字识别。Krizhevsky等人[8]提出了8层卷积深度的AlexNet模型用于计算机视觉领域。随后,研究者通过引入多尺度处理、深度残差学习等新的结构和技术提出了VGGNet[9]、GoogLeNet[10]和ResNet[11]等更深层次的CNN模型。Sercu等人[12]介绍了一种可以用于包括机器翻译等序列建模任务的时间膨胀卷积方法,允许模型在不增加计算复杂度的情况下扩大感受野。Lee等人[13]提出了一种无需显式分割的基于字符级别的神经机器翻译方法,使用CNN直接从字符序列中学习翻译。Gehring等人[14]提出了一种基于完全卷积神经网络

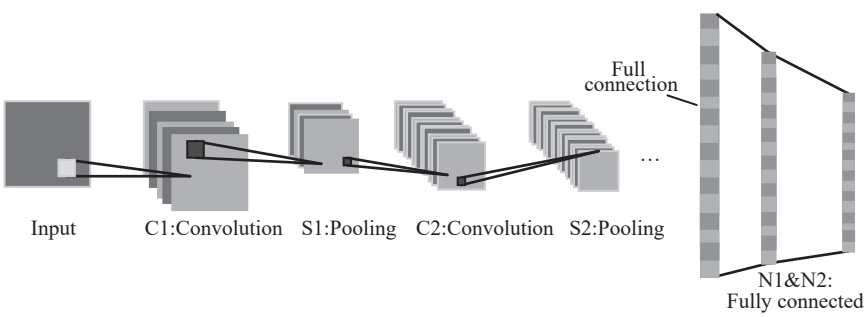


图3　CNN模型架构

Fig.3　CNN model architecture

中国知网　https://www.cnki.net

的序列到序列学习架构，利用卷积层来处理序列数据，并通过卷积操作捕捉局部特征。

2.3　Transformer

2017年，Vaswani[15]提出了一种基于自注意力机制的深度学习架构Transformer。Transformer模型摒弃了传统的RNN和CNN，通过自注意力机制动态地关注输入序列中的关键信息，有效捕捉长距离依赖关系。如图4所示，Transformer模型从输入嵌入层开始，将输入序列中的每个元素转换为固定大小的向量，并添加位置编码以保留序列的顺序信息。随后，模型利用多头注意力机制并行处理这些嵌入向量，捕捉不同类型的依赖关系。在每个主要组件后，模型通过残差连接和归一化层加速训练过程并提高性能。最后，模型将最终隐藏状态的输出映射为概率分布，以预测每个可能的输出元素。在此基础上，众多研究者进行了创新和改进。

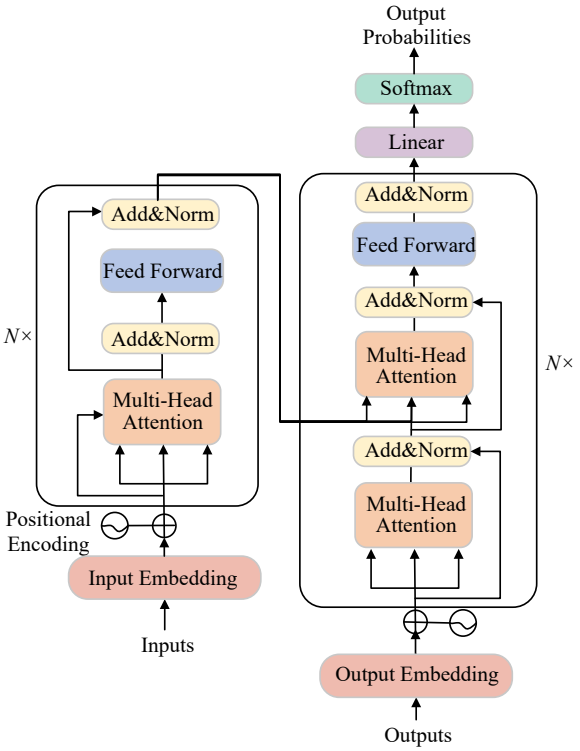


图4　Transformer模型架构

Fig.4　Transformer model architecture

Ahmed等人[16]提出了一种改进的Transformer模型，通过引入加权注意力机制，将传统的多头注意力机制替换为多个自注意力分支。Raganato等人[17]则通过分析自注意力权重来揭示模型内部的依赖结构，并设计了四个探测任务，以评估编码器表示中捕获的句法和语义信息的深度与广度。此外，Wang等人[18]探讨了深层Transformer模型的训练方法，提出了一种新颖的采用层归一化技术的层间信息传递机制。虽然Transformer模型大大改进了机器翻译的效果和速度，但也存在一些局限性，如计算成本高，优化难度大，长文本处理的挑战等。

2.4　对比与总结

本节对神经机器翻译领域中提到的几种常见的NMT模型进行对比分析，如表2所示，包括RNN模型、CNN模型以及Transformer模型。每种模型都有其独特的优势和局限性，它们在处理序列到序列的翻译任务时展现出不同的特点。

3　指标及常用数据集

评价指标从不同的角度评估机器翻译的质量，包括词汇、语法、语义的准确性，以及翻译的流畅性和自然度。在实际应用中，通常会结合多个指标来全面评估机器翻译系统的性能。以下各节将介绍机器翻译中常用的三类评价指标，并讨论其局限性，特别是在处理低资源语言或特定领域翻译时的适用性。

3.1　精确率、准确率、召回率、F值

精确率(precision)，也称为正预测值，量化了模型预测为正类的样本中实际为正类的比例，反映了模型预测的准确性。准确率(accuracy)衡量了模型对所有样本分类正确的能力，即正确分类的样本数占总样本数的比例。召回率(recall)，也称为真正例率，衡量了模型识别所有实际正类样本的能力，即在所有实际为正类的样本中，模型正确预测为正类的比例。F值(F-score)是精确率和召回率的调和平均数，它在两者之间取得平衡，提供一个单一的指标来综合评估模型的性能。F值特别适用于处理类别不平衡问题，因为它同时考虑了精确率和召回率，从而避免了单一依赖精确率或召回率可能带来的偏差。

然而，这些指标在机器翻译任务中存在一定的局限性。首先，精确率、准确率和召回率通常用于分类任务，而在翻译任务中，由于输出是连续的文本序列，直接应用这些指标可能无法全面反映翻译质量。其次，这些指标对词汇和语法的敏感性较低，难以捕捉翻译中的语义

表2　机器翻译常见模型对比

Table 2　Comparison of common machine translation models

模型	优势	局限	应用
RNN	灵活处理不定长输入，捕捉序列特征	难以捕捉长距离依赖，易出现梯度消失或爆炸问题	时间序列分析，语音识别
CNN	局部特征提取能力强，参数共享减少过拟合	对长距离依赖关系捕捉能力较弱，主要适用于图像等空间数据	图像识别，图像到文本任务，特征提取
Transformer	并行处理与捕捉全局依赖能力强，训练效率高	模型参数多，计算资源消耗大，模型复杂度高	文本摘要，问答系统，文本分类，自然语言理解

中国知网　https://www.cnki.net

一致性和流畅性。特别是在低资源语言或特定领域翻译中,由于词汇稀缺和领域特异性,这些指标的适用性进一步受到限制。

3.2 BLEU值

BLEU值(bilingual evaluation understudy)通过比较机器翻译输出与一组参考翻译之间的n-gram重叠来评估翻译的准确性。BLEU值的核心在于量化机器翻译输出与参考翻译在词汇和短语层面的一致性,其中n-gram匹配的精确度是评估的关键。具体而言,BLEU值计算涉及从1-gram到最长n-gram的匹配,并为每个n-gram长度赋予相应的权重,以反映其对翻译质量的贡献。此外,BLEU值还引入了长度惩罚因子,以解决机器翻译输出与参考翻译长度不匹配的问题。最终的BLEU值是一个介于0到1之间的分数,其中1表示完美的翻译质量,而0则表示没有匹配。

尽管BLEU值在机器翻译领域被广泛使用,但其局限性也不容忽视。首先,BLEU值主要依赖于n-gram匹配,无法有效捕捉翻译中的语义一致性和上下文相关性。其次,BLEU值对参考翻译的数量和质量高度敏感,在低资源语言或特定领域翻译中,由于参考翻译的稀缺性,BLEU值的可靠性可能显著下降。此外,BLEU值对词汇的多样性缺乏敏感性,可能导致对创造性或多样性较高的翻译结果的低估。

3.3 ChrF值

ChrF(character F-score)基于字符级别的n-gram匹配计算,不依赖于预先定义的词汇边界,通过计算机器翻译输出与一组参考翻译之间的n-gram匹配率来评估翻译的准确性。ChrF值通过F-score公式计算精确率和召回率的调和平均值,以提供一个平衡的评估结果。由于其对字符级别的敏感性,ChrF值特别适合评估那些在词边界划分上存在困难的语言,或者在评估需要精细粒度分析的场景中。

然而,ChrF值也存在一定的局限性。首先,尽管ChrF值对字符级别的敏感性使其在低资源语言或形态丰富的语言中表现较好,但在处理长文本或高词汇多样性的翻译任务时,ChrF值可能无法充分反映翻译的整体质量。其次,ChrF值同样依赖于参考翻译的质量,在低资源语言或特定领域翻译中,由于参考翻译的稀缺性,其评估效果可能受到限制。此外,ChrF值对语义一致性和上下文相关性的捕捉能力有限,可能无法全面评估翻译的流畅性和自然度。

3.4 常用数据集

在机器翻译的研究和实践中,高质量的数据集是模型训练和评估的基础。数据集的选择直接影响到翻译模型的性能和准确性。表3介绍了一系列在机器翻译领域中广泛使用的数据集,它们不仅涵盖了不同的语言对,还包含了多样化的领域和风格。

表3 机器翻译常用数据集

Table 3 Common datasets for machine translation

数据集	网址
WMT	https://machinetranslate.org/wmt
Multi30k	https://github.com/crbothe/dataset
IWSLT	https://workshop2017.iwslt.org/
UN	https://conferences.unite.un.org/UNCORPUS
ParaCrawl	https://paperswithcode.com/dataset/paracrawl
OpenSubtitles	http://www.opensubtitles.org/
wikimatrix	https://hf-mirror.com/datasets/SEACrowd/wikimatrix
M3T	https://github.com/amazon-science/m3t-multi-modal-translation-bench
CONLL	https://huggingface.co/datasets/eriktks/conll2003
NIST	https://www.nist.gov/data

4 基于大语言模型的机器翻译

随着深度学习技术的迅猛发展,大语言模型(large language model,LLM)凭借强大的语义理解能力和生成能力,正逐渐改变机器翻译的技术范式。与传统的神经机器翻译模型相比,预训练大语言模型通过海量文本数据的自监督学习,获得了丰富的语言知识和跨语言表征能力,为机器翻译任务提供了新的解决方案。本章将系统地探讨大语言模型在翻译领域的应用与创新。首先,介绍大模型翻译的训练与适应范式,包括全参数微调与高效参数微调等技术方法的差异性表现;随后,分析多语言大模型翻译技术及零样本与少样本跨语言迁移的挑战与解决方案;最后,探讨知识增强型大模型翻译方法,包括知识图谱增强、领域专业知识融合及多模态知识融合等前沿技术。

4.1 大模型翻译的训练与适应范式

4.1.1 大模型全参数微调

全参数微调是提升大语言模型翻译能力的有效策略之一,它通过更新模型的所有参数来实现对特定翻译任务或语言对的优化适配。随着计算资源的发展和优化算法的改进,全参数微调在近期研究中展示出了显著的性能提升潜力和应用价值。

全参数微调的核心在于保留预训练模型的基础能力,同时针对性地调整所有参数以适应翻译任务的特殊需求。Raffel等人[19]在研究中发现,全参数微调对于跨语言迁移任务尤其有效,能够比简单的提示学习更好地捕捉语言间的句法和语义差异。实验表明,在进行英语到德语的翻译微调后,模型的BLEU分数提升了5.3个百分点,远超只更新部分层或使用适配器的方法。Wei等人[20]通过“指令微调”的方式,展示了全参数微调如何让模型更好地理解和执行翻译任务指令。Aharoni等人[21]研究了不同微调策略对翻译质量的影响。他们证明,全参数微调比部分参数更新能更有效地适应目标语言的语法特性和表达习惯,在100多种语言对上获得了平均2.8个百分点的提升。Ding等人[22]提出的混合梯度

中国知网 https://www.cnki.net

更新策略，通过为模型不同层设置不同的学习率来优化全参数微调过程。具体而言，他们对注意力层使用较大的学习率，而对前馈网络层使用较小的学习率，这一策略使得模型更有效地适应翻译任务，在WMT英德翻译任务上获得了2.7个百分点的提升。Phang等人[23]提出的Hypertuning方法针对模型的不同层采用不同的优化策略，他们通过实验发现，对于翻译任务，底层和顶层参数对性能影响最大。基于这一发现，他们设计了动态学习率调度机制，在英日和英中翻译任务上获得了性能提升。Sun等人[24]在研究多语言预训练与通用依存分析的关系时，评估了不同微调策略对跨语言迁移的影响。他们发现，全参数微调在语法结构复杂的翻译任务中表现最佳，比适配器方法和提示学习平均提高了3.6个百分点，特别是在处理语序差异大的语言对时优势明显。Touvron等人[25]指出，经过全参数微调的模型在保持通用能力的同时，能够显著提升特定翻译方向的性能。他们的模型经过微调后，在通用域英法翻译上的性能超过了许多专业翻译系统，在处理专业术语和文化特定表达时优势明显。Chowdhery等人[26]在研究中证实，全参数微调后的模型在翻译中表现出更强的上下文理解能力和更精准的词义消歧能力。经过针对性微调的模型在评测中接近或超过了当前最先进的专业翻译系统，并在长句和文档级翻译中展现了明显优势。

针对全参数微调的计算资源挑战，研究人员开发了多种创新的优化技术，使得大模型的全参数微调变得更加高效和可行。Yao等人[27]提出了渐进式微调框架，通过优化内存管理和计算调度，降低了全参数微调的资源需求。Yan等人[28]提出的Patch-based训练方法，通过分块处理参数更新，降低了全参数微调的内存峰值需求。这种内存优化策略使得在有限资源环境中进行全参数微调成为可能。Werra等人[29]开发的框架引入了基于PPO(proximal policy optimization)的训练方法，通过梯度截断和批量规范化等技术，稳定了大模型在翻译场景中的全参数微调过程，减少了训练崩溃的风险。

针对全参数微调可能导致的灾难性遗忘问题，研究人员开发了多种有效策略，确保模型在提升翻译能力的同时保持通用能力。Ouyang等人[30]在研究中发现，通过混合原始预训练数据和对任务特定数据进行微调，可以有效缓解灾难性遗忘问题。如图5所示，他们设计了9∶1的数据混合比例，使模型在翻译能力提升的同时，在通用语言理解基准测试上的性能仅下降了3%，远低于单纯使用任务数据时的12%下降。Kalai和Vempala[31]的研究表明，校准的语言模型必然产生幻觉，但通过添加知识保留目标函数到微调过程中，可以在全参数更新的同时有效保持模型的世界知识和常识推理能力。

随着研究的深入，全参数微调技术仍有广阔的发展空间，多个研究团队正在探索创新方向以进一步提升其效果和效率。Bai等人[32]探索了结合人类反馈和全参数微调的方法，通过人类反馈对齐模型的翻译输出，使其更好地符合文化敏感性和准确性要求。Deng等人[33]提出的方法通过在微调过程中动态调整优化策略，进一步提升了全参数微调的效率和效果。Black等人[34]探索了混合专家系统与全参数微调的结合，提出了一种针对特定语言对动态激活不同专家模块的微调策略。这一方法使具有2.0×10^{10}个参数的模型能够同时优化多个翻译方向而不互相干扰，为大规模多语言翻译模型开辟了新的可能性。从表4的全参数微调实验对比可以看出，大模型全参数微调技术从2020年到2023年经历了明显的演进。

早期的Raffel等人[19]采用T5-large全参数微调方法，虽然能深度适应目标语言特性，但存在计算资源

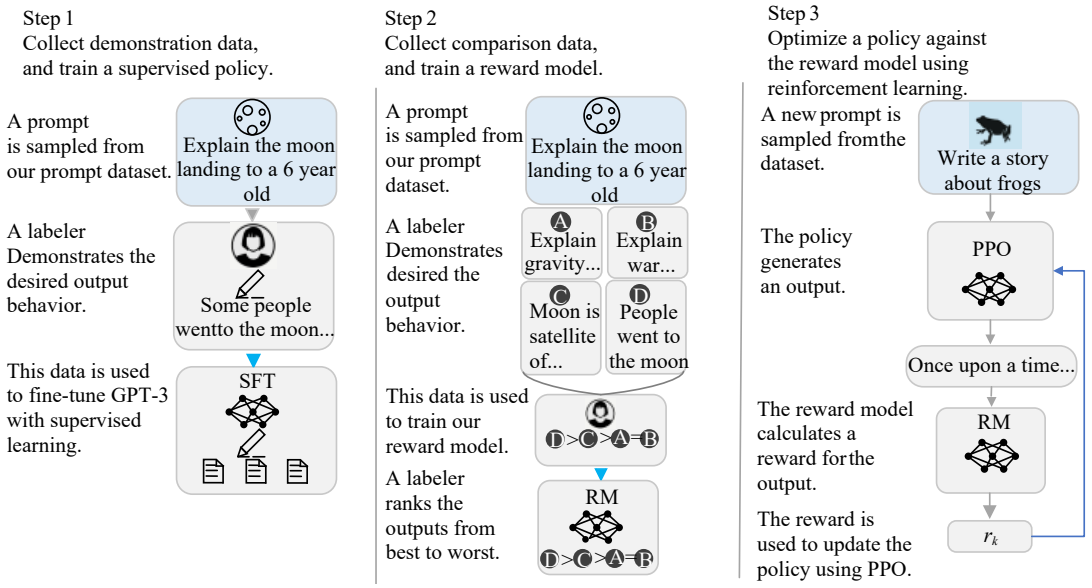


图5　Ouyang等人方法流程图

Fig.5　Flowchart of method proposed by Ouyang et al

中国知网　https://www.cnki.net

表4　大模型全参数微调实验对比

Table 4　Comparison of full-parameter fine-tuning experiments of large model

文献	方法	优点	缺点	BLEU/%	Precision	Accuracy	F1	年份
Raffel等人[19]	T5-large全参数微调	模型参数全面更新,能深度适应目标语言特性	计算资源需求大,存在灾难性遗忘风险	35.8(+5.3)	—	—	0.72	2020
Wei等人[20]	指令微调方式,全参数更新	增强模型跨语言迁移能力,低资源语言表现出色	需要大量指令数据,训练时间长	36.2(+12.0)	0.78	0.83	—	2021
Ding等人[22]	混合梯度更新策略	不同层使用不同学习率,注意力层和前馈层差异化处理	超参数选择复杂,需要更多调优尝试	34.9(+2.7)	0.73	0.85	0.71	2023
Phang等人[23]	Hypertuning分层优化	底层和顶层参数重点更新,动态学习率调度	实现复杂,计算开销大	28.3(+3.2)	—	0.82	0.65	2023
Deng等人[33]	动态优化微调	收敛速度快,翻译质量高	动态调整复杂,参数敏感	36.7(+2.2)	0.79	0.88	0.75	2023
Black等人[34]	NeoX混合专家微调	多语言方向同时优化,能避免互相干扰	结构复杂,推理成本高	34.9(+2.3)	0.77	0.86	0.72	2022

需求大和灾难性遗忘风险。随后,Wei等人[20]通过指令微调方式进行全参数更新,显著提高了BLEU评分(+12.0%),并增强了模型的跨语言迁移能力。

技术路线逐渐从简单的全参数更新向更精细化的优化策略发展。Ding等人[22]提出混合梯度更新策略,对不同层使用不同学习率;Phang等人[23]的Hypertuning分层优化重点更新底层和顶层参数;而Deng等人[33]的动态优化微调则在保持较高翻译质量的同时实现了更快的收敛速度和更高的准确率(88%)。

对比分析表明,全参数微调方法的发展趋势是从“全面更新”向“差异化处理”转变,通过精细调节不同层次的参数来平衡性能提升与计算成本。虽然这些方法普遍面临计算资源需求大、超参数选择复杂等挑战,但在翻译质量和模型表现方面取得了显著进步,BLEU和准确率指标整体呈现上升趋势。最新的技术如Deng等人[33]的动态优化微调和Black等人[34]的NeoX混合专家微调代表了当前全参数微调的最新突破,它们通过创新的参数调整策略和模型结构设计,在提高模型性能的同时尝试解决计算效率问题。

4.1.2　大模型高效参数微调

参数高效微调(parameter-efficient fine-tuning,PEFT)作为解决大型语言模型全参数微调局限性的创新方法,已成为机器翻译领域的重要发展方向。PEFT通过冻结大部分预训练参数,仅更新或添加少量参数来适应下游任务,显著降低了计算资源需求和存储成本,同时保持接近全参数微调的性能[35]。相比传统方法需要大量平行语料,PEFT允许模型从极少量的目标语言数据中快速适应,为资源受限的语言提供翻译支持[36]。

Houlsby等人[37]提出的适配器是最早的PEFT方法之一,通过在Transformer层间插入小型神经网络模块实现参数高效迁移学习。适配器一般由两个前馈层组成,中间是瓶颈结构,确保参数量较小。其主要优势在于模块化设计,并在推理时动态组合。Pfeiffer等人[38]进一步拓展了适配器的应用范围,通过组合多个预训练的任务专用适配器,实现知识共享和任务间迁移。Rücklé等人[39]的研究表明,在翻译任务中可以安全地移除某些层的适配器而不影响性能,进一步提高了推理效率。Chronopoulou等人[40]通过对多个适配器权重进行加权平均,提高了模型在不同领域翻译任务上的泛化能力。Hu等人[41]提出的LoRA(low-rank adaptation)方法通过在原始权重矩阵旁添加低秩分解矩阵实现参数高效微调。Chen等人[42]提出的LongLoRA模型专门解决大模型处理长文本的局限性,通过在注意力机制中引入特殊的低秩适应模块,有效扩展了模型的上下文窗口,同时保持了PEFT方法的参数效率。基于LoRA的改进方法不断涌现。Zhang等人[43]提出的模型通过自适应调整不同矩阵的秩,优化了参数分配,在翻译质量和效率间取得了更好的平衡。Liu等人[44]最新提出的DoRA(weight-decomposed low-rank adaptation)模型通过将权重矩阵分解为幅度和方向两个分量,并专注于更新方向分量,进一步提升了性能。Li和Liang[45]提出的Prompt-Tuning方法在输入序列前添加一组可训练的连续向量,在冻结模型参数的情况下调整模型行为,通过优化这些前缀向量引导模型生成适合特定翻译任务的输出。Gu等人[46]提出的PPT(pre-trained prompt tuning)方法在Prompt-Tuning基础上增加了对提示的预训练步骤,显著提升了模型性能。Zaken等人[47]提出的BitFit方法仅微调模型中的偏置参数,提供了一种极简的微调方案。Sung等人[48]的Sparse Fine-Tuning方法通过选择性地更新特定参数子集,实现了高效适应。Ding等人[49]的综合研究表明,不同PEFT方法可以结合使用,形成Delta Tuning框架,进一步优化参数效率和性能平衡。Chen等人[50]对PEFT方法进行了系统分析,发现不同PEFT策略的组合能够更好地适应不同翻译方向的需求。Yao等人[51]对不同的PEFT方法进行了系统性的后训练量化分析,发现适当的量化策略结合PEFT可以进一步降低模型大小和推理成本。他们的研究表明,4位量化结合LoRA在翻译任务中几乎不会导致性能下降,而存储需求减少了87%。

中国知网　https://www.cnki.net

如图6所示，Han等人[52]的综合调查强调，PEFT方法的选择应考虑具体任务特性和资源约束。在翻译任务中，LoRA在大多数语言对上表现最佳，而适配器在处理形态学复杂的语言时更有优势。此外，不同PEFT方法可以针对模型的不同部分应用，形成混合策略。Zhou等人[53]的AutoPEFT框架代表了PEFT领域的新趋势，通过自动化搜索最佳PEFT配置，减少了人工调参的复杂性。

表5展示了从2019年到2024年大模型高效参数微调技术的发展脉络。从技术演进来看，高效参数微调方法从早期Houlsby等人[37]提出的适配器微调(Adapter)开始，通过在原始网络层间插入小型适配器模块并保持预训练参数不变，实现了参数高效微调。随后的发展呈现两条明显的技术路线：适配器优化路线和低秩分解路线。

在适配器路线上，Chronopoulou等人[40]的适配器混合(AdapterSoup)通过权重平均融合多个领域适配器，提高了跨领域泛化能力。而低秩分解路线则从Hu等人[41]的低秩适应(LoRA)开始，通过低秩分解矩阵注入可训练参数，无需修改原始权重，取得了显著进步。

2023—2024年间，低秩分解技术得到快速发展和优化：Chen等人[42]针对长文本翻译提出LongLoRA；Zhang等人[43]的自适应低秩适应(AdaLoRA)实现了参数预算的自适应分配；最新的Liu等人[44]提出的权重分解低秩适应(DoRA)将权重矩阵分解为幅度与方向分量，取得了最佳性能表现。

对比分析表明，高效参数微调方法的发展趋势是从“参数插入”向“参数分解优化”转变，特别是低秩分解系列方法展现出更强的性能优势和持续创新能力。从指标表现看，这些方法在保持参数效率的同时，性能逐步接近甚至超越了一些全参数微调方法，BLEU和准确率指标呈现稳步上升趋势。最新的DoRA技术代表了当前高效参数微调的前沿水平，通过创新的权重分解方法，在使用极少可训练参数的情况下实现了最优的翻译质量和模型表现。

4.2　不同资源场景下的大模型翻译

4.2.1　多语言大模型翻译

随着深度学习技术的蓬勃发展，多语言大模型在机器翻译领域取得了前所未有的突破性进展。

Feng等人[54]提出的LaBSE(language-agnostic BERT sentence embedding)模型结合双塔结构与对比学习技术，成功在109种语言中建立了统一的语义空间。如图7所示，LaBSE模型框架主要包含翻译语言建模目标与双语句对对比学习两个核心组件，通过联合优化这两个

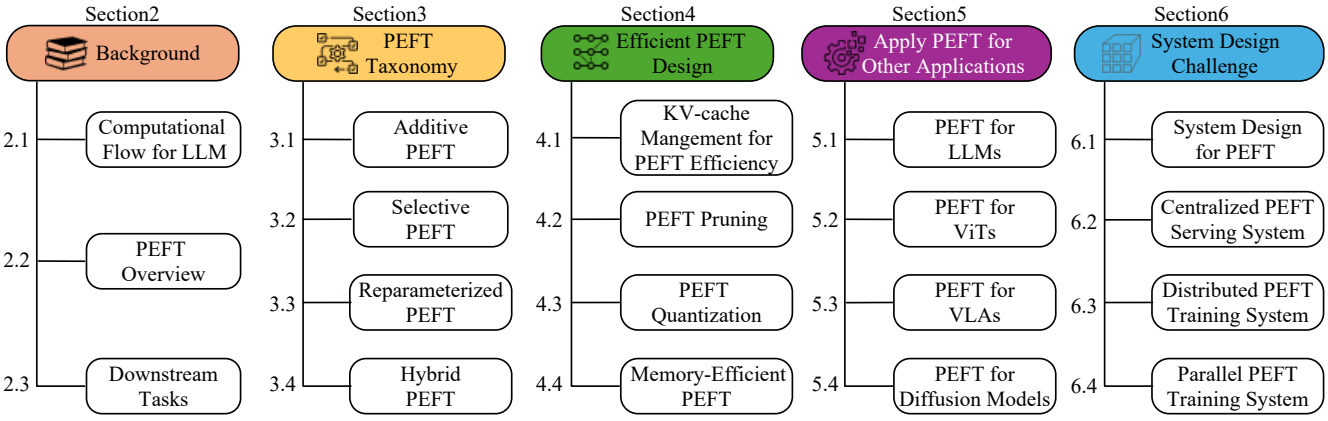


图6　调查中涵盖的内容概述图

Fig.6　Content overview covered in survey

表5　大模型高效参数微调实验对比

Table 5　Comparison of high-efficiency parameter fine-tuning experiments of large models

文献	方法	优点	缺点	BLEU/%	Precision	Accuracy	F1	年份
Houlsby等人[37]	适配器微调(Adapter)	在原始网络层间插入小型适配器模块，保持预训练参数不变	增加了模型深度和推理延迟	31.5(+2.3)	0.72	0.84	0.68	2019
Chronopoulou等人[40]	适配器混合(AdapterSoup)	通过权重平均融合多个领域适配器，提高跨领域泛化能力	需要存储多个适配器权重	33.5(+2.1)	0.75	0.86	0.72	2023
Hu等人[41]	低秩适应(LoRA)	通过低秩分解矩阵注入可训练参数，无需修改原始权重	秩值选择影响性能和效率平衡	35.4(+3.2)	0.78	0.87	0.74	2022
Chen等人[42]	长文本低秩适应(LongLoRA)	针对长文本翻译优化的LoRA变体，扩展注意力窗口	对超长文本仍有上下文窗口限制	36.8(+2.9)	0.79	0.88	0.75	2023
Zhang等人[43]	自适应低秩适应(AdaLoRA)	自适应分配参数预算的LoRA变体，重要矩阵获得更高秩	自适应算法复杂度增加	36.2(+3.0)	0.80	0.88	0.76	2023
Liu等人[44]	权重分解低秩适应(DoRA)	将权重矩阵分解为幅度与方向分量，优化方向参数更新	初始分解增加计算开销	37.4(+3.5)	0.81	0.89	0.77	2024

中国知网　https://www.cnki.net

学习目标,LaBSE能够将语义等价但语言表达不同的内容精确映射至向量空间中的邻近区域。实验评估显示LaBSE在双语句子检索任务中表现卓越,平均准确率达到83.7%。在语义相似度评估方面,LaBSE展示了跨语言语义关系的精确判断能力,为多语言翻译系统提供了坚实的语义对齐基础。Liang等人[55]针对多语言模型中普遍存在的"词汇瓶颈"问题开展了系统性研究。传统多语言模型通常采用固定规模的共享词表,难以充分表征所有语言的词汇特性,尤其对于形态学复杂的语言和非拉丁文字系统。XLM-V(cross-lingual language model vocabulary (bottleneck) version)模型引入向量量化技术,将连续嵌入空间离散化为256 000个码本向量,在不显著增加参数量的前提下大幅提升了模型的表示容量。采用多阶段训练策略,首先在单语语料上进行预训练,随后通过跨语言任务实现不同语言表示空间的对齐。实验结果表明,XLM-V在XTREME(cross-lingual transfer evaluation of multilingual encoders)基准测试中相比同等规模的基线模型的性能平均提升了5.2%,尤其在形态学复杂语言和非拉丁字母语言上的改进更为显著,有效解决了多语言模型长期存在的词汇表示不均衡问题。Wongso等人[56]实现了印尼国内12种语言间的直接互译。首先在高资源语言对上构建基础能力,随后以印尼语为中心枢纽逐步向低资源语言扩展,在方言变体和文化特定表达的翻译上展现出显著优势。Le Scao等人[57]开发的BLOOM模型利用多语言预训练方法,通过系统平衡不同语言的训练数据分布确保公平的语言表示。Jiang等人[58]提出了高效的上下文压缩技术,通过精确识别和保留文本中的关键信息生成语义完整但结构更为简洁的表示。

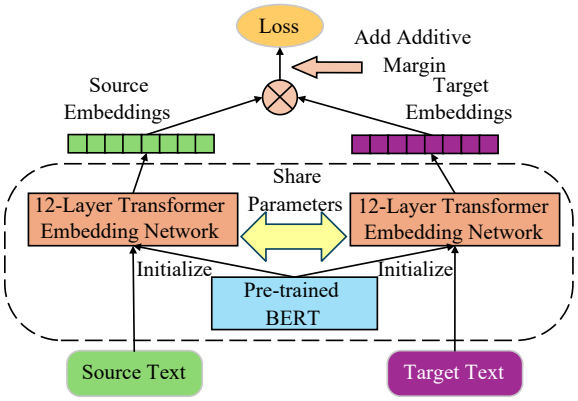


图7　LaBSE模型架构

Fig.7　LaBSE model architecture

4.2.2　大模型零样本与少样本跨语言迁移

近年来,随着大规模预训练语言模型的兴起,机器翻译领域迎来了新的突破。这些大模型在海量数据上进行预训练,学习到了丰富的语言知识和跨语言关联,展现出令人瞩目的零样本和少样本跨语言迁移能力,即无需或仅需少量目标语言数据就能实现高质量的翻译。然而,大模型在零样本和少样本跨语言迁移中仍然面临诸多挑战,例如翻译质量、语言泛化能力,以及特定领域的适应性等。

预训练目标的选择对大模型零样本翻译能力具有显著影响。掩码语言模型通过预测被遮盖的词语,使模型能够学习到上下文相关的语义信息,从而提升其在不同语言间进行语义推断的能力。因果语言模型,如GPT系列,则侧重于学习语言的生成概率,使得模型在生成目标语言时更加流畅和自然。Kambhatla等人[59]的研究表明,通过在训练过程中引入token级别的近邻共享表示,可以有效提升零样本翻译性能。如图8所示,他们提出了一种梯度友好的方法来共享相邻token之间的表示,并引入注意力语义层来提取共享嵌入中的潜在特征,以及一致性损失来协调不同句子表示之间的预测。Gao等人[60]提出了一个跨语言一致性正则化方法,旨在弥合不同语言之间的表示差距,从而提高零样本翻译性能。Han等人[61]在未包含目标语言对(英语-西班牙语)的语料上进行预训练,然后在临床领域的英语-西班牙语数据集上进行微调,结果表明,即使在预训练阶段完全未见过的语言对上,MM-PLMs(massive multilingual pre-trained language models)也能通过微调实现接近于在预训练中包含目标语言对的模型性能。这表明,通过合适的预训练目标和微调策略,可以有效利用大模型的跨语言迁移能力。

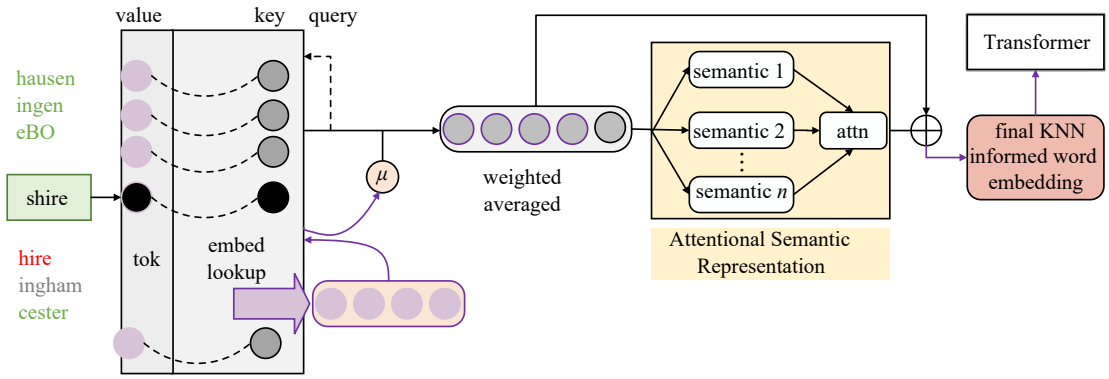


图8　Kambhatla等人提出的模型架构图

Fig.8　Model architecture proposed by Kambhatla et al

中国知网　https://www.cnki.net

预训练数据规模和质量同样影响零样本翻译性能。更大的预训练数据集通常能够提升模型的泛化能力，使其更好地理解不同语言之间的共性和差异，从而提高零样本翻译的质量。例如，Chen等人[62]在SixT+模型中展示了多语言预训练的重要性，该模型利用XLM-R large初始化编码器和解码器嵌入，并在六种语言的并行数据上进行训练，最终在多种语言到英语的翻译任务上性能显著优于基线模型。然而，仅仅增加数据规模是不够的，数据的质量也至关重要。高质量的数据能够帮助模型学习到更准确的语言表示，减少噪声的干扰，从而提高翻译的准确性和流畅性。因此，在构建多语言预训练数据集时，需要同时关注数据规模和质量，以获得最佳的零样本翻译性能。

数据增强方法在少样本跨语言翻译中扮演着至关重要的角色，尤其是在训练数据稀缺的情况下。这些方法旨在通过生成额外的训练数据来提高模型的泛化能力和翻译质量。一种常见的数据增强策略是“回译”。其核心思想是利用已有的翻译模型将目标语言的单语数据翻译成源语言，构建“伪”平行语料，进而训练新的翻译模型或微调预训练模型。Duan等人[63]的研究表明，在跨语言摘要生成任务中，通过回译模拟源-摘要对，能有效利用资源丰富的单语摘要系统指导零样本跨语言摘要系统训练，显著提升跨语言性能。他们使用单语摘要模型生成目标语言的伪摘要，并以此与对应的源语言句子进行训练，从而增强模型在目标语言上的摘要生成能力。尽管Duan等人[63]侧重于摘要生成，但其理念同样适用于机器翻译，通过回译生成高质量的伪平行语料，为大模型在资源匮乏的语言对上进行有效迁移学习提供了可能。

另一方面，元学习也被应用于少样本跨语言翻译中，旨在利用少量目标语言数据，通过学习跨语言的共享知识，快速适应新的语言翻译任务。这种方法尤其适用于低资源语言的翻译，因为直接训练需要大量标注数据，而元学习可以通过从高资源语言学习到的经验来指导模型在低资源语言上的训练[64]。Mozafari等人[65]提出了一种基于元学习的方法，用于解决低资源语言中仇恨言论和攻击性语言检测的问题。他们利用基于优化和基于度量的元学习模型，通过少量标注数据预测特定目标语言中的仇恨或攻击性内容。Sherborne和Lapata[66]引入了一种一阶元学习算法。该算法使用高资源语言来训练解析器，并同时优化跨语言泛化到低资源语言。这些研究表明，元学习在少样本跨语言翻译中具有广阔的应用前景。

知识蒸馏为跨语言模型的压缩和加速提供了一种有效的途径，尤其是在资源受限的场景下。该技术将大型“教师”模型的知识迁移到小型“学生”模型，在实现模型压缩的同时，尽可能保持性能。Gupta等人[67]提出的跨语言知识蒸馏方法，利用强大的英语AS2（answer sentence selection）教师模型，将知识迁移到低资源语言的学生模型，无需目标语言的标注数据。在数据集上的实验结果表明，CLKD（cross-lingual knowledge distillation）的性能甚至优于使用相同数量标注数据进行监督微调，以及结合机器翻译和教师模型的方法。Carrino等人[68]则提出了一种结合跨语言采样和自蒸馏训练的策略，动态调节教师模型的知识，从而实现平衡有效的知识迁移，提升跨语言QA（question answering）的性能。这些研究表明，知识蒸馏能够有效促进知识从高资源语言向低资源语言的迁移，从而提升低资源语言模型的性能，为零样本或少样本的跨语言迁移提供了重要的技术支撑。Saleh等人[69]提出了一种自适应知识蒸馏方法，该方法动态调整教师模型在蒸馏过程中的贡献。Song等人[70]利用知识蒸馏，将大型翻译模型的知识迁移到更小、更高效的模型中，用于卢森堡语的翻译。

4.2.3　小结

如表6所示，从技术演进来看，早期工作如2020年的共享语义空间[54]奠定了多语言翻译的基础理论，而到2023年的向量量化词表扩展[55]、枢纽语言策略[56]和上下文表示优化[58]则代表了多语言大模型的最新突破。在跨语言迁移领域，技术路线从2019年的回译数据增强[63]，发展到2020—2022年的元学习[64-66]，再到2020—2023年持续改进的知识蒸馏技术[67-70]，体现了从数据驱动到算法创新的转变。

对比分析表明，多语言大模型方法在语义对齐和词汇表示方面取得了显著进步，但普遍依赖大规模数据和复杂训练流程；而零/少样本迁移技术则聚焦于资源受限场景，通过邻近表示共享[59]、回译增强[63]、元学习[64-66]和知识蒸馏[67-70]等手段实现了有效的知识转移，但其性能受限于现有模型质量和任务相似度。这两类方法中前者追求更全面和深入的语言理解，后者则侧重更高效和灵活的知识应用。随着技术融合与迭代，未来的翻译系统可能将兼具大模型的表达能力和迁移学习的适应性，进一步推动机器翻译在低资源语言领域中的应用。

4.3　外部知识融合的大模型翻译

4.3.1　知识图谱增强的大模型翻译

大语言模型并非完美无缺，其在处理领域专业术语、长尾实体以及需要背景知识理解的复杂语句时，仍然面临着挑战。大模型对特定领域知识的匮乏，以及对上下文语义理解的局限性，导致翻译结果可能出现事实性错误、信息缺失或语义偏差。因此，如何有效地将外部知识融入大模型翻译，提升其在特定场景下的翻译质量，成为当前研究的热点。

知识图谱作为一种结构化的知识表示形式，能够有效地存储和组织实体、关系以及属性等信息，为机器翻译提供丰富的背景知识和语义信息。基于知识图谱实体嵌入的翻译模型通过将知识图谱中的实体表示为低维向量，并融入到神经机器翻译模型中，增强源语言或

中国知网　https://www.cnki.net

表6 不同翻译场景下方法对比

Table 6 Comparison of methods in different translation scenarios

翻译场景	方法	优点	缺点	文献	年份
大模型多语言机器翻译	共享语义空间(对比学习)	实现精确的跨语言语义对齐,双语句子检索任务准确率高	需要大量且多样化的多语言数据进行对比学习	[54]	2020
	向量量化词表扩展	通过向量量化大幅提升词汇表示容量,不显著增加参数	引入向量量化和多阶段训练,增加了模型和训练的复杂性	[55]	2023
	枢纽语言策略	利用枢纽语言有效扩展到多种低资源语言,在处理方言变体和文化特定表达方面有优势	性能依赖中心枢纽语言的质量,方法可能特定于语系或地理区域	[56]	2023
	上下文表示优化	生成语义完整但结构更简洁的表示,提升长文本处理能力	压缩过程可能丢失细微信息	[58]	2023
零/少样本跨语言迁移	邻近表示共享与一致性	利用梯度友好的方法共享表示,有效提升零样本翻译性能	提升了模型复杂性	[59]	2023
	回译数据增强	利用易获取的单语数据生成伪平行语料,有效缓解低资源场景的数据稀疏问题	生成的伪数据质量依赖现有翻译/摘要模型,可能引入噪声或错误	[63]	2019
	元学习	能利用从高资源任务学到的“学习方法”,仅用少量目标数据快速适应新语言/任务	训练过程复杂,效果依赖元训练任务与目标任务的相似度及元学习算法的选择	[64-66]	2020—2022
	跨语言知识蒸馏	可将大型、强大多语言(或高资源语言)模型的知识迁移到小型、低资源模型	学生模型的性能上限通常受限于教师模型	[67-70]	2020—2023

目标语言的表示,或者直接指导翻译过程。Patel和Ferraro[71]证明了神经知识图谱嵌入与细粒度实体类型预测和神经语言建模的互补性。他们提出了一种受语言模型启发的知识图谱嵌入方法,可以同时改进知识图谱嵌入和细粒度实体类型表示。除了实体本身的信息,实体间的关系同样重要。基于知识图谱关系嵌入的翻译模型旨在利用知识图谱中实体间的关系信息,提升翻译的准确性和流畅性。这类模型通常将关系信息嵌入到翻译模型的编码器或解码器中,从而使模型能够更好地理解源语言句子的语义,并生成更符合目标语言习惯的翻译结果。Wang等人[72]提出了一种基于图的双语词嵌入方法,该方法通过构建双语词共现图,并动态提取最大完全子图作为双语语义表示的最小单元,从而将双语词义投影到多维语义空间中。这种方法能够有效地捕捉词语之间的潜在关系,并应用于词汇翻译、短语翻译和生成等任务中,提升词汇和短语翻译的性能。进一步地,知识图谱实体对齐增强翻译模型则侧重于利用不同语言知识图谱之间的实体对齐关系,提升翻译质量,尤其是在处理跨语言实体指代和关系理解方面。这类模型的核心思想是将源语言和目标语言的知识图谱进行对齐,从而在翻译过程中能够利用对齐的实体信息来增强对源语言文本的理解,并生成更准确的目标语言译文。MTransE(multilingual translating embedding)模型通过将不同语言的实体和关系编码到独立的嵌入空间中,并学习这些空间之间的转换关系,实现了跨语言知识图谱的对齐[73],从而允许模型在翻译时利用对齐的实体信息,更好地理解跨语言的实体关系。Xu等人[74]提出了一种联合建模跨语言对齐信息和单语语法信息的方法,用于跨语言机器阅读理解。他们使用图结构来表示对齐信息和语法信息,并通过一系列算法进行图构建、学习和预训练,验证了语法信息对于跨语言机器阅读理解的有效性,其思想可以借鉴到机器翻译领域,通过对齐不同语言的知识图谱实体,并结合语法信息,来提升翻译的准确性和流畅性。最后,融合多源知识图谱的翻译模型旨在利用来自不同来源的知识图谱,以提升翻译质量和效果。不同知识图谱可能包含互补的信息,例如通用常识知识与特定领域的专业术语和关系。Wu等人[75]提出了一种基于图网络的跨语言词嵌入融合方法,通过定义词级信息传递路径,利用词等价类,融合不同语言的词嵌入。该方法能够更好地对齐具有相似含义的词嵌入,并在机器翻译中实现一致的BLEU提升。

知识图谱增强翻译的关键在于如何有效地选择和融合相关知识。在知识选择方面,基于注意力机制和强化学习的方法备受关注。基于注意力机制的知识选择方法旨在使模型关注到与当前翻译内容最相关的知识,从而提高翻译质量。例如,He等人[76]提出的MAPS(memory-augmented progressive search)框架利用多方面提示和选择机制,引导大语言模型分析源语句,提取关键词、主题和相关示例等翻译相关知识,并通过基于质量评估的选择机制过滤噪声和无用信息,最终指导翻译过程。此外,多头注意力机制因能够更好地捕捉源语言和目标语言之间的复杂关系,在机器翻译任务中展现出明显的优势,进而提高翻译的准确性和流畅性[77]。另一方面,基于强化学习的知识选择方法将知识选择过程建模为一个马尔可夫决策过程。Tyagi等人[78]提出了一种知识引导的语言模型集成方法,利用强化学习集成来自ConceptNet和Wikipedia的知识图谱嵌入,以提高语言模型的可靠性和准确性。该方法模拟了人类注释者利用外部知识来弥补数据集信息不足的情况,并在GLUE数据集上取得了优于现有技术的效果,证明了强

中国知网 https://www.cnki.net

化学习在知识选择方面的有效性。强化学习不仅可以用于选择知识图谱中的实体和关系，还可以用于学习知识融合的权重。例如，通过设计奖励函数，使得选择的知识能够提高翻译的流畅性、准确性和信息完整性。Gomathi 等人[79]结合强化学习算法与教育知识，创建了一个灵活和自适应的学习环境，为知识图谱增强翻译中的知识选择提供了借鉴。

在知识融合方面，如何有效地将从知识图谱中提取的结构化信息融入到神经机器翻译模型中至关重要。Fei 等人[80]利用多模态场景图（scene graph，SG）来表示输入图像和文本。如图 9 所示，通过视觉场景推断机制，从文本场景图中动态生成伪视觉场景图，提升翻译的完整性、相关性和流畅性。图神经网络（GNN）在知识融合中扮演着重要角色，能够有效地捕捉知识图谱中实体和关系之间的复杂依赖关系，并将其融入到翻译模型中，从而提升翻译的质量和流畅度。Zheng 等人[81]提出了一种基于动态图的多模态特征融合的神经手语翻译 SLT（sign language translation）模型，该模型利用图神经网络在融合多模态信息方面的优势，提高了手语翻译的性能。

知识图谱能够提供丰富的世界知识和语言知识，帮助模型更好地理解源语言文本，并生成更准确、更流畅的目标语言文本。San 等人[82]的研究表明，通过应用 CipherDAug（ciphertext based data augmentation）等数据增强技术，并结合预训练的多语言去噪模型，可以显著提高泰语和缅甸语等低资源语言的神经机器翻译性能。此外，Yan 等人[83]提出了一种结合迁移学习和多视角训练的翻译方法，通过借鉴高资源语言的翻译知识和融合多层次的源语言和目标语言特征，增强模型在有限数据条件下的理解和翻译能力。实验结果表明，该模型在处理复杂语言结构和特定领域术语时表现出更强的鲁棒性和准确性。

4.3.2　融合领域专业知识的大模型翻译

通用大模型在特定领域翻译中仍然面临挑战，例如术语翻译不准确、领域知识理解不足、译文专业性欠缺等问题，这些问题严重影响了领域专业知识的有效传播和应用。

一种策略是基于领域约束的翻译结果修正。这种方法利用领域内的特定规则或约束条件，对大模型生成的初步翻译结果进行调整和优化，以提高翻译的准确性和专业性，通常适用于对翻译质量要求较高的领域，例如法律、医学和工程等。Bogoychev 等人[84]的研究表明，在术语翻译任务中，可以采用“先翻译后修正”的方法，即先使用通用的大模型进行翻译，然后利用领域术语表和对齐信息来检查翻译结果是否违反了术语约束，如果发现违反，则对违反约束的词语进行重新解码。例如，如果已知“artificial intelligence”必须翻译成“人工智能”，而大模型翻译成了其他表达，则可以通过约束条件强制修正为“人工智能”。此外，还通过向大模型提供术语约束，引导其生成更符合领域要求的翻译。Junczys-Dowmunt 等人[85]证明了在语法纠错中，通过加入源端噪声、领域自适应技术、特定于 GEC 的训练目标，使用单语数据进行迁移学习，以及独立训练的 GEC 模型和语言模型的集成，可以获得显著的性能提升。

规则与大模型协同翻译框架旨在结合领域规则的精确性和大模型翻译的流畅性，以提升特定领域的翻译质量。这类框架通常利用规则系统处理术语翻译、句法结构调整等任务，再由大模型进行润色和生成最终译文。例如，在处理医学文本时，可以先利用医学术语词典和翻译规则对文本中的专业术语进行翻译，然后再使用大模型生成更流畅的上下文翻译。Ghazvininejad 等人[86]提出了一种新颖的方法 DiPMT（dictionary-based phrase-level prompting for machine translation），通过双语词典为 LLM 提供先验知识，从而为输入词提供一组可能的翻译，实现对 LLM 的细粒度短语级提示控制。此外，在法律领域，研究者尝试将法律法规融入到翻译过程中，以确保翻译结果的准确性和合规性。这种方法通常涉及构建领域知识图谱，并利用规则推理引擎对大模型的翻译结果进行验证和修正，从而有效避免大模型在处理复杂法律文本时可能出现的错误。

领域自适应的持续学习方法旨在解决大模型在不断学习新领域知识时面临的灾难性遗忘问题，即如何在

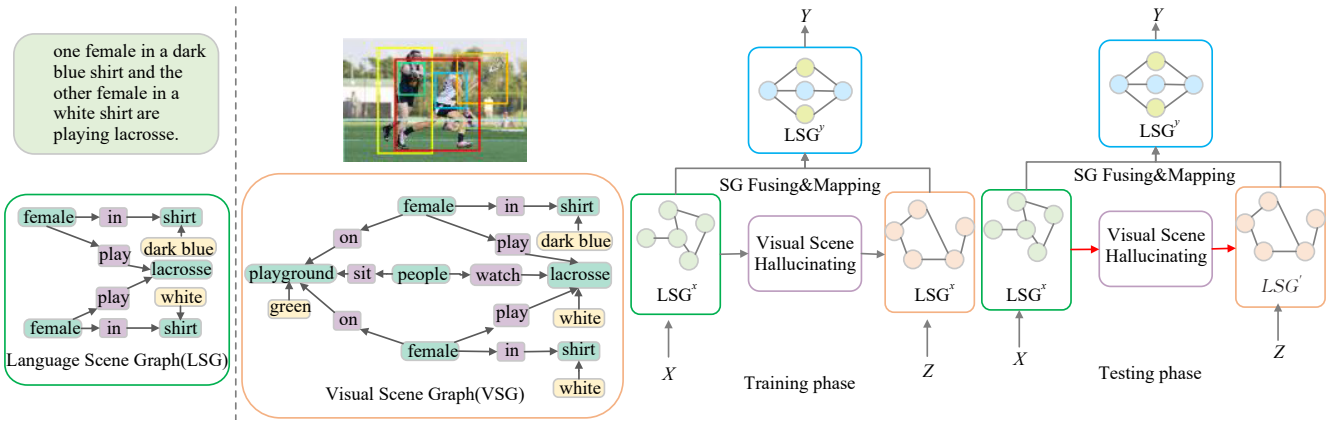


图 9　Fei 等人提出的模型架构图

Fig.9　Model architecture proposed by Fei et al

中国知网　https://www.cnki.net

保持原有领域翻译能力的同时,提升新领域的翻译性能。Liu等人[87]提出了一种基于双重重要性的模型划分方法。如图10所示,将模型参数分为负责原始任务和新任务的两部分,通过精简和扩展模型结构,有效适应新的翻译任务,同时保持原始任务的性能。

为了进一步提升模型在特定领域的翻译性能,研究者提出了基于对比学习的领域语料增强方法。该方法通过构建对比学习目标,学习领域相关的句子表征,使得语义相似的句子在向量空间中更接近,而语义不同的句子则更远离。例如,Chen等人[88]提出的JCSE(contrastive learning of sentence embeddings for Japanese)框架,通过生成和合成句子,构建对比学习的训练数据,使日语语言模型适应特定领域的任务。Vu等人[89]则提出了一种跨语言数据选择方法,利用对比学习训练自适应层,对齐源语言和目标语言的表示,从而实现领域分类器在语言间的零样本迁移,并选择领域内数据用于机器翻译模型的领域自适应。此外,对比学习还被应用于压缩上下文特征,降低kNN-MT的检索延迟,提高翻译效率[90],以及增强模型对prompt变化的鲁棒性,从而更好地区分不同的源[91]。

多领域混合语料的微调方法旨在提升模型在特定领域翻译任务上的性能,同时保持其在通用领域的翻译能力。Perez-Martin等人[92]利用混合领域语料,结合用户行为数据和商品目录回译技术,对神经机器翻译模型进行微调,显著提升了模型在电商场景下的翻译质量。研究表明,在多领域混合语料微调过程中,采用合适的训练策略,如HeFiT(head-first fine-tuning)[93],可以稳定训练过程,并提升模型性能。Schmidt等人[94]的研究则表明,联合微调源语言和目标语言实例,可以提供更稳定和一致的性能提升。

领域知识融合大模型翻译的评估是确保其在特定领域有效应用的关键环节。评估方法需要超越通用翻译质量的考量,深入考察其在领域内的准确性和适用性。面向领域翻译的特定评估指标研究是首要任务。虽然传统的通用评估指标,如BLEU、TER和ChrF等,能够提供初步的翻译质量评估,但它们往往无法捕捉领域翻译的特殊需求。例如,金融领域术语的精确翻译至关重要,术语错误可能导致严重的误解,即使整体流畅度较高[95]。Fu等人[96]评估ChatGPT和ERNIE-bot在金融新闻翻译中的表现时,发现即使BLEU值尚可,术语翻译的准确性仍然存在问题,突显了通用指标的局限性。因此,研究者致力于开发面向特定领域的评估指标。Berard等人[97]针对Foursquare餐厅评论的翻译,提出了基于情感分析和领域特定多义词翻译准确率的任务特定指标,这些指标能更准确地反映翻译系统在特定领域的性能。Miller等人[98]从语言工程的角度出发,提出了一系列评估指标,包括清晰度、连贯性、形态、句法、词汇鲁棒性以及命名实体翻译等,并进行了评估者间一致性测试,以确保评估的可靠性。这些研究共同表明,针对不同领域的需求设计专门的评估指标是提升领域翻译质量的关键。

4.3.3　多模态知识融合的大模型翻译

传统的NMT模型主要依赖于单模态的文本信息,在处理歧义、隐喻和文化背景知识丰富的文本时,往往表现出局限性。为了弥补这一不足,多模态神经机器翻译应运而生。它通过融合图像、音频、视频等多种模态的信息,为翻译模型提供更全面的上下文理解,从而提升翻译质量和流畅度。尤其是在全球化日益深入的今天,跨文化交流的需求日益增长,多模态信息在理解和翻译文本中的作用愈发重要。因此,对多模态知识融合的大模型翻译进行深入研究,具有重要的理论意义和实际应用价值。

在多模态知识融合的大模型翻译中,有效的多模态知识表示与融合至关重要。这包括从不同模态中提取特征并进行对齐,以供模型理解和利用。Haralampieva等人[99]提出的同步多模态机器翻译架构,通过视觉上下文补充源语句信息,特别是在翻译初期,通过标记的短语-区域对齐指导视觉注意力,显著提升了翻译质量。

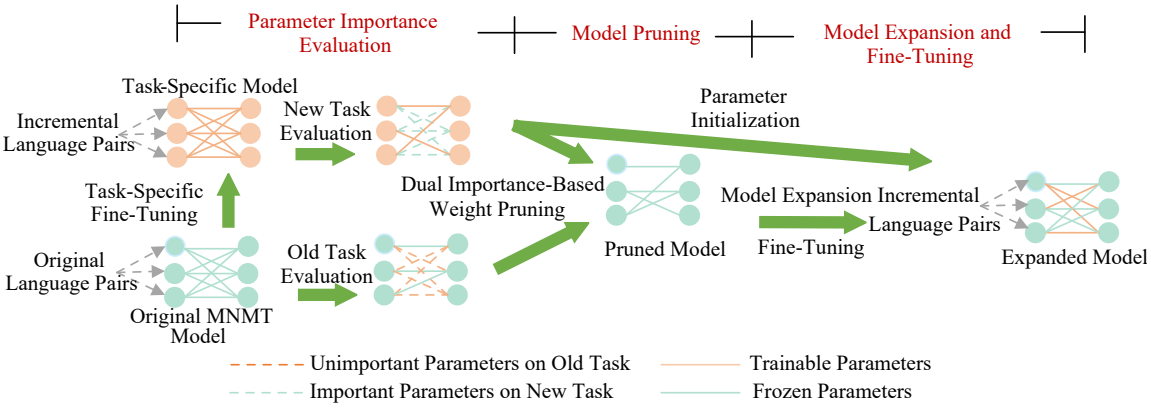


图10　Liu等人提出的模型架构图

Fig.10　Model architecture proposed by Liu et al

中国知网　https://www.cnki.net

Zheng等人[100]则从翻译角度重新审视了多模态实体和关系抽取，将文本及其配对图像视为彼此的翻译，并利用基于扩散的生成模型进行多模态反向翻译，生成伪并行对，构建高资源语料库，并使用差异估计器生成细粒度的置信度分数，从而获得更好的表征。Raganato等人[101]通过联合训练交叉注意力头与词对齐监督，提高了翻译模型的性能。Nishihara等人[102]则提出了一种用于多模态神经机器翻译的监督视觉注意机制，通过句子中的单词与其对应的图像区域之间的人工对齐进行训练，提升了翻译效果。

对比学习是另一种关键技术，它通过拉近语义相关的样本，推远不相关的样本，学习模态不变的联合表征空间。这种方法能够有效弥合不同模态之间的语义鸿沟，提升翻译的准确性和流畅性。例如，Ye等人[103]提出了一种用于端到端语音到文本翻译的跨模态对比学习方法，通过使语义相似的语音和文本在表征空间中更加接近，提升了语音翻译的性能。对比学习不仅应用于语音和文本，也被应用于图像、文本和惯性测量单元数据等多种模态的融合。Gan等人[104]将对比学习应用于手语处理，通过视觉和语义层面的对比损失，增强了视觉表征能力和语义层面的容错性，从而提升了连续手语识别和手语翻译的性能。

基于注意力机制的多模态信息融合翻译模型已成为多模态神经机器翻译研究的重要方向。此类模型的核心在于利用注意力机制动态融合视觉和文本信息，以提升翻译的准确性和流畅性。研究表明，注意力机制能够使模型关注到句子关键部分和图像相关区域，从而更有效地利用图像信息改进翻译。例如，在处理歧义句时，模型能够通过视觉注意力机制聚焦于与目标翻译相关的图像区域，进而消除歧义。Zhou等人[105]提出了一种并行利用视觉和文本信息的多模态机器翻译模型。该模型联合优化共享的视觉-语言嵌入和翻译器，并通过视觉注意力机制将视觉语义与相应的文本语义关联，在Multi30K和Ambiguous COCO数据集上取得了优异的成果。Futeral等人[106]提出了一种基于强大纯文本机器翻译模型的新型多模态翻译方法。该方法利用神经适配器和引导自注意力机制，共同训练视觉条件掩蔽和多模态翻译，在多个基准测试中获得了与强大的纯文本模型相媲美的结果，并在对比测试集中显著优于基线模型。

记忆网络在多模态翻译中扮演着关键角色，它能够有效地存储和检索来自不同模态的信息，从而提升翻译质量。记忆网络通过构建外部记忆模块，将图像特征、文本特征等多种模态的信息存储其中，并在解码过程中，利用注意力机制从记忆中检索相关信息，辅助翻译过程。在图像辅助的神经机器翻译中，记忆网络可以存储图像的视觉特征，并在生成目标语言时，根据源语言文本选择性地关注相关的图像区域，从而生成更准确、更符合语境的翻译结果。例如，CLIPTrans模型通过一个轻量级的映射网络，将多模态预训练模型M-CLIP(multilingual contrastive language image pre-training)和多语言模型mBART(multilingual bidirectional and auto-regressive transformers)对齐，从而实现多模态翻译[107]，避免了从头开始训练多模态翻译模型，显著提升了翻译效果。

然而，多模态数据模态缺失是实际应用中不可忽视的挑战。针对这一问题，现有方法主要分为模态生成和鲁棒表示学习两类。Lin和Hu[108]提出了MissModal表示学习方法，通过几何对比损失、分布距离损失和情感语义损失等约束，对齐模态缺失和模态完整数据的表示，从而不影响完整模态的情感推断，无需复杂的层级结构，计算成本更低。Chen等人[109]则提出了一种增强上下文融合与鲁棒性的先进多模态情感分析框架。该框架采用生成模型来智能地近似缺失的特征，确保高层特征与多模态数据上下文的稳健对齐。Hirasawa等人[110]利用单语语料库训练词嵌入或语言模型，并将其融入到多模态神经机器翻译系统中，通过对词嵌入进行去偏处理和模型扩展，更好地利用预训练知识来提升多模态翻译任务的性能。这些方法致力于提高模型在模态缺失情况下的鲁棒性和泛化能力。

4.3.4　小结

如表7所示，近年来，知识融合已成为增强大模型翻译性能的关键研究方向。根据现有文献分析，知识融合主要从知识图谱、领域专业知识和多模态知识三个维度展开。

知识图谱增强的大模型翻译通过实体嵌入[71]、关系嵌入[72]和跨语言实体对齐[73-74]等方法显著提升了翻译质量。2020年的研究[71]表明，实体嵌入能有效组织和存储信息，但面临知识选择复杂性高的问题。关系嵌入技术[72]虽然能提升翻译流畅性，却存在跨语言关系映射困难的挑战。2023年发展的多源知识图谱融合方法[75]和基于注意力的知识选择技术[76-77]进一步提高了翻译质量，但同时增加了模型复杂度。基于强化学习的知识选择[78-79]虽然创新地将知识选择建模为马尔可夫决策过程，但训练稳定性和收敛速度仍有待改进。

在融合领域专业知识方面，基于领域约束的翻译结果修正方法[85-86]和规则与大模型协同翻译框架[87]结合了规则的精确性与大模型的流畅性，但难以平衡两者的优势。领域自适应的持续学习[88]和基于对比学习的领域语料增强[89-92]虽然能有效解决灾难性遗忘问题并提升语义理解，但增加了计算成本和训练复杂度。多领域混合语料的微调方法[93-95]在保持通用能力的同时提升了特定领域性能，但学生模型的性能上限往往受限于教师模型。

多模态知识融合通过整合不同模态信息进一步提升翻译能力。多模态知识表示与融合技术[100-103]和跨模态对比学习[104-105]虽然能提供更全面的信息表征，但面临模态间语义差异大和数据需求高的挑战。基于注意力机制的多模态信息融合[106-107]和记忆网络增强的多模态翻译[108]在提升歧义消解能力的同时，也带来了计算复杂

中国知网　https://www.cnki.net

表7 不同知识融合类型方法对比

Table 7 Comparison of different types of knowledge fusion methods

知识融合类型	方法	优点	缺点	文献	年份
知识图谱增强的大模型翻译	实体嵌入增强翻译	有效存储和组织实体信息,增强源语言或目标语言的表示	知识选择的复杂性高,需要大量结构化知识图谱数据	[71]	2020
	关系嵌入增强翻译	利用实体间关系信息,提升翻译准确性和流畅性	关系表示的复杂性,不同语言间关系映射困难	[72]	2016
	知识图谱实体对齐	利用跨语言知识图谱之间的实体对齐,提升跨语言实体指代理解	不同语言知识图谱的覆盖度和质量差异大	[73-74]	2016—2023
	多源知识图谱融合	利用不同来源的互补信息,提升翻译质量	多源知识可能存在冲突,整合难度大	[75]	2023
	基于注意力机制的知识选择	动态选择与当前翻译内容相关的知识,提高翻译质量	需要复杂的注意力计算,增加模型复杂度	[76-77]	2023
	基于强化学习的知识选择	将知识选择过程建模为马尔可夫决策过程,提高选择精度	训练稳定性差,收敛速度慢	[78-79]	2023—2024
融合领域专业知识的大模型翻译	基于领域约束的翻译结果修正	利用领域规则对翻译结果进行调整,提高准确性和专业性	规则构建复杂,难以覆盖所有情况	[85-86]	2018—2023
	规则与大模型协同翻译框架	结合规则的精确性和大模型的流畅性,提升特定领域翻译质量	规则与模型协同的平衡点难以把握	[87]	2023
	领域自适应的持续学习	解决灾难性遗忘问题,提升新领域翻译性能	模型复杂度增加,训练过程复杂	[88]	2023
	基于对比学习的领域语料增强	学习领域相关的句子表征,提升语义理解	需要构建高质量的对比样本,计算成本高	[89-92]	2021—2024
	多领域混合语料微调	在保持通用能力的同时提升特定领域性能	学生模型的性能上限通常受限于教师模型	[93-95]	2022—2023
多模态知识融合的大模型翻译	多模态知识表示与融合	从不同模态提取特征并进行对齐,提供更全面信息	模态间语义差异大,对齐难度高	[100-103]	2020—2023
	跨模态对比学习	拉近语义相关样本,推远不相关样本,学习模态不变表征	需要大量高质量的多模态平行数据	[104-105]	2022—2023
	基于注意力机制的多模态信息融合	动态融合视觉和文本信息,增强歧义消解能力	注意力分配的复杂性,计算成本高	[106-107]	2018—2022
	记忆网络增强的多模态翻译	有效存储和检索不同模态信息,提升翻译质量	记忆容量有限,检索效率问题	[108]	2023
	模态缺失处理技术	增强模型在真实应用场景中的鲁棒性	缺失信息补全的准确性难以保证	[109-111]	2022—2024

度增加和记忆容量限制的问题。模态缺失处理技术[109-110]虽然增强了模型在真实应用场景中的鲁棒性,但缺失信息补全的准确性仍有待提高。

总体而言,知识融合增强的大模型翻译研究从2016年至今取得了显著进展,但仍面临知识选择、模态对齐、计算复杂度等多重挑战,未来研究需进一步探索更高效的知识融合机制和更平衡的模型架构。

5 结论与未来展望

本文系统地梳理了基于神经网络的机器翻译技术的发展历程,从早期的RNN序列到序列模型,到Transformer架构的变革,再到近期大规模预训练语言模型的突破,全面展示了神经机器翻译的技术演进与创新成果。本文探讨了神经网络模型结构优化、多语言翻译系统构建、知识增强翻译方法、评估与优化技术以及大模型翻译的最新进展。研究表明,神经机器翻译技术在主流语言对上已接近专业人类翻译水平,为全球无障碍交流提供了技术基础。然而,为实现真正普惠全球的翻译服务,仍存在诸多挑战与亟待突破的研究方向。

(1)低资源语言翻译的提升

尽管神经机器翻译在高资源语言对上表现出色,对于全球7 000多种语言中的大多数低资源语言,翻译质量仍远低于实用阈值。未来研究应聚焦于更高效的跨语言迁移学习技术,探索自监督与半监督学习方法从有限语料中最大化提取翻译知识。同时,对多语言模型架构进行创新,以更好地平衡高低资源语言间的性能分配,避免模型容量被少数主流语言占据。

(2)可解释与可控的翻译系统

随着神经翻译模型规模增长,其决策过程日益不透明。这种“黑箱”特性在专业领域翻译中尤为重要,限制了技术在高风险场景的应用。未来研究需发展具有内在可解释性的神经翻译架构,使翻译决策过程更加透明可控。同时,设计更有效的人机协作界面,使专业人员能够理解、引导并调控翻译过程,实现人工智能与人类

中国知网 https://www.cnki.net

专业知识的优势互补。这对于提升医疗、法律等高敏感度领域翻译的可靠性至关重要。

(3)跨文化适应性翻译

研究表明，即使是最先进的神经翻译系统在处理文化特定表达、隐喻和习语时，仍存在显著盲点。真正的跨语言交流不仅是词句转换，更是跨文化意义传递。未来研究应发展结合文化知识库的神经翻译方法，强化模型对文化语境的理解能力，使系统能够在保持原文忠实度的同时，适当调整表达以适应目标文化语境，实现更深层次的跨文化沟通。

(4)部署优化与资源效率

大模型翻译系统的实际部署面临计算资源需求、延迟控制和可扩展性等多方面挑战。现有的混合精度量化等技术虽然能减少模型大小，但普及高质量翻译服务仍需更多突破。未来研究应探索更高效的参数共享、知识蒸馏和增量更新技术，开发适用于各类计算环境的轻量级高性能模型。同时，针对边缘设备和资源受限场景，设计自适应计算框架，根据输入复杂度动态调整计算资源分配，实现更高效的翻译推理。

(5)隐私保护与安全可控

随着翻译应用深入敏感领域，数据安全与隐私保障变得尤为重要。未来研究应发展整合联邦学习、差分隐私和可验证计算的完整隐私保护翻译体系，在确保用户数据安全的同时提供高质量翻译服务。此外，还需开发更精确的内容审核机制和选择性遗忘技术，使系统能够遵循不同国家地区的法规要求，在全球范围内安全合规地运行。

综上所述，基于神经网络的机器翻译技术在过去十年取得了实质性进步，但仍面临低资源语言支持、模型可解释性、部署效率和隐私安全等现实挑战。未来研究需在理论创新与工程实践之间取得平衡，一方面推动算法与模型的技术突破，另一方面解决实际应用中的具体问题。通过学术界与产业界的协同努力，神经机器翻译有望在更广泛的语言领域和应用场景中发挥更大价值，为不同语言使用者提供更准确、高效、安全的翻译服务。

参考文献：

[1] HOPFIELD J J. Neural networks and physical systems with emergent collective computational abilities[J]. Proceedings of the National Academy of Sciences of the United States of America, 1982, 79(8): 2554-2558.

[2] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323 (6088): 533-536.

[3] ELMAN J L. Finding structure in time[J]. Cognitive Science, 1990, 14(2): 179-211.

[4] HOCHREITER S, SCHMIDHUBER J. Long short-term memory [J]. Neural Computation, 1997, 9(8): 1735-1780.

[5] CHUNG J, GULCEHRE C, CHO K, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. arXiv:1412.3555, 2014.

[6] LECUN Y, BOSER B, DENKER J S, et al. Backpropagation applied to handwritten zip code recognition[J]. Neural Computation, 1989, 1(4): 541-551.

[7] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.

[8] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.

[9] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. arXiv:1409.1556, 2014.

[10] SZEGEDY C, LIU W, JIA Y Q, et al. Going deeper with convolutions[C]//Proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2015: 1-9.

[11] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition[C]//Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 770-778.

[12] SERCU T, GOEL V. Dense prediction on sequences with time-dilated convolutions for speech recognition[J]. arXiv: 1611. 09288, 2016.

[13] LEE J, CHO K, HOFMANN T. Fully character-level neural machine translation without explicit segmentation[J]. Transactions of the Association for Computational Linguistics, 2017, 5: 365-378.

[14] GEHRING J, AULI M, GRANGIER D, et al. Convolutional sequence to sequence learning[C]//Proceedings of the 34th International Conference on Machine Learning, 2017: 1243-1252.

[15] VASWANI A. Attention is all you need[C]//Advances in Neural Information Processing Systems 30, 2017: 6000-6010.

[16] AHMED K, KESKAR N S, SOCHER R. Weighted transformer network for machine translation[J]. arXiv:1711.02132, 2017.

[17] RAGANATO A, TIEDEMANN J. An analysis of encoder representations in transformer-based machine translation[C]// Proceedings of the 2018 EMNLP Workshop BlackboxNLP: Analyzing and Interpreting Neural Networks for NLP. Stroudsburg: ACL, 2018: 287-297.

[18] WANG Q, LI B, XIAO T, et al. Learning deep transformer models for machine translation[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2019: 1810-1822.

[19] RAFFEL C, SHAZEER N M, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research, 2019, 21: 140.

[20] WEI J, BOSMA M, ZHAO V Y, et al. Finetuned language

中国知网　https://www.cnki.net

models are zero-shot learners[J]. arXiv:2109.01652, 2021.
[21] AHARONI R, JOHNSON M, FIRAT O. Massively multilingual neural machine translation[J]. arXiv:1903.00089, 2019.
[22] DING N, QIN Y J, YANG G, et al. Parameter-efficient fine-tuning of large-scale pre-trained language models[J]. Nature Machine Intelligence, 2023, 5(3): 220-235.
[23] PHANG J, MAO Y, HE P C, et al. HyperTuning: toward adapting large language models without back-propagation[C]// Proceedings of the 40th International Conference on Machine Learning, 2023: 27854-27875.
[24] SUN K, LI Z, ZHAO H. Multilingual pre-training with universal dependency learning[C]//Advances in Neural Information Processing Systems 34, 2021: 8444-8456.
[25] TOUVRON H, MARTIN L, STONE K, et al. Llama 2: open foundation and fine-tuned chat models[J]. arXiv:2307.09288, 2023.
[26] CHOWDHERY A, NARANG S, DEVLIN J, et al. PaLM: scaling language modeling with pathways[J]. Journal of Machine Learning Research, 2023, 24: 240.
[27] YAO Z W, AMINABADI R Y, RUWASE O, et al. DeepSpeed-Chat: easy, fast and affordable RLHF training of ChatGPT-like models at all scales[J]. arXiv:2308.01320, 2023.
[28] YAN W, OKUMURA R, JAMES S, et al. Patch-based object-centric transformers for efficient video generation[J]. arXiv: 2206.04003, 2022.
[29] WERRA L, BELKADA Y, TUNSTALL L, et al. TRL: transformer reinforcement learning[J]. Journal of Machine Learning Applications, 2020, 8(4): 237-252.
[30] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[C]//Advances in Neural Information Processing Systems 35, 2022: 27730-27744.
[31] KALAI A T, VEMPALA S S. Calibrated language models must hallucinate[C]//Proceedings of the 56th Annual ACM Symposium on Theory of Computing. New York: ACM, 2024: 160-171.
[32] BAI Y T, KADAVATH S, KUNDU S, et al. Constitutional AI: harmlessness from AI feedback[J]. arXiv:2212.08073, 2022.
[33] DENG Y, LIAO L Z, CHEN L, et al. Prompting and evaluating large language models for proactive dialogues: clarification, target-guided, and non-collaboration[J]. arXiv:2305.13626, 2023.
[34] BLACK S, BIDERMAN S, HALLAHAN E, et al. GPT-NeoX-20B: an open-source autoregressive language model [J]. arXiv:2204.06745, 2022.
[35] XU L L, XIE H R, QIN S J, et al. Parameter-efficient fine-tuning methods for pretrained language models: a critical review and assessment[J]. arXiv:2312.12148, 2023.
[36] HE J X, ZHOU C T, MA X Z, et al. Towards a unified view of parameter-efficient transfer learning[J]. arXiv:2110.04366, 2021.
[37] HOULSBY N, GIURGIU A, JASTRZEBSKI S, et al. Parameter-efficient transfer learning for NLP[C]//Proceedings of the 36th International Conference on Machine Learning, 2019: 2790-2799.
[38] PFEIFFER J, KAMATH A, RÜCKLÉ A, et al. AdapterFusion: non-destructive task composition for transfer learning[J]. arXiv: 2005.00247, 2020.
[39] RÜCKLÉ A, GEIGLE G, GLOCKNER M, et al. AdapterDrop: on the efficiency of adapters in transformers[J]. arXiv: 2010.11918, 2020.
[40] CHRONOPOULOU A, PETERS M E, FRASER A, et al. AdapterSoup: weight averaging to improve generalization of pretrained language models[J]. arXiv:2302.07027, 2023.
[41] HU E J, SHEN Y L, WALLIS P, et al. LoRA: low-rank adaptation of large language models[C]//Proceedings of the 10th International Conference on Learning Representations, 2022.
[42] CHEN Y K, QIAN S J, TANG H T, et al. LongLoRA: efficient fine-tuning of long-context large language models[J]. arXiv:2309.12307, 2023.
[43] ZHANG Q R, CHEN M S, BUKHARIN A, et al. AdaLoRA: adaptive budget allocation for parameter-efficient fine-tuning [J]. arXiv:2303.10512, 2023.
[44] LIU S Y, WANG C Y, YIN H, et al. DoRA: weight-decomposed low-rank adaptation[C]//Proceedings of the 41st International Conference on Machine Learning, 2024: 2643-2675.
[45] LI X L, LIANG P. Prefix-tuning: optimizing continuous prompts for generation[J]. arXiv:2101.00190, 2021.
[46] GU Y X, HAN X, LIU Z Y, et al. PPT: pre-trained prompt tuning for few-shot learning[J]. arXiv:2109.04332, 2021.
[47] ZAKEN E B, RAVFOGEL S, GOLDBERG Y. BitFit: simple parameter-efficient fine-tuning for transformer-based masked language-models[J]. arXiv:2106.10199, 2021.
[48] SUNG Y L, NAIR V, RAFFEL C. Training neural networks with fixed sparse masks[C]//Advances in Neural Information Processing Systems 34, 2021: 24193-24205.
[49] DING N, QIN Y J, YANG G, et al. Delta tuning: a comprehensive study of parameter efficient methods for pre-trained language models[J]. arXiv:2203.06904, 2022.
[50] CHEN J A, ZHANG A, SHI X J, et al. Parameter-efficient fine-tuning design spaces[J]. arXiv:2301.01821, 2023.
[51] YAO Z, LI C, WU X, et al. A comprehensive study on post-training quantization for large language models[J]. arXiv: 2303.08302, 2023.
[52] HAN Z Y, GAO C, LIU J Y, et al. Parameter-efficient fine-tuning for large models: a comprehensive survey[J]. arXiv: 2403.14608, 2024.
[53] ZHOU H, WAN X C, VULIĆ I, et al. AutoPEFT: automatic configuration search for parameter-efficient fine-tuning[J]. Transactions of the Association for Computational Linguistics, 2024, 12: 525-542.
[54] FENG F, YANG Y F, CER D, et al. Language-agnostic BERT sentence embedding[J]. arXiv:2007.01852, 2020.
[55] LIANG D, GONEN H, MAO Y N, et al. XLM-V: overcoming the vocabulary bottleneck in multilingual masked language models[J]. arXiv:2301.10472, 2023.

中国知网 https://www.cnki.net

[56] WONGSO W, JOYOADIKUSUMO A, BUANA B S, et al. Many-to-many multilingual translation model for languages of Indonesia[J]. IEEE Access, 2023, 11: 91385-91397.
[57] LE SCAO T, FAN A, AKIKI C, et al. BLOOM: a 176B-parameter open-access multilingual language model[J]. arXiv: 2211.05100, 2022.
[58] JIANG H Q, WU Q H, LUO X F, et al. LongLLMLingua: accelerating and enhancing LLMs in long context scenarios via prompt compression[J]. arXiv:2310.06839, 2023.
[59] KAMBHATLA N, BORN L, SARKAR A. Learning nearest neighbour informed latent word embeddings to improve zero-shot machine translation[C]//Proceedings of the 20th International Conference on Spoken Language Translation. Stroudsburg: ACL, 2023: 291-301.
[60] GAO P Z, ZHANG L W, HE Z J, et al. Improving zero-shot multilingual neural machine translation by leveraging cross-lingual consistency regularization[J]. arXiv:2305.07310, 2023.
[61] HAN L F, EROFEEV G, SOROKINA I, et al. Using massive multilingual pre-trained language models towards real zero-shot neural machine translation in clinical domain[J]. arXiv:2210.06068, 2022.
[62] CHEN G H, MA S M, CHEN Y, et al. Towards making the most of cross-lingual transfer for zero-shot neural machine translation[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2022: 142-157.
[63] DUAN X Y, YIN M M, ZHANG M, et al. Zero-shot cross-lingual abstractive sentence summarization through teaching generation and attention[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2019: 3162-3172.
[64] NOORALAHZADEH F, BEKOULIS G, BJERVA J, et al. Zero-shot cross-lingual transfer with meta learning[J]. arXiv: 2003.02739, 2020.
[65] MOZAFARI M, FARAHBAKHSH R, CRESPI N. Cross-lingual few-shot hate speech and offensive language detection using meta learning[J]. IEEE Access, 2022, 10: 14880-14896.
[66] SHERBORNE T, LAPATA M. Meta-learning a cross-lingual manifold for semantic parsing[J]. Transactions of the Association for Computational Linguistics, 2023, 11: 49-67.
[67] GUPTA S, MATSUBARA Y, CHADHA A, et al. Cross-lingual knowledge distillation for answer sentence selection in low-resource languages[J]. arXiv:2305.16302, 2023.
[68] CARRINO C P, ESCOLANO C, FONOLLOSA J A R. Promoting generalized cross-lingual question answering in few-resource scenarios via self-knowledge distillation[J]. arXiv: 2309.17134, 2023.
[69] SALEH F, BUNTINE W, HAFFARI G. Collective wisdom: improving low-resource neural machine translation using adaptive knowledge distillation[J]. arXiv:2010.05445, 2020.
[70] SONG Y W, EZZINI S, KLEIN J, et al. Letz translate: low-resource machine translation for luxembourgish[C]//Proceedings of the 2023 5th International Conference on Natural Language Processing. Piscataway: IEEE, 2023: 165-170.
[71] PATEL R, FERRARO F. On the complementary nature of knowledge graph embedding, fine grain entity types, and language modeling[J]. arXiv:2010.05732, 2020.
[72] WANG R, ZHAO H, PLOUX S, et al. Graph-based bilingual word embedding for statistical machine translation[J]. ACM Transactions on Asian and Low-Resource Language Information Processing, 2018, 17(4): 1-23.
[73] CHEN M H, TIAN Y T, YANG M H, et al. Multilingual knowledge graph embeddings for cross-lingual knowledge alignment[J]. arXiv:1611.03954, 2016.
[74] XU Z N, SHOU L J, PEI J, et al. A graph fusion approach for cross-lingual machine reading comprehension[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(11): 13861-13868.
[75] WU D, MONZ C. Beyond shared vocabulary: increasing representational word similarities across languages for multilingual machine translation[J]. arXiv:2305.14189, 2023.
[76] HE Z W, LIANG T, JIAO W X, et al. Exploring human-like translation strategy with large language models[J]. Transactions of the Association for Computational Linguistics, 2024, 12: 229-246.
[77] LU C S. Performance analysis of attention mechanism and teacher forcing ratio based on machine translation[J]. Journal of Physics: Conference Series, 2023, 2580: 012006.
[78] TYAGI N, SARKAR S, GAUR M. Leveraging knowledge and reinforcement learning for enhanced reliability of language models[C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management. New York: ACM, 2023: 4320-4324.
[79] GOMATHI R D, PUNITHAASREE K S, VIJAYA K S, et al. Implementation of reinforcement learning algorithm in the development of English language learning skills[J]. Rupkatha Journal on Interdisciplinary Studies in Humanities, 2024, 16(2).
[80] FEI H, LIU Q, ZHANG M S, et al. Scene graph as pivoting: inference-time image-free unsupervised multimodal machine translation with visual scene hallucination[J]. arXiv:2305.12256, 2023.
[81] ZHENG J B, LI S Y, TAN C, et al. Leveraging graph-based cross-modal information fusion for neural sign language translation[J]. arXiv:2211.00526, 2022.
[82] SAN M E, USANAVASIN S, THU Y K, et al. A study for enhancing low-resource Thai-Myanmar-English neural machine translation[J]. ACM Transactions on Asian and Low-Resource Language Information Processing, 2024, 23(4): 1-24.
[83] YAN J, LIN T, ZHAO S. Migration learning and multi-view training for low-resource machine translation[J]. International Journal of Advanced Computer Science and Applications, 2024, 15(5): 0150572.
[84] BOGOYCHEV N, CHEN P Z. Terminology-aware translation with constrained decoding and large language model prompting

中国知网　https://www.cnki.net

[J]. arXiv:2310.05824, 2023.
[85] JUNCZYS-DOWMUNT M, GRUNDKIEWICZ R, GUHA S, et al. Approaching neural grammatical error correction as a low-resource machine translation task[J]. arXiv:1804.05940, 2018.
[86] GHAZVININEJAD M, GONEN H, ZETTLEMOYER L. Dictionary-based phrase-level prompting of large language models for machine translation[J]. arXiv:2302.07856, 2023.
[87] LIU J P, HUANG K Y, YU H, et al. Continual learning for multilingual neural machine translation via dual importance-based model division[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2023: 12011-12027.
[88] CHEN Z H, HANDA H, SHIRAHAMA K. JCSE: contrastive learning of Japanese sentence embeddings and its applications[J]. arXiv:2301.08193, 2023.
[89] VU T T, HE X L, PHUNG D, et al. Generalised unsupervised domain adaptation of neural machine translation with cross-lingual data selection[J]. arXiv:2109.04292, 2021.
[90] WANG D X, FAN K, CHEN B X, et al. Efficient cluster-based k-nearest-neighbor machine translation[J]. arXiv:2204.06175, 2022.
[91] BEIGI A, TAN Z, MUDIAM N, et al. Model attribution in LLM-generated disinformation: a domain generalization approach with supervised contrastive learning[C]//Proceedings of the 2024 IEEE 11th International Conference on Data Science and Advanced Analytics. Piscataway: IEEE, 2024: 1-10.
[92] PEREZ-MARTIN J, GOMEZ-ROBLES J, GUTIÉRREZ-FANDIÑO A, et al. Cross-lingual search for e-commerce based on query translatability and mixed-domain fine-tuning[C]//Proceedings of the ACM Web Conference 2023. New York: ACM, 2023: 892-898.
[93] MICHAIL A, KONSTANTINOU S, CLEMATIDE S. UZH_CLyp at SemEval-2023 task 9: head-first fine-tuning and ChatGPT data generation for cross-lingual learning in tweet intimacy prediction[J]. arXiv:2303.01194, 2023.
[94] SCHMIDT F D, VULIĆ I, GLAVAŠ G. Don't stop fine-tuning: on training regimes for few-shot cross-lingual transfer with multilingual language models[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2022: 10725-10742.
[95] AHMED N. A review of existing machine translation approaches, their challenges and evaluation metrics[J]. Pakistan Journal of Engineering, Technology & Science, 2023, 11(1): 29-44.
[96] FU Y X, SI S J, MAI L Y, et al. FFN: a fine-grained Chinese-English financial domain parallel corpus[C]//Proceedings of the 2024 International Conference on Asian Language Processing. Piscataway: IEEE, 2024: 127-132.
[97] BÉRARD A, CALAPODESCU I, DYMETMAN M, et al. Machine translation of restaurant reviews: new corpus for domain adaptation and robustness[J]. arXiv:1910.14589, 2019.
[98] MILLER K J, VANNI M. Inter-rater agreement measures, and the refinement of metrics in the PLATO MT evaluation paradigm[C]//Proceedings of Machine Translation Summit X: Papers, 2005: 125-132.
[99] HARALAMPIEVA V, CAGLAYAN O, SPECIA L. Supervised visual attention for simultaneous multimodal machine translation[J]. Journal of Artificial Intelligence Research, 2022, 74: 1059-1089.
[100] ZHENG C M, FENG J H, CAI Y, et al. Rethinking multimodal entity and relation extraction from a translation point of view[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2023: 6810-6824.
[101] RAGANATO A, VÁZQUEZ R, CREUTZ M, et al. An empirical investigation of word alignment supervision for zero-shot multilingual neural machine translation[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2021: 8449-8456.
[102] NISHIHARA T, TAMURA A, NINOMIYA T, et al. Supervised visual attention for multimodal neural machine translation[C]//Proceedings of the 28th International Conference on Computational Linguistics. Stroudsburg: ACL, 2020: 4304-4314.
[103] YE R, WANG M X, LI L. Cross-modal contrastive learning for speech translation[J]. arXiv:2205.02444, 2022.
[104] GAN S W, YIN Y F, JIANG Z W, et al. Contrastive learning for sign language recognition and translation[C]//Proceedings of the 32nd International Joint Conference on Artificial Intelligence. San Francisco: Morgan Kaufmann, 2023: 763-772.
[105] ZHOU M Y, CHENG R X, LEE Y J, et al. A visual attention grounding neural model for multimodal machine translation[J]. arXiv:1808.08266, 2018.
[106] FUTERAL M, SCHMID C, LAPTEV I, et al. Tackling ambiguity with images: improved multimodal machine translation and contrastive evaluation[J]. arXiv:2212.10140, 2022.
[107] GUPTA D, KHARBANDA S, ZHOU J W, et al. CLIPTrans: transferring visual knowledge with pre-trained models for multimodal machine translation[C]//Proceedings of the 2023 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2023: 2863-2874.
[108] LIN R H, HU H F. MissModal: increasing robustness to missing modality in multimodal sentiment analysis[J]. Transactions of the Association for Computational Linguistics, 2023, 11: 1686-1702.
[109] CHEN Q, DONG S H, WANG P M. Advanced multimodal sentiment analysis with enhanced contextual fusion and robustness (AMSA-ECFR): symmetry in feature integration and data alignment[J]. Symmetry, 2024, 16(7): 934.
[110] HIRASAWA T, KANEKO M, IMANKULOVA A, et al. Pretrained word embedding and language model improve multimodal machine translation: a case study in Multi30K[J]. IEEE Access, 2022, 10: 67653-67668.

中国知网 https://www.cnki.net